




2교시 · 수작업 표현 (hand-crafted representation)

서열에서 사람이 직접 feature 를 설계한다 — 물성 · 인코딩 · 진화정보

3교시 스토리 덱 중 2교시 · 재직자·전공자 · 한국어

'1교시의 물성 축'이 그대로 '표현 축'이 된다

1교시에서 본 것 (토대)

- 아미노산 결사슬 물성: 소수성·전하·크기·방향족
- 특수 잔기: Cys(이황화)·Pro(꺾임)·Gly(유연)
- 1~4차 구조 계층 — 물성이 접힘·기능을 만든다

2교시에서 하는 것 (표현)

- 같은 물성을 '서열에서 숫자로' 계산(pI ·GRAVY·MW)
- 서열을 고정 벡터로 인코딩(one-hot·조성·k-mer)
- 진화정보(MSA·PSSM)로 보존·문맥까지

+심화

정제·발현에서 쓰던 물성 감각(소수성·전하·크기·흡광)이 그대로 계산 feature 설계 감각으로 이어진다. 1교시 물성/구조 기초는 여기서 재설명하지 않고 '입력'으로만 쓴다.

이 교시에서 볼 것 — 수작업 표현의 전개

A. 표현이란·왜 중요한가

representation 정의·성능 상한·저분자 대비·3단계 계보

B. 물성 feature

ProtParam: MW·pI·GRAVY·instability·aromaticity (+실습)

C. 서열 인코딩

one-hot·AAC·DPC·k-mer·PAAC·CTD·윈도우 프로파일

D. 진화정보

PSSM·MSA 보존성 — 강하지만 조건부

E. 예측 툴(큰 그림)

물성·용해도·응집·국재화·안정성·항체 + 정직한 한계

요약 · 3교시 예고

수작업 계열 비교표 · '사람이 설계 vs 기계가 학습'

PART A

단백질 표현이란·왜 중요한가

같은 단백질, 다른 벡터 → 다른 성능

'표현(representation)'이란 무엇인가

- 표현 = 단백질(서열·구조)을 기계가 다룰 수 있는 '숫자 벡터/행렬'로 바꾼 것
- 모델은 아미노산 글자가 아니라 벡터만 본다 → 표현이 곧 '입력 언어'
- 좋은 표현 = 과제에 필요한 정보(물성·보존·구조·기능)를 담고 불필요한 건 버린 것
- 표현 → 모델 → 예측: 파이프라인 맨 앞이자 성능의 상한을 결정

용어 · representation

단백질을 고정/가변 차원의 수치 벡터·행렬로 사상한 것 — feature·descriptor·embedding 과 혼용

표현의 위치 — 서열에서 예측까지

① 서열 (raw)

아미노산 글자열 — 기계가 직접 못 읽음

② 표현 (feature)

벡터/행렬로 변환 — 2교시의 주제(사람이 설계)

③ 모델

SVM · RF · 회귀 · 신경망 — 벡터만 입력받음

④ 예측 · 해석

용해도 · 안정성 · 기능 · 유사도 — downstream 출력

+심화

②가 병목이자 상한 — ①은 고정, ③④는 ②가 담은 정보 안에서만 작동한다. 그래서 '어떤 모델'보다 '어떤 표현'을 먼저 고민한다.

표현이 성능의 상한을 정한다

표현이 나쁘면

- 필요한 신호가 벡터에 아예 없음
- 모델이 아무리 커도 못 배움
- 과적합 · 일반화 실패
- 해석 불가

표현이 좋으면

- 적은 데이터로도 학습(전이)
- 단순 모델(SVM/RF)로도 높은 성능
- 도메인 외 일반화 여지 ↑
- 의미 있는 유사도 · 검색

+심화

핵심 프레임: '어떤 모델을 쓰느냐'보다 '단백질을 어떤 벡터로 바꾸느냐'가 downstream(용해도 · 안정성 · 기능) 성능을 더 크게 좌우하는 경우가 많다.

표현이 담아야 할 정보 — 무엇을 벡터에 넣나

조성(composition)

각 아미노산이 얼마나 있나 — 물성·전하·소수성의 총량

국소 순서(local order)

이웃 잔기 패턴·모티프 — 기능 부위의 서열 신호

진화 보존(conservation)

계열에서 안 변하는 위치 = 기능적으로 중요

구조·문맥(3D·context)

3D 배치·먼 잔기 간 관계 (2교시 밖 — 3교시 주제)

+심화

수작업 표현은 이 중 조성·국소순서·진화보존을 사람이 '골라' 담는다. 구조·문맥은 담기 어려워 학습된 표현·구조 표현(3교시)으로 넘어간다.

저분자 표현 vs 단백질 표현

저분자(small molecule)

- SMILES 문자열 · 분자 그래프
원자=노드, 결합=엣지
- Morgan/ECFP 지문(고정 비트)
- 수십~수백 원자 규모
- RDKit 로 즉시 descriptor 계산

단백질(protein)

- 20종 아미노산 서열(길이 수백~수천)
- 1~4차 구조 · 거대 분자
- 서열↔구조↔기능 관계 복잡
- 가변 길이 → 고정 벡터화가 과제

+심화

공통점은 '분자를 벡터로'지만 규모 · 계층성이 다르다 — 단백질은 길이가 가변이고 3D 접힘 · 상호작용이 기능을 만들어, 조성 · 서열 · 구조를 아우르는 다층 표현이 필요하다.

단백질 표현의 3단계 진화 — 이 교시의 위치

① 수작업 특성공학 (2000s~)

one-hot·AAC·PAAC·CTD·물성(AAindex/ProtParam) — 사람이 feature 설계 + SVM/RF

② 진화정보 (~2019)

PSSM·MSA·공진화 — 동족체 많으면 강력, 그러나 MSA 검색 느림·고아 취약

③ 학습된 표현 PLM (2021~)

ESM·ProtT5 임베딩이 '새 표준 feature' — 대규모 사전학습(3교시)

③+ 구조+PLM 융합 (2023~)

구조 인식 PLM·GNN·AlphaFold 소스 — 서열 임베딩에 3D 결합(3교시)

+심화

2교시는 ①·② (파란·청록) — 사람이 직접 설계하는 수작업 표현. ③·③+ (회색)의 학습된·구조 표현은 3교시 전담. '특성공학이 사라진' 게 아니라 새 표준으로 편입됐을 뿐.

'좋은 수작업 표현'의 조건

- 과제 관련성: 예측할 특성(용해도·안정성 등)과 연결된 정보를 담을 것
- 고정 차원: 가변 길이 서열을 전통 ML 이 받는 고정 벡터로
- 해석 가능성: 각 feature 가 물리·화학적으로 무슨 뜻인지 말할 수 있을 것
- 저비용·재현성: 계산이 빠르고 결과가 결정론적(같은 입력=같은 벡터)

+심화

수작업 표현의 최대 강점이 바로 이 '해석 가능성 + 저비용 + 소규모 데이터 적합'. 담을 수 있는 정보에 상한이 있다는 게 약점 — 그 상한을 넘으려는 게 3교시.

수작업 표현 = '특성공학(feature engineering)'

특성공학(2교시)

- 도메인 지식으로 feature 를 사람이 '설계'
- 물성·조성·순서·보존을 골라 맞춤
- 무엇을 답을지 사람이 결정
- 투명하지만 정보 상한 존재

표현학습(3교시 예고)

- 데이터로 표현을 '학습'(자동)
- PLM 이 문맥적 임베딩 생성
- 무엇을 답을지 모델이 결정
- 강력하지만 블랙박스·데이터 의존

+심화

2교시 전체가 '특성공학' 이야기다 — 서열에서 사람이 직접 feature 를 설계하는 기술. 3교시의 표현학습과 대비되는 축을 지금 확실히 잡아두자.


PART B

물성 feature

생화학 물성을 '서열에서 숫자로' — ProtParam

아미노산 물성 척도 — AAindex

- 각 아미노산에 물성 값을 부여한 지수 모음(수백 종)
- 소수성·부피·전하·유연성·2차구조 선호 등
- 서열 → 잔기별 물성 벡터 → feature
- 1교시 결사슬 물성의 '정량판'(재설명 없이 참조만)



용어 · AAindex

아미노산 물성 지수 데이터베이스(Kawashima & Kanehisa) — 서열 기반 물성 feature 의 원재료

세 물성 축 → 실험 · 표현의 공통 언어

물성 축	척도 예	실험 · 표현 연결
소수성	Kyte-Doolittle · GRAVY	용해도 · 막 · HIC
전하 · pI	겔사슬 pKa · 순전하 · 등전점	IEX 완충 pH · 정전기
크기 · 부피	잔기 부피 · 분자량(MW)	패킹 · SEC
방향족	Trp/Tyr/Phe 함량	A280 흡광 · 스택킹

+심화

1교시 물성 축(소수성 · 전하 · 크기 · 흡광)이 그대로 계산 feature 가 된다 — '실험의 축'과 '표현의 축'이 같다는 것이 이 강의의 뼈대.

서열에서 바로 계산되는 물성 (ProtParam)

물성	의미	용도 · 표현
MW	분자량	SDS-PAGE 예상
theoretical pI	등전점	IEX 완충 pH
extinction coef.	280nm 흡광계수	A280 정량
GRAVY	평균 소수성	용해도·막 가늠
instability index	불안정성 지수(>40 불안정)	안정성 플래그
aromaticity	방향족 잔기 비율	흡광·스택킹

용어 · ProtParam

ExPASy의 서열→물성 계산기(MW·pI·흡광·GRAVY·instability·aromaticity) — 실험/표현 공통 1번 도구

ProtParam — 물성을 '규칙'으로 계산

핵심 원리

1. **조성 집계** — 서열에서 각 아미노산·원자 개수 카운트
2. **MW** — 잔기 질량 합 - $(n-1) \times \text{물 질량}$
3. **pI** — 각 이온화기 pKa 로 순전하=0 되는 pH 를 이분탐색
4. **ϵ_{280}** — nTrp·nTyr·nCys 기여 합(Gill & von Hippel)
5. **GRAVY** — Kyte-Doolittle hydropathy 평균
6. **instability** — DIWV 이펩타이드 가중합 · aromaticity=방향족 비율

차별점 · 강점

- ▶ 학습 없는 순수 규칙 계산 → 즉시·투명
- ▶ 물리·경험 상수(pKa· ϵ 기여) 사용
- ▶ 결과가 곧 ML feature 이자 실험 수치

한계 · 주의

- Trp 없으면 ϵ 부정확·Cys 산화상태 영향
- instability·GRAVY 는 휴리스틱(단정 금지)

BioPython 으로 물성 표현 계산

서열 → pI · GRAVY · MW · 흡광계수 · 불안정성

```
from Bio.SeqUtils.ProtParam import ProteinAnalysis
seq = 'MKTAYIAKQRQISFVKSHFSRQLEERLGLIEVQ'
pa = ProteinAnalysis(seq)
pa.molecular_weight()      # MW
pa.isoelectric_point()     # 이론 pI
pa.gravy()                 # 평균 소수성
pa.aromaticity()          # 방향족 비율
pa.instability_index()     # >40 이면 '불안정' 플래그
```

▶ 이 소수의 물성 값이 곧 해석 가능한 저차원 feature — 소규모 데이터 · 설명 필요 과제에 강함

⚠ 함정

물성 벡터는 저차원 · 해석적이지만 서열의 국소 모티프 · 문맥은 못 담는다 → 복잡 과제엔 조성 · k-mer 와 결합

여러 서열 → 물성 feature 행렬 (numpy)

서열 리스트 → ($N \times 5$) 물성 feature 행렬

```
import numpy as np
from Bio.SeqUtils.ProtParam import ProteinAnalysis
def feats(seq):
    pa = ProteinAnalysis(seq)
    return [pa.molecular_weight(), pa.isoelectric_point(),
            pa.gravy(), pa.aromaticity(), pa.instability_index()]
X = np.array([feats(s) for s in seqs]) # (N, 5)
# X 를 그대로 sklearn 분류/회귀 모델 입력으로
```

▶ 각 서열이 5차원 물성 벡터 → 고정 크기 ($N \times 5$) 행렬 → SVM/RF 등 전통 ML 에 바로 투입

⚠ 함정

물성 스케일이 제각각(MW 수만 vs GRAVY 소수점) → StandardScaler 등 정규화 후 모델에 넣어야 편향 방지

계산 물성 → 실험 결정 (예)

pI → IEX 완충 pH

- 예측 pI 6.2 인 단백질
- pH 5.2(pI-1) → 양전하 → CEX 결합
- pH 7.2(pI+1) → 음전하 → AEX 결합
- pI 근처 pH · 저염은 침전 주의

흡광계수 → A280

- $\epsilon(280)$ 계산(Trp · Tyr · Cys)
- A280 측정 → $c = A/(\epsilon \cdot l)$
- 염료 assay 없이 농도 정량
- Trp 없으면 신뢰도 ↓

+심화

'한 서열'에서 정제 완충 조건과 정량법이 바로 나온다 — 실험 시작 전 5분 계산이 며칠을 아낀다. 이 값들이 동시에 ML feature 이기도 하다.

물성 feature — 요약과 한계

- 장점: 저차원·해석적·계산 즉시·소규모 데이터에 강함
- 각 feature 가 물리화학적 의미를 가져 '왜'를 설명 가능
- 한계: 서열의 순서·국소 모티프·문맥 정보를 담지 못함
- 보완: 조성·k-mer(순서)·진화정보(보존)와 결합해 정보량 확장



함정

instability index>40='불안정', GRAVY 부호 등은 휴리스틱 — 단일 수치로 단정 말고 플래그·근거로만 사용


PART C

서열 인코딩

서열을 고정 벡터로 — one-hot · 조성 · k-mer · 서술자

one-hot 인코딩 — 가장 단순한 표현

- 각 잔기를 20($\pm$ unknown/gap)차원 0/1 벡터로
- 서열 길이 $L \rightarrow L \times 20$ 행렬
- 단순 · 투명, 정보 손실 없음(원본 보존)
- 작은 데이터 · baseline 에 유용



용어 · one-hot

범주(아미노산 20종)를 서로 직교하는 0/1 벡터로 인코딩 — 유사도 정보를 담지 못함

one-hot · 조성(AAC) 인코딩 (numpy)

서열 → one-hot($L \times 20$) · 조성(20차원)

```
import numpy as np
AA = 'ACDEFGHIKLMNPQRSTVWY'
idx = {a:i for i,a in enumerate(AA)}
def onehot(seq):
    M = np.zeros((len(seq), 20))
    for i,a in enumerate(seq): M[i, idx[a]] = 1
    return M
aac = onehot(seq).mean(0)      # 아미노산 조성(20차원, 길이 무관)
```

▶ one-hot= $L \times 20$ 행렬(가변 길이), 평균 풀링=조성(고정 20차원) — 전통 ML(SVM/RF) 입력




함정

조성(AAC)은 순서 정보를 완전히 버린다 — 같은 조성·다른 서열을 구분 못 함. 순서가 중요하면 k-mer/PSSM 필요

아미노산 조성(AAC) · 서술자 계열

- AAC: 아미노산 빈도(20차원, 길이 무관)
- DPC: 이웃 2잔기 빈도(dipeptide, 400차원)
- PAAC: 조성 + 서열순서 상관향(Chou 2001)
- CTD: 물성그룹 조성·전이·분포(Dubchak 1995)



용어 · AAC/PAAC/CTD

길이 무관 고정벡터 서열 서술자 — 전통 ML(SVM/RF) 입력의 표준

조성·k-mer 계열 서술자 — 차원과 의미

서술자	무엇	차원(대략)
AAC	아미노산 빈도	20
DPC / dipeptide	이웃 2잔기 빈도	400
k-mer (k=3)	연속 3잔기 빈도	8,000(희소)
PAAC	조성 + 서열순서 상관항(Chou)	20+λ
CTD	물성그룹 조성·전이·분포(Dubchak)	~100+

+심화

AAC→DPC→k-mer 로 갈수록 국소 순서·모티프를 담지만 차원이 급증하고 희소해진다. PAAC·CTD 는 물성/순서를 압축한 절충안 — 모두 '길이 무관 고정 벡터'라 전통 ML 에 바로 투입.

PAAC — 조성에 '서열 순서'를 되살린다

- 문제: AAC 는 순서를 완전히 버려 같은 조성·다른 서열을 구분 못 함
- 해법(Chou): 조성 20차원 + 물성 기반 서열순서 상관항 λ 개 추가
- 상관항 = 일정 간격 잔기쌍의 물성(소수성·친수성·질량) 유사도 평균
- 결과: $20+\lambda$ 고정 벡터 — 순서 정보를 '압축'해 담음

CTD — 물성 그룹으로 서열을 요약

Composition (C)

각 물성 그룹(예: 소수성/중성/친수성) 잔기의 전체 비율

Transition (T)

이웃한 두 잔기가 서로 다른 그룹으로 바뀌는 빈도

Distribution (D)

각 그룹이 서열의 앞·중간·끝 어디에 분포하는지

+심화

CTD 는 아미노산을 소수성·전하·극성·2차구조 선호 등 물성 그룹으로 묶어(예: 3그룹) 조성·전이·분포를 계산 — 물성 정보를 순서까지 함께 압축한 ~100차원대 서술자.

DPC · k-mer — 국소 순서를 담되 차원이 폭증

어떻게 담나

- DPC: 이웃 2잔기 쌍 빈도($20 \times 20 = 400$)
- k-mer: 연속 k잔기 빈도(20^k)
- $k=3 \rightarrow 8,000$ 차원(대부분 0 = 희소)
- 모티프 · 국소 순서 신호를 포착

트레이드오프

- 차원 $\uparrow \rightarrow$ 과적합 · 계산 비용 $\uparrow$
- 희소 $\rightarrow$ 대부분 관측 안 됨
- gap 서술자(CKSAAP)로 완화 시도
- 실무: 차원 축소 · 정규화 병행

+심화

AAC(20) $\rightarrow$ DPC(400) $\rightarrow$ k-mer(20^k)로 갈수록 '순서 해상도'는 올라가지만 차원 · 희소성이 급증한다. 데이터가 적을수록 저차원(AAC · 물성)이 오히려 안전.

물성 프로파일 · 윈도우 feature

- AAindex 물성을 서열 따라 나열 → 잔기별 물성 프로파일
- 이동창(sliding window) 평균 → 국소 환경 표현(hydrophathy plot 등)
- 잔기 주변 문맥을 압축 — 막·2차구조 고전 예측기의 입력
- 윈도우 크기가 하이퍼파라미터(작으면 국소, 크면 전역)

+심화

one-hot·조성·물성 프로파일은 모두 '사람이 설계한' 수작업 feature — 소규모·해석에는 여전히 유효. 잔기 단위 예측엔 프로파일, 전역 분류엔 조성이 유리.

인코딩의 공통 속제 — 가변 길이를 고정 벡터로

per-residue ($L \times d$, 가변)

- one-hot($L \times 20$) · 물성 프로파일
- 잔기 단위 과제(2차구조 · contact)
- 패딩/트렁케이션 필요
- 전통 ML 엔 그대로 못 넣음

per-protein (d , 고정)

- 조성 · DPC · PAAC · CTD · 물성 스칼라
- 전역 분류 · 회귀(국재화 · 용해도)
- 길이 무관 → SVM/RF 바로 투입
- 풀링(평균)으로 순서 손실

+심화

과제의 granularity에 표현을 맞춘다: 잔기 단위면 per-residue, 단백질 단위면 per-protein. 수작업 표현은 대개 풀링으로 고정 벡터를 만들며, 이때 순서 정보 손실이 트레이드오프.

서열 인코딩 — 무엇을 언제

상황	권장 인코딩	이유
데이터 매우 적음	물성 · AAC(저차원)	과적합 방지 · 해석
순서 · 모티프 중요	DPC · k-mer · PAAC	국소 순서 신호
물성+순서 절충	PAAC · CTD	압축된 고정 벡터
동족체 많음	PSSM(PART D)	진화 보존 · 공변이
잔기 단위 과제	one-hot · 물성 프로파일	위치별 정보 유지

+심화

실무 시작점: 강한 baseline(AAC+물성)부터 돌려보고, 필요하면 순서(k-mer/PAAC) · 진화(PSSM)를 더한다. 처음부터 고차원 인코딩은 소규모 데이터에서 오히려 손해.

서열 인코딩 — 한눈에

인코딩	형태·차원	담는 정보	놓치는 것
one-hot	$L \times 20$ (가변)	원본 보존	유사성·길이
AAC/조성	20(고정)	전체 물성 총량	순서
DPC/k-mer	400~수천	국소 모티프	고차원·희소
PAAC/CTD	$\sim 20 + \lambda$ / $\sim 100 +$	조성+순서 압축	장거리 문맥
물성 프로파일	L 또는 윈도우	국소 물성 환경	전역 구조

+심화

공통점: 사람이 '무엇을 담을지' 설계 → 투명하고 소규모에 강함. 조성·k-mer 는 순서·모티프를, PAAC·CTD 는 둘의 절충을 노린다. 진화 보존은 다음 PART D 가 담당.


PART D

진화정보 (evolutionary)

MSA·PSSM — 진화가 남긴 보존·공변이 신호

PSSM · MSA — 진화가 남긴 신호

- 상동체 정렬(MSA) → 컬럼별 보존·공진화
- PSSM: 위치별 20아미노산 log-odds 행렬($L \times 20$)
- 보존=기능 중요, 공변이=3D 접촉 신호
- 단일서열보다 풍부한 문맥



용어 · PSSM

position-specific scoring matrix — 계열에서 관찰된 위치별 치환 선호(PSI-BLAST/HHblits)

MSA · PSSM · 공변이 — 진화 feature

핵심 원리

1. **상동체 검색** — PSI-BLAST/HHblits 로 쿼리와 유사 서열 수집
2. **MSA 구성** — 수집 서열 다중정렬(컬럼=상동 위치)
3. **위치별 빈도** — 각 컬럼 아미노산 관측빈도 $f(i,a)$ + pseudocount
4. **log-odds** — 배경빈도 대비 $\log(f/p) \rightarrow$ PSSM 행렬($L \times 20$)
5. **반복 검색** — PSSM 으로 재검색해 원거리 상동체 추가
6. **공변이** — 컬럼 쌍 상관(DCA) $\rightarrow$ contact 신호(구조예측 입력)

차별점 · 강점

- ▶ 단일서열 대비 '진화적 보존·공변이' 포착
- ▶ 반복 검색으로 원거리 상동체까지
- ▶ 보존도가 곧 기능 중요도 힌트

한계 · 주의

- 동족체 적으면 얇은 MSA $\rightarrow$ 약함(고아)
- 검색 비용·시간
- 정렬 품질에 민감

공변이 → 접촉 신호 (3교시 브리지)

- 함께 변하는 잔기쌍(공진화)은 3D 에서 가까울 가능성이 높다
- 컬럼 쌍 상관을 직접 커플링(DCA/Potts)으로 정제 → 간접 상관 제거
- 출력 = $L \times L$ 접촉 신호 → 구조 예측 · 구조 표현의 입력
- 이 신호가 곧 3교시 학습된 · 구조 표현으로 이어지는 다리

+심화

수작업 진화정보의 정점이 공변이 → contact. 다만 이를 정확한 구조 표현으로 바꾸는 딥러닝 · PLM 은 3교시 주제 — 여기서 '진화정보가 구조 힌트를 담는다'까지만.

진화정보 — 강하지만 조건부

강력할 때

- 동족체가 많을 때 매우 강함
- 보존=기능 중요 위치 짚어냄
- 공변이=3D 접촉·구조 신호
- 단일서열보다 풍부한 문맥

약할 때·비용

- 고아(orphan)·설계 단백질엔 얕은 MSA
- MSA 검색 비용·시간 큼
- 정렬 오류에 민감
- → 단일서열 PLM 이 이 공백 겨냥(3교시)

+심화

진화정보는 수작업 표현 중 정보량이 가장 크지만 '동족체가 있어야' 작동한다. 이 조건부 약점이 단일서열로 동작하는 학습된 표현(3교시)이 등장한 직접적 이유.

진화정보 feature — 어디에 쓰나

feature 형태

- PSSM: 잔기별 20차원 log-odds($L \times 20$)
- 보존 점수: 컬럼별 엔트로피/보존도
- 공변이: 잔기쌍 커플링 → contact 신호
- 잔기·전역 과제 모두에 사용

대표 활용

- 2차구조 예측(PSIPRED 입력)
- 기능 부위·잔기 중요도 추정
- 구조 예측의 핵심 입력(공변이)
- 원거리 상동성 탐지

+심화

PSSM 은 '위치별' 표현이라 잔기 단위 과제에 강하다. 수작업 표현의 정점이지만 MSA 의존이 한계 — 이 지점이 3교시 학습된 표현으로 넘어가는 자연스러운 다리.

PART E

예측 툴 — 큰 그림

수작업 표현 + 모델 → 실험 특성을 미리 예측

왜 미리 예측하나 — 예측 → 실험 결정

- 발현·정제·안정성 실험은 비싸고 느리다
- 서열의 수작업 표현 + 간단한 모델로 특성을 미리 예측 → 리스크 조기 발견
- 문제 단백질을 '재설계'하거나 전략(태그·숙주·완충) 변경
- 대부분 무료 웹 서버 — 예측값이 곧 구체적 실험 결정으로

+심화

프레임: 예측값 → 실험 결정. pl→완충 pH, 흡광계수→A280, 응집 hotspot→변이/태그, 신호펩타이드→construct. 이 큰 그림만 잡고 개별 톨 계보는 생략한다.

물리화학 예측 — pI · MW · 흡광 · GRAVY

무엇을 예측

- MW · 이론 pI · 흡광계수 · GRAVY · 불안정성
- 순전하 vs pH 곡선
- 모두 규칙 기반 계산(학습 불필요)
- PART B 물성 feature 그대로 활용

실험 결정 연결

- pI → IEX 완충 pH(CEX/AEX)
- 흡광계수 → A280 농도 정량
- GRAVY → 용해도 · 막 가늠
- instability → 안정성 플래그

+심화

대표 도구: ExPASy ProtParam(규칙 기반). pI 는 딥러닝 계산기(IPC 2.0)도 있으나 개념은 동일 — '서열에서 물리화학 상수를 계산해 실험에 바로 쓴다'.

용해도 · 응집 예측 — 발현 실패를 앞단으로

용해도 · 발현

- 서열 → 가용 발현 확률 · 용해도 점수
- 전하 · 소수성 패치 · 서열복잡도가 신호
- 낮으면 → 태그 · 저온 · 숙주 변경
- 대표: Protein-Sol · CamSol

응집 · 아밀로이드

- '끈적한' 소수성 hotspot(APR) 탐지
- β -응집(TANGO) · 아밀로이드(WALTZ)
- hotspot → 표면 변이 · 가용화 태그
- 구조로 표면 노출 보정(AGGRESCAN3D)

용어 · APR

aggregation-prone region — 응집을 유발하는 짧은 소수성 세그먼트(엔지니어링 표적)

국제화 · 신호 · 무질서 예측

특성	무엇을 예측	실험 결정
신호펩타이드	분비 · 절단부위(SignalP)	성숙형 construct
막 topology	막관통 · 내외 방향(DeepTMHMM)	detergent · 도메인
세포내 국제화	다중라벨 위치(DeepLoc)	숙주 선택
무질서(IDR)	유연 영역(IUPred3)	말단 절단 · 결정화

+심화

응용(1교시 국제화 연결): 신호펩타이드→성숙형 클로닝, TM→detergent/도메인 절단, 국제화→숙주, 무질서 말단 절단→결정화·안정성 ↑. 대표 톨만 제시(계보 생략).

안정성($\Delta\Delta G \cdot T_m$) · 항체 developability

안정성 · 변이($\Delta\Delta G \cdot T_m$)

- 한 잔기 치환 → 접힘 자유에너지 변화($\Delta\Delta G$)
- $\Delta\Delta G > 0$ 불안정화 · < 0 안정화
- T_m (녹는점) 등급 예측도 있음
- 안정화 변이 설계 · 선별

항체 developability

- 효능 외 '제조성' 위험 조기 선별
- 응집 · 점도 · 용해도 · 전하 패치
- TAP: CDR 기반 5지표로 플래그
- 수백 후보를 실험 전 triage

용어 · developability

치료 항체가 응집 · 점도 · 발현 등 제조 관점에서 실용 가능한지 — 후기 실패를 앞단으로 (TAP)

예측 → 실험 결정 매핑 (한 장 요약)

예측 특성	대표 도구	실험 결정
pl · 흡광계수	ProtParam · IPC 2.0	IEX 완충 pH · A280 정량
용해도 · 응집	Protein-Sol · TANGO · A3D	태그 · 변이 · 숙주
신호 · TM · 국재화	SignalP · DeepTMHMM · DeepLoc	construct · detergent · 숙주
무질서	IUPred3	말단 절단 · 결정화
안정성 · developability	FoldX · TAP	변이 설계 · 후보 triage

+심화

실무 순서: 값이 싼 서열 예측을 먼저 전부 돌려 '리스크 지도'를 만든 뒤 발현·정제 실험을 설계 — 실패를 앞단으로 당긴다.

예측 툴 쓸 때 — 정직한 한계

- 예측 ≠ 측정 — 반드시 실험 검증(A280·IEF·DSF·SEC/DLS)
- 훈련 도메인 한계(대개 E.coli 수용성·구형 단백질)
- 막·분비·당화·설계 단백질엔 덜 맞을 수 있음
- 성능·정확도 수치는 데이터·분할 의존 → 절대치보다 '경향'으로



함정

instability index>40='불안정', pLDDT=disorder 등은 휴리스틱/proxy. 단일 수치로 단정 말고 여러 근거·실측과 함께 — 성능 수치는 원논문·벤치마크 확인 권장

오늘의 실습 — 수작업 표현 직접 만들기

- ① one-hot($L \times 20$) · ② 아미노산 조성(AAC, 20) 을 numpy 로 구현
- ③ 물성 feature(ProtParam: pI · GRAVY · MW · 흡광 · instability)를 BioPython 으로
- ④ 여러 서열 → 고정 크기 feature 행렬 → 간단 분류/군집
- 표현별 벡터로 'family 구분력'을 눈으로 비교 — 정성 관찰 중심

+심화

목표: 표현 선택이 결과를 어떻게 바꾸는지 체감. 성능 수치는 데이터·분할에 의존하므로 절대치보다 '경향'에 주목(3교시에서 학습된 표현과 비교).

수작업 표현 계열 — 한눈에 (차원·장단점)

표현	차원	장점	단점
one-hot	$L \times 20$	단순·무손실	가변길이·유사성無
AAC/조성	20	길이무관·빠름	순서 손실
DPC/k-mer	400~수천	국소 모티프	고차원·희소
PAAC/CTD	$\sim 20 + \lambda / \sim 100 +$	조성+순서 압축	장거리 문맥無
물성(ProtParam)	수~수십	해석적·실험연결	문맥 없음
PSSM/MSA	$L \times 20$	진화 보존·공변이	고아 취약·느림

+심화 공통 특징: 사람이 feature 를 '설계'한다 → 투명·해석적이고 소규모 데이터에 강하지만, 답을 수 있는 정보에 상한이 있다. 그 상한을 넘으려는 것이 3교시의 학습된 표현.

수작업 표현이 여전히 중요한 이유

- 소규모 데이터: 저차원·해석적 feature 가 과적합을 막는다
- 해석·규제 대응: '왜 이 예측인지'를 물성·보존으로 설명 가능
- 강한 baseline: PLM 이 항상 이기지 않는다 — 반드시 비교 기준으로
- 하이브리드: 실무에선 물성 몇 개 + 학습된 표현을 함께 쓰는 경우 많음

+심화

'특성공학이 사라졌다'는 오해 — 수작업 표현은 baseline·해석·소규모 과제에서 여전히 1선. 3교시의 학습된 표현도 이 위에서 비교·보완된다.

2교시 정리 — 서열에서 사람이 설계한다

1

표현 = 단백질을 벡터로 바꾼 것, 파이프라인 맨 앞 · 성능 상한
'모델보다 표현을 먼저 의심하라'

2

물성 feature: ProtParam 으로 pI · GRAVY · MW · 흡광을 서열에서 계산
해석적 · 소규모에 강함

3

서열 인코딩: one-hot · 조성 · k-mer · PAAC · CTD · 프로파일
순서 · 모티프를 고정 벡터로

4

진화정보: PSSM · MSA 보존 · 공변이 — 강하지만 동족체 조건부
고아 · 설계엔 약함

5

예측 틀: 수작업 표현+모델로 특성 예측 → 실험 결정, 단 실측 필수
예측 ≠ 측정

다음 — 사람이 설계 vs 기계가 학습

2교시 (수작업 표현)

- 사람이 feature 를 직접 설계
- 물성·조성·k-mer·PSSM
- 투명·해석·소규모에 강함
- 답을 수 있는 정보에 상한

3교시 (학습된·구조 표현)

- 데이터에서 표현을 자동 학습
- PLM 임베딩(ESM·ProtT5)·전이학습
- 구조 표현(contact·graph·AlphaFold)
- 문맥·대규모·MSA 불필요

+심화

한 문장 브리지 — 2교시는 '사람이 무엇을 담을지 고른다', 3교시는 '기계가 무엇을 담을지 배운다'. 수작업 표현의 정보 상한을 넘는 학습된·구조 표현으로 넘어간다.

주요 출처 (2교시)

• 물성/인코딩: Kawashima & Kanehisa NAR 2000 (AAindex); Kyte & Doolittle 1982 (GRAVY); Gasteiger et al. 2005 (ProtParam); Gill & von Hippel 1989 (ϵ280); Guruprasad 1990 (instability).	• 예측 툴(대표): Teufel 2022 (SignalP 6.0); Hallgren 2022 (DeepTMHMM); Thumuluri 2022 (DeepLoc 2.0); Erdős 2021 (IUPred3); Schymkowitz 2005 (FoldX); Raybould 2019 (TAP, PNAS).
• 서술자: Chou 2001 (PAAC, Proteins); Dubchak et al. 1995 (CTD, PNAS); Rao et al. 2019 (TAPE, NeurIPS).	• 저분자 대비 · 리뷰: Rogers & Hahn 2010 (ECFP, JCI); Zhang C et al. 2025 (Biology 14:1137, 서열표현 리뷰).
• 진화정보: Altschul 1997 (PSI-BLAST); Remmert 2012 (HHblits, Nat Methods); Jones 1999 (PSIPRED); Morcos et al. 2011 (DCA, PNAS).	• 3교시 연계: Rives 2021 (ESM-1b, PNAS); Lin 2023 (ESM-2, Science); Elnaggar 2022 (ProtTrans/ProtT5); Tsuboyama 2023 (megascale ΔG, Nature).
• 예측 툴(대표): Hebditch 2017 (Protein-Sol); Sormanni 2015 (CamSol); Fernandez-Escamilla 2004 (TANGO); Maurer-Stroh 2010 (WALTZ, Nat Methods); Kuriata 2019 (AGGRESCAN3D 2.0).	• * 일부 서지(PAAC/TANGO DOI, DeepTMHMM 정식게재 등)는 확인 권장. 예측 툴은 교육용 — 라이브 URL · 버전 · 적용범위 확인 필요. 성능 수치는 원논문 · 벤치마크에서 확인.

감사합니다

2교시 · 수작업 표현 — 서열에서 사람이 직접 feature 를 설계한다

핵심 참고: Kawashima & Kanehisa 2000 (AAindex) · Gasteiger 2005 (ProtParam) · Chou 2001 (PAAC)
Dubchak 1995 (CTD) · Altschul 1997 (PSI-BLAST) · Rao 2019 (TAPE)

다음 3교시: 학습된 표현(PLM·임베딩) & 구조 기반 표현