




1교시 · 화학정보학과 분자 구조 표현

분자를 컴퓨터로 표현하는 법 = 이후 모든 예측의 토대

신약개발 화학정보학 3교시 과정 · 1교시 · 재직자·전공자 · 한국어

분자를 다루려면, 먼저 분자를 '표현'해야 한다

- 컴퓨터는 화학 구조(그림)를 직접 인식하지 못한다
기계가 보는 것은 오직 숫자·비트(0/1)
- 그래서 분자를 수학적·논리적 기호로 '번역'하는 것이 화학정보학의 첫걸음
- 이 번역(표현, representation) 위에 검색·예측·설계가 모두 올라간다
- 1교시: 화학정보학이 무엇이며, 분자를 1D/2D/3D 로 어떻게 표현하는가
2·3교시의 토대

+심화

관통 메시지: '무엇을 어떻게 표현하나'를 모르면 어떤 모델도 세울 수 없다. 표현이 담는 정보의 종류·정밀도가 뒤 단계(예측·설계)의 상한을 정한다.

3교시 과정 지도 — 지금 어디에 있나

1교시 · 화학정보학과 분자 구조 표현

◀ 현재

개요 · 역사 · 신약 파이프라인 · DB · 분자를 1D/2D/3D 로 표현

2교시 · SMILES & 분자 기술자

SMILES/SMARTS 문법 · 정규화 · fingerprint · molecular descriptor

3교시 · QSAR & 모델링

정량적 구조-활성 관계(QSAR) · 예측 모델 · 실습

+심화

흐름: '분자를 표현한다(1교시)' → '문자열 · 기술자로 특징을 뽑는다(2교시)' → '구조-활성 관계를 모델링한다(3교시)'. 뒤로 갈수록 표현이 예측으로 이어진다.

1교시가 끝나면

- 화학정보학의 정의·역사·신약개발 내 위치를 설명한다
Gasteiger 정의·50년 역사·CADD
- 화학 데이터를 다루는 정보 시스템과 공개 DB 를 안다
- 왜 이름(명명법)이 아닌 수학적 표기가 필요한지 설명한다
translation gap
- 분자를 0D→1D→2D→3D 로 표현하는 계층을 구분한다
- 표준 식별자(InChI)·파일 포맷(MOL/SDF)·표현 비교를 이해한다
2·3교시로 연결

1교시에서 볼 것 — 두 갈래

PART 1 · 화학정보학 개요

- **A. 화학정보학이란**
정의 · vs 생물정보학 · 4대 과제
- **B. 발전의 역사**
디지털화 → QSAR → 3D → 빅데이터
- **C. 신약개발 파이프라인**
CADD · SBDD/LBDD · 가상탐색
- **D. 데이터 · DB**
정보 시스템 · 지식 · 공개 DB

PART 2 · 분자 구조 표현

- **E. 왜 구조 표현?**
명명법 한계 · translation gap
- **F. 차원 계층**
0D → 1D → 2D → 3D
- **G. 1D 선형 표기**
WLN · SMILES(개념)
- **H. 표준 식별자**
InChI · InChIKey
- **I. 2D 분자 그래프**
connection table · 행렬
- **J. 3D · 파일 포맷**
컨포머 · MOL/SDF/PDB
- **K. 종합 · 브리지**
표현 비교 · 2교시로

PART A

화학정보학이란?

화학 문제를 정보학 방법론으로 푸는 학문 — 데이터를 지식으로

화학정보학(Cheminformatics)의 정의

“화학적 문제를 해결하기 위해
정보학(Informatics) 방법론을 적용하는 학문”

— Johann Gasteiger

1

데이터 관리 (Data Management)

방대한 화학 구조·반응의 디지털 저장·검색·체계화

2

지식 추출 (Knowledge Extraction)

데이터 마이닝으로 화학 패턴·정량적 구조-활성 관계(QSAR) 발견

3

합리적 예측 (Rational Prediction)

수학적 모델로 미지 화합물의 특성(독성·생리활성)을 사전 예측

화학정보학 vs 생물정보학

구분	화학정보학	생물정보학
연구 대상	저분자 화합물 (small molecules)	유전자·단백질 (genes & proteins)
발전 시기	1990년대 이후 본격화	상대적으로 더 일찍 정착
주요 과제	유기 합성 계획·신약 설계	서열 분석·단백질 접힘 예측

+심화 경계는 모호하다: 저분자 화합물이 단백질에 결합하는 과정을 연구할 때 두 학문의 경계는 완전히 융합된다 (예: 구조 기반 신약 설계).

화학정보학의 4대 핵심 과제

과제 (Task)	입력	출력	핵심 기술
1. 표현 (Representation)	물리적 분자	수학적 표현자(Descriptor)	그래프 이론 · 위상수학
2. 데이터 (Data Systems)	화학 데이터	구조화된 정보/DB	시스템 아키텍처 · 검색
3. 학습 (Machine Learning)	데이터 & 정보	예측 모델	통계 · 패턴 인식 · AI
4. 응용 (Application)	타겟 분자	최적 합성 경로	역합성 분석 · 지식 DB

+심화

오늘(1교시)은 과제 1 '표현' 과 과제 2 '데이터' 를 다룬다. 과제 3 '학습'(QSAR)은 3교시, 표현자 산출은 2교시 뒀이다.

PART B

발전의 역사

구조의 디지털화에서 빅데이터·AI 까지 — 50년의 여정

화학정보학 발전의 50년 여정

1950s-60s

구조의 디지털화

화학 구조의 기계어 번역 및 데이터베이스 태동

1970s

규칙의 발견

부분 구조 검색과 정량적 구조-활성 관계(QSAR)의 등장

1980s

3D 혁명

개인용 컴퓨터 보급과 3D 분자 모델링의 실용화

1990s-현재

데이터 대폭발

HTS·조합화학의 등장 및 'Cheminformatics' 명명

구조의 디지털화와 검색의 시작

- 초기 컴퓨터의 제한된 저장·연산력을 극복하기 위한 '번역'의 시대
- 선형 표기법(Linear Notation): WLN 등 구조를 1차원 문자열로 압축 저장
- 연결 테이블(Connection Table): 1957년 Ray & Kirsch — 원자·결합을 행렬로 명시 기록
- CAS(Chemical Abstracts Service) 레지스트리 — 방대한 문헌 구조의 DB화 시작
현대 시스템의 근간

용어 · Connection Table

원자·결합을 수학적 행렬로 명시 기록해 컴퓨터가 화학적 위상(topology)을 이해하게 한 표현 (2D 파트에서 상세)

규칙의 발견과 3D 모델링

1970s · 규칙과 예측의 기원

- DENDRAL (1965~): 최초의 화학 전문가 시스템
- Feigenbaum & Lederberg (Stanford)
- 질량 분석 데이터로 구조를 스스로 추론
- QSAR 1964 Hansch & Fujita: 물성↔활성 정량화
 $\text{Log}(1/C) = a\pi + b\sigma + c$

1980s · 3D 혁명 · 정보 대중화

- CONCORD (1987, Pearlman): 2D→3D 자동 변환
- PC 보급으로 책상 위 정보 검색 가능
- Beilstein · Gmelin 등 전통 사전의 전자 DB화
- 수용체-리간드 도킹 등 3D 기반 설계의 문
입체화학의 시대

빅데이터와 'Cheminformatics' 명명

- 조합화학 & HTS: 로봇으로 한 번에 수만 개 화합물 합성·시험
- 처리할 데이터가 상상 못할 규모로 다시 한 번 폭발
- 용어의 탄생 (1998): F. K. Brown 이 'Cheminformatics' 로 명명
- 정의: 신약개발에서 방대한 데이터를 지식으로 변환해 더 나은 의사결정을 내리는 과정

+심화

데이터 규모: 100년간 100만 개에 불과하던 화합물이 2000년 1,500만 개로 기하급수 성장했고, 오늘날 3,500만 개 이상으로 확대 — 사람 손으로는 감당 불가.


PART C

신약개발 파이프라인 속 화학정보학

무작위 실험에서 합리적 설계(CADD)로 — 표현이 만드는 예측

무작위 실험(Trial & Error)의 한계

- 과거: 물리적 합성·시험에 100% 의존
- 개발 기간 10~14년, 평균 비용 \$800M~\$1B+
- 성공률 단 0.01% 수준 (FDA 승인 기준)
- 병목: Phase II 임상 높은 실패율
주원인 = 독성·약효 부족




⚠ 함정

물리적 합성과 맹목적 무작위 시험에 의존하는 과거 방식은 시간·비용 측면에서 더 이상 지속 불가능하다.

신약개발 파이프라인과 CADD

- CADD (Computer-Aided Drug Design) = In silico 개입
- 단계: Target ID → Lead ID → Lead Opt → 전임상 → 임상
- 화학정보학은 주로 1~3단계(타겟~선도물질 최적화)에 집중
- 의미: 약을 '발견'에서 정밀하게 '설계'하는 패러다임 전환



구조 기반(SBDD) vs 리간드 기반(LBDD)

SBDD (구조 기반 설계)

- 조건: 표적 단백질의 3D 구조를 알 때
X-ray · NMR 등
- 주요 기술: 분자 도킹 · 분자 동역학(MD)
- 원리: 자물쇠(단백질) 모양에 맞는 열쇠(약) 설계

LBDD (리간드 기반 설계)


- 조건: 표적 3D 구조는 모르나 활성 리간드는 알 때
- 주요 기술: pharmacophore 모델링 · QSAR
QSAR 상세=3교시
- 원리: 작동하는 열쇠들의 공통 패턴으로 더 나은 열쇠 유추

+심화

두 접근 모두 '정확한 구조 표현'을 전제로 한다 — 도킹은 3D 좌표를, pharmacophore/QSAR 는 기술자를 필요로 한다. 그래서 표현이 먼저다.

가상 탐색(Virtual Screening)

- 대규모 화학 라이브러리: ZINC·ChEMBL 등 수백만~수천만 화합물
- In silico 필터링: 결합력·독성·약물성(drug-likeness) 초고속 스크리닝
- 결과: 물리 실험(in vitro)에서 테스트할 소수 Hit/Lead 선별
- 전제: 정확한 구조 표현(CT·fingerprint) 없이는 부분/유사도 검색 불가



+심화

핵심: 한 번의 물리 합성 전에 독성·비결합 화합물을 미리 걸러 천문학적 비용을 절감. 'fingerprint·유사도 검색'의 상세는 2교시.

PART D

데이터 · 데이터베이스 · 정보 시스템

방대한 화학 데이터를 관리·검색·지식화하는 골격

화학 정보 시스템의 작동 구조




+심화

방대·복잡한 화학 데이터를 최종 사용자가 쉽게 검색하도록, 어플리케이션 계층과 저장소 계층(DB / Flat-File)을 엄격히 분리해 관리한다.

화학 데이터베이스 landscape

- 화합물 라이브러리: ZINC · ChEMBL (수백만~수천만 화합물)
- 주식·매핑 DB: ChEBI · DrugBank · KEGG
- 식별자 체계: CAS Registry · Beilstein · Gmelin
- Open Babel: 110종 화학 파일 포맷 상호 변환
MOL/SDF · PDB · MOL2 등



+심화

이들은 원본 강의에 등장한 DB·도구다. 서로 다른 DB 를 잇는 '보편 키'가 필요한데 — 그 역할이 뒤에 나올 InChIKey 다.

PART E

왜 '구조 표현'이 필요한가

이름으로는 부족하다 — 기계가 읽는 수학적 표기로

화학자의 언어 vs 컴퓨터의 언어

화학자의 언어

- 인간의 직관
- 형태와 그림 (2D/3D 구조식)
- 공간적 성질로 사고
- 사람 사이 소통에 최적

컴퓨터의 언어

- 기계의 논리
- 비트(0과 1)
- 수학적 연산만 가능
- 그림·직관은 인식 불가

+심화

기계는 원자도 결합도 '보지' 못한다. 화학 구조를 컴퓨터가 이해할 인공 언어로 번역하지 못하면 AI·QSAR·가상탐색 어떤 분석도 불가능하다 (Translation Gap).

하나의 구조, 수많은 이름 — 명명법의 함정

에탄올 한 물질 → **Ethanol · Ethyl alcohol · EtOH · 에탄올 · Hydroxyethane ...**

같은 구조가 수많은 동의어를 가져 컴퓨터는 'Ambiguous Input' 으로 처리 → DB 매칭 불가

관용명 (Trivial)

- 예: Acetic Acid, Palytoxin
- 직관적 · 소통 빠름
- 규칙이 없어 알고리즘으로 구조 복원 불가

계통 명명법 (IUPAC)

- 예: Ethanoic Acid
- 이름에서 구조 도출 규칙 존재
- 이름이 매우 길어지고 파싱 비용 큼

+심화

결론: 명명법은 텍스트 인덱싱엔 적합하나, 부분 구조 검색 · 물성 계산 · 대규모 마이닝엔 한계 — 이름이 아닌 수학적 · 시스템적 표기가 필요하다.

표준 파일 포맷 = 글로벌 공용어

- 화학 SW 마다 내부 데이터 구조(Internal Format)가 모두 다르다
- 이들을 연결할 글로벌 공용어(External Exchange Format)가 필수 — 보통 ASCII 텍스트
- MDL Molfile & SDF (.sdf): 2D/3D 구조+비구조 속성을 한 파일에 — 제약 산업 지배적 표준
- PDB (.pdb): 단백질 등 거대 분자(macromolecule)의 3D 좌표 표준

+심화

이런 표준 포맷이 없었다면 기관 간 데이터 공유와 AI 모델 구축은 불가능했을 것 — 표현은 '저장·교환'의 문제이기도 하다. (포맷 상세는 J 파트)

PART F

표현의 차원 계층

0D → 1D → 2D → 3D · 담는 정보가 늘수록 복잡도도 는다

분자 표현의 4가지 차원 (0D→3D)

0D

분자식 (Molecular Formula)

$C_2H_4O_2$ — 구성 원자의 종류·수, 위상 정보 없음

1D

선형 표기 (Line Notation)

C=CC(C)=O 등 SMILES·WLN 문자열, 기계 파싱에 최적

2D

위상 그래프 (Connection Table)

원자(노드)·결합(에지)의 2차원 네트워크

3D

공간 좌표 (3D Coordinates)

x,y,z 데카르트 좌표·입체화학, 물리 현실에 가장 근접

같은 분자(카페인)를 다르게 표현하기

표현 방식	값 (카페인, Caffeine)
관용명 (Common)	Caffeine
분자식 (0D)	C8H10N4O2
IUPAC 명	1,3,7-trimethylpurine-2,6-dione
CAS 번호	58-08-2
WLN (1D)	T56 BN DN FNVNVJ B F H
SMILES (1D)	CN1C=NC2=C1C(=O)N(C(=O)N2C)C
InChI	InChI=1/C8H10N4O2/c1-10-4-9-6-5(10)7(13)12(3)8(14)11(6)2/h4H,1-3H3

+심화

같은 분자여도 목적에 따라 표현이 다르다 — 이름은 사람용, 분자식은 요약, SMILES/WLN 은 전송, InChI 는 식별. 다음 파트부터 1D→2D→3D 순으로 본다.

PART G

1D 선형 표기법 (Line Notation)

2D 구조를 한 줄 문자열로 — 저장·전송에 최적

2D에서 1D로의 번역 · 진화

문제 & 해결

- 화학자의 2D 구조식은 직관적이거나
- DB 저장·검색엔 부적합
- → 구조를 1D 알파벳·숫자 문자열로
- 변환하는 '선형 표기법' 필요

진화 (1960s→현재)

- WLN (1960s): 최초의 대중적 암호화
- ROSDAL (1980s초): Beilstein DB용
- SLN (1980s중): 명시적 수소·확장성
- SMILES (현재): 직관 문법·글로벌 표준

+심화

공통 원리: 2D 위상(topology) 구조를 1D 문자열로 '평면화(flattening)'하여 저장 용량을 최소화하고 검색·전송 속도를 극대화한다.

WLN · ROSDAL · SLN — 무엇이 달랐나

표기법	핵심 논리	특징 · 한계
WLN	프래그먼트(Fragments) 기호화	최초 시스템; 같은 구조에 여러 코드(모호성) · 인간 판독 난해
ROSDAL	그래프 노드-에지 (1-2=3)	원자에 번호 부여 · 기호로 결합 표현; Beilstein 검색에 최적화
SLN	원자 + ID (Atom+ID)	명시적 수소 표기 · 데이터 확장성; 마쿠쉬 구조 · 3D 속성 처리

+심화

흐름: 프래그먼트(WLN)의 모호성 → 수학적 그래프(ROSDAL)로 명확성 확보 → 확장성(SLN) → 직관 · 호환성의 SMILES 로 수렴. 지금 표준은 SMILES.

SMILES — 현재의 글로벌 표준 (문법은 2교시)

- Simplified Molecular Input Line Entry System — Weininger 1988
- Daylight Chemical Information Systems 개발 · 정의: opensmiles.org
- 연결 테이블과 stereochemistry 를 한 줄 문자열로 표현 (예: 에탄올 CCO)
- 철학: 컴퓨터가 이해할 만큼 완벽하고, 사람이 키보드로 빠르게 칠 만큼 단순

⚠ **함정**

한 분자가 여러 SMILES 로 표현됨(one-to-many) → DB 중복 · ML 입력 시 'Canonical SMILES'로 정규화해야 안전. 정규화 · 문법 상세는 2교시.

PART H

표준 식별자 (InChI / InChIKey)

하나의 구조 = 하나의 코드 · DB 를 잇는 보편 키

표기법이 갖춰야 할 두 원칙

명확성 (Unambiguous)

- 하나의 코드 → 오직 하나의 구조로 복원
- 코드를 읽으면 구조가 유일하게 결정됨
- 데이터 신뢰성의 전제

유일성 (Unique)

- 하나의 구조 → 오직 하나의 표준 코드
- 번호 매기는 순서와 무관하게 동일 코드
- 해결: Morgan Algorithm(정규화)

+심화

문제: 같은 구조라도 원자 번호 부여 순서에 따라 수천 개의 다른 코드가 생성될 수 있다. Morgan Algorithm 이 위상 대칭성을 계산해 항상 동일한 '표준(Canonical)' 코드를 부여 — 데이터 중복 방지의 핵심.

InChI — 구조 기반 국제 표준 식별자

- International Chemical Identifier — NIST & IUPAC 개발
- 목적: 분자를 고유하게 식별 · 구조 기반 생성(CAS 번호와 달리) · 구조와 1:1 매칭
- 계층 구조: 분자식 / 원자 연결 / 수소 / 전하 / 입체화학 sub-layer
- 특징: 구조 이성질체(tautomer)가 같은 InChI 를 가짐 (SMILES 는 아님)

Aspirin InChI: InChI=1/C9H8O4/c1-6(10)13-8-5-3-2-4-7(8)9(11)12/h2-5H,1H3,(H,11,12)

용어 · InChIKey

InChI 를 27자 고정 길이로 해시한 코드(예: BSYNRYMUTXBXSQ-...) — 사람이 쓰기 어렵지만 DB 검색·매칭에 최적. InChI Trust 오픈소스로 생성

InChIKey — 서로 다른 DB 를 잇는 열쇠

- 각 DB(ChEBI · DrugBank · KEGG ...)는 자체 ID 체계를 가진다
- 구조 기반 InChIKey 를 공통 키로 쓰면 DB 간 동일 분자를 상호 매칭 가능
- 예: Aspirin — ChEBI:15365 · InChIKey BSYNRYMUTXBXSQ-WXRBYKJCCW
- InChIKey 하나로 ChEBI ↔ DrugBank ↔ KEGG 를 연결
데이터 통합의 접착제

+심화

실무 감각: 여러 DB 를 합칠 때 이름 · CAS 로 매칭하면 놓치거나 충돌한다. 구조에서 계산되는 InChIKey 로 매칭하는 것이 가장 안전하다.


PART I

2D 분자 그래프 (Connection Table)

분자 = 수학적 그래프 · 화학정보학의 가장 핵심 기반 층

분자 = 수학적 그래프

- 원자(Atom) = 노드(Node)
- 결합(Bond) = 에지(Edge)
- 결합의 실제 길이·각도 같은 기하 정보는 무시
- '무엇이 무엇과 연결되어 있는가'라는 순수 연결성(topology)만 추출



용어 · 위상(Topology)

기하(거리·각도)를 뺀 순수 연결 관계 — 2D 그래프가 담는 정보이자 부분 구조 검색·그래프 분석의 기반

구조를 데이터로: 행렬(Matrix) 표현

행렬 방식	정의	화학적 활용
인접 행렬 (Adjacency)	두 원자의 연결 여부 1/0	분자의 기본 골격 구조 인식
거리 행렬 (Distance)	두 원자 간 최단 경로의 결합 수	3D 공간 특성·원자 간 거리 유추
결합 행렬 (Bond)	결합 차수(단일/이중 등) 기록	다중 결합의 화학적 성질 반영
발생 행렬 (Incidence)	원자-결합(간선) 직접 관계 매핑	다중 결합·네트워크 위상 분석

+심화 N개 원자 분자 → $N \times N$ 행렬. 인접 행렬은 이중 결합 정보를 잃으므로, 위상 거리엔 distance matrix, 다중 결합엔 bond matrix 를 쓴다.

행렬의 한계와 Connection Table

문제 · Sparse Matrix

- 실제 분자는 크지만 결합은 국지적
- 행렬은 불필요한 0 을 무수히 저장
- → 메모리 낭비(비효율)

해결 · Connection Table (CTab)

- Atom List: 원소 · 좌표(x,y,z)
- Bond List: 결합한 원자쌍 · 결합 종류
- 존재하는 결합만 리스트로 나열
산업 표준

+심화

CTab 은 원자 정보와 '존재하는 결합의 쌍'만 리스트로 저장 — 컴퓨터가 위상을 완벽히 파악하면서 메모리를 절약. 현대 파일 포맷(MOL/SDF)의 심장이다.

PART J

3D 좌표와 파일 포맷

위상을 넘어 공간으로 · MOL/SDF/PDB 로 저장

2D를 넘어: 입체화학과 3D의 필연성


- 때로는 위상(topology)만으로는 부족하다
- 생체 내 단백질 수용체는 3D 지형(topography)을 인식한다
- 연결이 같아도 입체(stereochemistry) 배치가 다르면 — 하나는 약(Drug), 하나는 독(Toxin)
- 현대 표기는 Wedge 결합·3D 좌표 보관으로 표현 체계를 현실에 가깝게 확장

용어 · 거울상 이성질체(Enantiomer)

2D 연결은 동일하나 3D 배치가 거울상인 한 쌍 — 생체 반응이 전혀 다를 수 있어 3D 표현이 필수

3D 구조와 컨포머(Conformer)

- 3D 표현 = 각 원자의 x, y, z 데카르트 좌표
- 물리적 현실에 가장 근접 — 도킹·물리화학 상호작용에 사용
- 한 분자도 회전·유연성으로 여러 3D 형태(컨포머)를 가짐
- CONCORD(1987) 등: 2D 연결 테이블 → 3D 구조 자동 생성



+심화

주의: 3D 는 정보량이 가장 크지만 기계 처리 비용도 크고 사람이 읽긴 불가능하다 — 목적에 맞는 차원을 고르는 것이 실무 감각.

MOL file — 연결 테이블의 파일화

acetaldehyde.mol (MDL Molfile, 발췌)

```

NSC7594 acetaldehyde
  7  6  0  0  0  ...  V2000
    0.0000  0.0000  0.0000  C   ← Atom block (x,y,z·원소)
    1.5000  0.0000  0.0000  C
    2.1200 -1.0200 -0.0200  O
  1  2  1  0  0  0  0   ← Bond block (원자1 원자2 결합차수)
  2  3  2  0  0  0  0   (2번C = 3번O, 이중결합)
M  END

```

▶ Header(이름) · Counts line(원자·결합 수) · Atom block · Bond block — Fortran 기반 고정 컬럼 규칙

대규모 저장(SDF)과 거대 분자(PDB)

SDF (Structure-Data File)

- Molfile(단일 분자) 여러 개를 이어붙임
- 각 분자 뒤에 속성 필드 추가 (예: <E_LOGP>)
- \$\$\$\$ 구분자로 분자 경계 표시
- 수만 화합물+속성 → ML 데이터셋의 뼈대

PDB (Protein Data Bank)

- Brookhaven 개발 · 단백질 결정 구조 저장
- 3D 좌표 중심, 컬럼 고정 크기
- 한계: bond order 정보 없음
- 후속: mmCIF 포맷으로 대체 진행

+심화

실무: 저분자는 MOL/SDF, 단백질 구조는 PDB/mmCIF. Open Babel 은 이런 110여 종 포맷을 서로 변환한다 (2교시 실습에서 다룸).

PART K

종합 & 2교시 브리지

표현 방법 비교 · 문자열 표현과 기술자로 이어짐

표현 방법 비교 — 목적에 맞는 도구

표기법	사람 가독	저장 공간	부분 검색	주요 용도
구조식 (Drawings)	최상	큼	수동	논문·인간 소통
SMILES (1D)	중간	매우 작음	어려움	DB 저장·빠른 교환
Connection Table (2D)	하	중간	빠름	계산·모델링·그래프 분석
Fingerprint (비트)	불가	매우 작음	매우 빠름	유사도 검색·ML (2교시)

+심화

단일 최강 표현은 없다: SMILES 는 전송, Connection Table 은 정밀 위상 계산, Fingerprint 는 초고속 스크리닝에 최적. Fingerprint·기술자 상세는 2교시.

1교시 정리

1

화학정보학 = 화학 문제를 정보학으로 푸는 학문(데이터→지식→예측)

Gasteiger; 1998 명명

2

컴퓨터는 그림을 못 본다 → 분자를 수학적 기호로 '번역'하는 것이 첫걸음

translation gap

3

표현은 차원 계층: 0D 분자식 → 1D 선형(SMILES) → 2D 그래프(CT) → 3D 좌표

4

유일·명확한 식별엔 InChI/InChIKey; 저장·교환엔 MOL/SDF/PDB

5

단일 최강 표현은 없다 — 목적(검색·계산·ML)에 맞게 고른다

2·3교시의 토대

구조 표현이 곧 2교시의 'feature 축'

1교시에서 본 것

- 분자를 1D/2D/3D 로 표현
- SMILES = 1D 선형 문자열(개념)
- Connection Table = 2D 그래프
- InChI · MOL/SDF = 식별 · 저장

2교시에서 숫자가 된다

- SMILES/SMARTS 문법 · 정규화
- fingerprint (구조 → 비트 벡터)
- molecular descriptor (물성 · 위상 지표)
- → QSAR 모델 입력(3교시)

+심화

한 문장 브리지 — 오늘 배운 '분자 표현'이 그대로 2교시에서 문자열(SMILES)과 기술자로 정량화되고, 3교시 QSAR 예측의 입력이 된다.

2교시 예고

SMILES & 분자 기술자 — 구조를 숫자로

SMILES/SMARTS 문법 · 정규화 · fingerprint · molecular descriptor · 공개 DB · Open Babel 실습

분자를 표현하는 법을 알았으니 — 이제 그것을 '숫자 특징(feature)'으로 바꾼다.

주요 출처 (1교시)

- 원본 강의자료: 1_화학정보학.pdf (52p); 2_분자구조표현방법.pdf (46p).
- 정의·역사: Gasteiger (화학정보학 정의); Ray & Kirsch 1957 (Connection Table); Feigenbaum & Lederberg (DENDRAL).
- QSAR·3D: Hansch & Fujita 1964 (QSAR); Pearlman 1987 (CONCORD); F. K. Brown 1998 ('Cheminformatics' 명명).
- 선형 표기·식별자: Weininger, J Chem Inf Comput Sci 1988, 28, 31 (SMILES); opensmiles.org; NIST & IUPAC / InChI Trust (InChI).
- 포맷·표준: MDL Molfile & SDF; PDB(Brookhaven)·mmCIF; Open Babel (110 formats); Pistoia Alliance (HELM).
- DB: ZINC · ChEMBL · ChEBI · DrugBank · KEGG · CAS Registry · Beilstein · Gmelin (원본 강의 등장 범위).
- * 모든 수치·명칭은 위 두 원본 PDF 정독 내용에 근거 (무-날조). 문법·기술자·QSAR 상세는 2·3교시에서 다룸.

감사합니다

1교시 · 화학정보학과 분자 구조 표현 — 표현이 모든 예측의 토대

다음: 2교시 SMILES & 분자 기술자 → 3교시 QSAR & 모델링

핵심 프레임: 분자를 어떻게 표현하나(0D→3D) = 이후 검색·예측·설계의 상한