

2교시 · 분자 구조 표현 방법 II

SMILES와 분자 기술자 — 구조를 '문자열'과 '벡터'로

문자열 표현(SMILES·canonical·입체·SMARTS) → 벡터 표현(기술자 0D~4D·지문)

분자 구조 표현 3교시 과정 · 2교시 · 재직자·전공자 · 한국어

3교시 과정 지도 — 지금 어디에 있나

1교시 · 분자 구조 표현의 기초

화학정보학 개요 · 분자 그래프 · InChI · 파일 포맷(MOL/SDF)

2교시 · SMILES와 분자 기술자

◀ 현재

문자열 표현(SMILES·canonical·입체·SMARTS) + 벡터 표현(기술자·지문)

3교시 · QSAR 모델링

기술자·지문을 입력으로 → 구조-활성 관계 학습 · 검증 · 적용범위

+심화

흐름: '구조를 어떻게 그리나(1교시)' → '구조를 문자열·벡터로 어떻게 바꾸나(2교시)' → '그 벡터로 활성을 어떻게 예측하나(3교시)'. 표현이 있어야 모델이 있다.

구조 표현에서 문자열·벡터 표현으로

1교시에서 본 것 (참조)

- 분자를 그래프로: 노드=원자, 엣지=결합
- InChI·파일 포맷(MOL/SDF)으로 구조 저장
- 2D 그림 = 사람이 보는 표현

2교시에서 할 것

- SMILES: 그래프를 한 줄 문자열로 직렬화
- Canonical: 1분자 = 1문자열 (중복 제거)
- 기술자·지문: 구조를 숫자 벡터로 변환

+심화

핵심 전환: 1교시의 '분자 그래프'를 (a) 사람·기계가 주고받는 문자열(SMILES)과 (b) 모델이 먹는 숫자 벡터(기술자·지문)로 바꾼다. 둘 다 '구조를 잃지 않고' 옮기는 표현.

2교시에서 볼 것

A. SMILES 문법

원자·결합·분지·고리·방향족·단절·반응 (6대 규칙)

B. Canonical SMILES

1분자 1문자열 · Morgan / Cangen 알고리즘

C. 입체·SMARTS·함정

Isomeric SMILES · 부분구조 검색 · RDKit · 흔한 함정

D. 분자 기술자

0D~4D 분류 · constitutional·topological·geometrical

E. 지문(Fingerprint)

구조키 · 해시 · 원형(ECFP) · 기술자 vs 지문

F. 표현자 품질 요건

무결성·타당성·유용성 (좋은 표현의 조건)

G. 3교시 브리지

기술자·지문 → QSAR 모델의 입력

PART A

SMILES 문법

분자 그래프를 한 줄 문자열로 — 6대 규칙

SMILES — 화학을 위한 언어

언어로서의 성질

- 의미론적 명확성: 왼→오른쪽으로 읽으면 구조가 유일하게 도출
- LR-1 문법: 백트래킹 없이 스트림으로 초고속 파싱
- 유한함: 무한한 예외가 아닌 극소수(6개) 규칙

왜 문자열인가

- SMILES = Simplified Molecular Input Line Entry System
- 확장성: 새 화학 개념도 기존 시스템 안 깨고 확장
- 그래프(1교시)를 텍스트 한 줄로 직렬화 → 저장·검색·입력 용이

용어 · SMILES

분자 그래프를 ASCII 문자열로 표기하는 1D 표현법 — 사람·기계 모두 읽고 쓰는 화학의 공용어

1D 문자열 표현들 — SMILES · InChI

SMILES

- 사람이 읽고 쓰기 쉬움 · 입력 친화적
- 실습: MolDraw(SMILES→구조 시각화)
- 본 2교시의 주 표현

InChI (1교시 참조만)

- IUPAC 표준 · 계층적 레이어 구조
- 주로 기계가 생성·대조하는 식별자
- 파일 포맷과 함께 1교시에서 다룸

+심화

1D = 한 줄 문자열 표현. SMILES와 InChI가 대표. InChI·파일 포맷의 상세는 1교시 소관이므로 여기서는 위치만 짚고, 2교시는 SMILES에 집중한다.

원자(Atoms) — 문장의 알파벳

- 원자는 원소 기호로 표기한다
- 유기물 부분집합(B C N O P S F Cl Br I)은 대괄호 [] 생략 가능
예: C(메탄), O(물), S(황화수소), Cl(염화수소)
- 수소(H) 개수는 정상 원자가에 맞춰 자동 계산
B(3) C(4) N(3) O(2) P(3,5) S(2,4,6) F/Cl/Br/I(1)
- 그 외 모든 상태(동위원소·전하·기타 원소)는 대괄호 안에 명시
예: [235U](동위원소), [Fe+2](전하), [Au](기타 원소)



함정

대괄호를 쓰면 H는 더 이상 자동 계산되지 않는다 — [C]는 수소 0개(흑연 탄소), C는 메탄(H 4개).

원자의 속성 — 전하·수소·질량 (대괄호 안)

속성	표기	예시·의미
전하(charge)	부호+숫자 또는 부호 반복	[Co+2] 또는 [Co++] · Cobalt(II)
수소 수(H count)	기호 뒤 H+정수	[NH4+] · 암모늄, implicit H 명시
하전된 H	H 자체가 원자	[H+] · 양성자(proton)
동위원소(mass)	기호 앞 정수	[13C] · Carbon-13, [2H] 중수소
중수(예)	조합	[2H]O[2H] · Heavy Water

+심화 원자 속성(전하·chirality 포함)을 지정하려면 반드시 대괄호가 필요하다. H는 보통 원자로 세지 않는(implicit) 속성이지만, 하전·질량 지정 시엔 explicit H로 취급된다.

결합(Bonds) — 원자를 잇는 접착제

결합	기호	예시
단일 결합	- (생략 가능)	에탄: CC 또는 C-C
방향족 결합	: (생략 가능)	방향족 고리 내부
이중 결합	=	에텐: C=C
삼중 결합	#	사이안화수소: C#N
비결합(단절)	. (dot)	[Na+].[Cl-] · 이온쌍 · 혼합물

+심화

인접 원자 사이의 단일(-)·방향족(:) 결합 기호는 입력 단순화를 위해 생략 가능 — 그래서 물은 O, 에탄올은 CCO로 짧게 쓴다. dot(.)은 결합 차수 0을 뜻한다.

분지(Branches) — 분자의 결가지

- 결가지(Branch)는 괄호 () 로 묶어 표현한다
- 괄호는 무한히 중첩(nested)되거나 연속(stacked)될 수 있다
예: C(F)(F)F 플루오로폼 · CCCC(C(=O)O)CCC
- 괄호 안에서 결합 기호도 지정 가능
예: CC(=O)O 아세트산
- 예: 아이소부티르산 골격 CC(C)C(=O)O
주사슬 C-C-C-O · 첫 가지 (C) · 둘째 가지 (=O)

+심화

괄호는 트리(tree) 구조를 만든다 — 주사슬에서 갈라지는 결가지를 괄호로 감싸 표현. 중첩·연속으로 임의의 분지 골격을 직렬화한다.

고리(Rings) — 그래프의 무한 루프 해제

- 연결된 고리의 결합 하나를 임의로 끊어 선형 사슬로 만든다
- 끊어진 두 원자 뒤에 같은 숫자(Ring Closure Digit)를 붙인다
예: 사이클로헥세인 C1CCCCC1
- 한 원자가 둘 이상의 고리 닫힘을 가질 수 있다
데칼린 C1CCC2CCCCC2C1 · 닫힘 번호는 재사용 가능
- 고리 닫힘의 기본 결합은 단일(또는 방향족)
결합 기호를 숫자 앞에 넣어 지정: C1=CCCCC1 등

+심화

핵심 아이디어: 그래프의 고리는 그대로 직렬화할 수 없으므로 '결합 하나를 끊고 번호표를 붙여' 선형 문자열로 만든 뒤, 같은 번호끼리 다시 이어 붙여 고리를 복원한다.

방향족성(Aromaticity) — 소문자 표기

- 방향족 원자는 소문자로 표기: 벤젠 c1ccccc1
- 소문자 허용 원자: c, n, o, p, s, as, se, * (wildcard)
- 탐지 기준: 고리의 여분 p-전자 수가 Hückel $4N+2$ 를 만족
- 질소는 문맥에 따라 다르다
피리딘 n1ccccc1 · 피롤 [nH]1cccc1 (H 명시 필요)



함정

n(피리딘형, p-전자 1개 기여)과 [nH](피롤형, p-전자 2개 기여)는 다르다 — 피롤 질소는 H를 반드시 명시해야 방향족으로 인식된다.

단절(.)과 흐름(>) — 문장 부호

마침표 (.) — 단절

- 결합 차수 0을 의미
- 형식적으로 연결 안 된 이온쌍·혼합물 나열
- 예: [Na+].[Cl-] · CCO.O(에탄올+물)
각 조각이 하나의 'component'

부등호 (>) — 반응식

- 두 개의 > 로 반응 흐름 표현
- 형식: 반응물 > 시약/촉매 > 생성물
- 예: CCO.CC(=O)O > [H+] > CC(=O)OCC.O
완벽한 양론 균형 없이 관찰 사실만 기록

+심화

dot(.)은 '분리', 부등호(>)는 '변환의 흐름'. reaction SMILES에서는 [C:1] 같은 atom map으로 반응 전후 원자를 추적할 수 있다(반응물>시약>생성물).

SMILES 6대 기본 구문 — 치트 시트

원자 (Atoms)

유기물 대괄호 생략 · H 자동

예: C, O, [Fe+2]

결합 (Bonds)

- , = , # , : (단일/방향족 생략)

예: C=C, C#N

분지 (Branches)

괄호 ()로 중첩 트리 표현

예: CC(C)C

고리 (Rings)

결합 끊고 숫자 라벨링

예: C1CCCC1

단절 (Disconnect)

마침표 . 로 비결합 표현

예: [Na+].[Cl-]

반응 (Reactions)

부등호 > 로 흐름 정의

예: A>B>C

PART B

Canonical SMILES

같은 분자, 여러 문자열 → 단 하나의 표준 문자열

SMILES의 한계 — 하나의 분자, 여러 문자열

- 일반 SMILES는 시작 원자·방향에 따라 같은 분자를 여러 유효 문자열로 표현
- 에탄올 하나가 CCO, OCC, C(C)O, C(O)C, O1.C1C ... 모두 유효
- 인간 입력에는 유연하지만, 데이터베이스 검색엔 치명적 중복
- 딥러닝 입력으로도 불안정 — 같은 분자가 다른 벡터로 인코딩될 위험



함정

'문자열이 다르다 ≠ 분자가 다르다.' 정규화 없이 문자열을 그대로 키(key)로 쓰면 같은 화합물이 중복 등록되거나 검색에서 누락된다.

Canonical SMILES — 1분자 = 1문자열

- 동일한 화학 구조에 오직 하나의 고유(unique) 표준 문자열을 부여
- '1 분자 = 1 고유 문자열' → 신뢰성 있는 저장·검색의 절대 기준
- CCO / OCC / C(C)O / C(O)C / O1.C1C → 표준화 → 모두 CCO
- 실습 도구: **openbabel** 등으로 **canonical** 변환 가능
canonical 형태는 DB dedup·딤러닝 일관 입력에 필수

정규화 알고리즘 — Canonical Labeling

- ① 위상수학(topology) 기반으로 원자의 우선순위를 평가한다
- ② 이웃 원자 수 · 원자 유형 · 수소 수 등으로 초기값(invariant)을 할당
- ③ 이웃에 부여된 값으로 각 원자 값을 갱신(반복)
- ④ 원자들이 고유하게 구분될 때까지(또는 값 변화가 없을 때까지) 반복
→ 이 순위대로 문자열을 생성하면 유일한 canonical SMILES

+심화

핵심: 분자 그래프에서 '누가 먼저 나오는 원자인가'를 구조만으로 결정하는 것. 라벨링(numbering)에 흔들리지 않는 불변의 순서를 찾으면 문자열이 유일해진다.

Morgan 알고리즘 — 이웃값 합으로 순위 매기기

핵심 원리

1. 초기 invariant — 모든 원자에 값 1 부여
2. 이웃값 합산 — 새 invariant = 이웃 원자 값들의 합
3. 서로 다른 값 개수(#values) 확인 — 반복할수록 값 종류가 늘어남
4. 반복 — #values가 더 이상 늘지 않을 때까지 합산 반복
5. 우선순위 확정 — 최종 invariant로 원자 우선순위 부여
6. SMILES 생성 — 우선순위 순서대로 문자열 조립 (동점은 원자 유형 · 결합 차수로 해소)

차별점 · 강점

- ▶ 직관적: 그래프 연결도를 반복 확산으로 요약
- ▶ 1965 Morgan 제안 — canonical labeling의 원형
- ▶ 아스피린 등 실제 분자에 단계별 적용 가능

한계 · 주의

- 초기값이 단순 → 원자 유형 결합순서 구분 못함
- 수치 값이 폭발적으로 증가
- 대칭 원자를 충분히 구분 못 함

Cangen 알고리즘 — 소수(prime) 곱으로 안정화

핵심 원리

1. 초기 invariants — 이웃 수 · 결합차수 합 · 원자번호 · 전하 · H 수를 인코딩
2. → 순위(rank)로 변환 — 초기 invariant를 정렬해 rank 부여
3. rank→소수 매핑 — rank 1,2,3,...를 소수 2,3,5,7,11,13,...에 대응
4. 새 invariant — 이웃들의 소수를 '곱한' 값 (합이 아닌 곱)
5. 재랭킹 — (옛 rank, 새 invariant)로 다시 순위 매김 — stable해질 때까지
6. SMILES 생성 — 최종 우선순위대로 canonical SMILES 출력

차별점 · 강점

- ▶ Weininger 그룹이 Morgan 단점 보완 위해 제안
- ▶ 곱셈 → 초기값 결합 모호성 방지
- ▶ 대칭 원자 문제 해결 · 안정적 우선순위

한계 · 주의

- 절차가 Morgan보다 복잡
- 구현체마다 세부 규칙(tie-break) 차이 가능

PART C

입체화학 · SMARTS · 함정

연결성을 넘어 3D 기하와 부분구조 검색까지

이성질체 표현 — 기하와 속성 부여

종류	표기	예시
동위원소(Isotopes)	질량수를 대괄호 앞	[13CH4]
이중결합 방향	슬래시 / \ 로 cis/trans	F/C=C/F
입체 중심(Stereo)	@ / @@ (테트라헤드랄)	C[C@H](N)O
반응원자 매핑	[atom:n]으로 추적	[OH:1]

+심화

기본 SMILES가 분자의 '연결성'만 보여준다면, Isomeric 규칙은 3차원 기하학(geometry)과 물리화학적 속성(동위원소·전하·입체)까지 부여한다.

입체 이성질 — @, @@ 와 /\

이중결합 방향 (E/Z)

- / 와 \ 문자로 cis/trans 지정
- 예: F/C=C/F (trans-2-butene류 표기)
- 지정 안 하면 방향 미정(CC=CC)

테트라헤드랄 카이랄 (@)

- @ = 반시계, @@ = 시계 방향(visual mnemonic)
- SMILES에 나열된 첫 이웃에서 '바라볼 때' 순서
- 예: L-alanine N[C@@H](C)C(=O)O
미지정: N[CH](C)C(=O)O

+심화

@/@@는 카이랄 중심 주위 이웃의 나열 순서를 3D 회전 방향으로 해석하는 규칙. 같은 원자 연결이라도 @와 @@는 서로 거울상(enantiomer)이 된다.

SMARTS — 부분구조 검색을 위한 확장

- SMARTS = SMILES를 확장한 '부분구조 질의(query) 언어'
- SMILES가 '하나의 분자'라면, SMARTS는 '찾고 싶은 패턴'을 기술
- 와일드카드·원자/결합 조건·논리 연산으로 유연한 매칭
예: 임의 원자 *, 방향족 탄소 c, 고리 원자 [R]
- 용도: 작용기 탐지·필터링·반응 규칙·독성 경보(structural alert)
라이브러리에서 특정 골격을 가진 분자만 골라내기

+심화

SMARTS는 SMILES 문법 위에 '질의 원자/결합' 개념을 얹은 표준(Daylight). 부분구조 검색(substructure search)은 화학 라이브러리 스크리닝의 기본 연산이다.

RDKit 한 줄 예시 (개념 코드)

python — SMILES 파싱 · canonical · 부분구조 · 지문

```
from rdkit import Chem
from rdkit.Chem import AllChem
mol = Chem.MolFromSmiles('CC(=O)Oc1ccccc1C(=O)O') # 아스피린
canon = Chem.MolToSmiles(mol) # canonical SMILES
patt = Chem.MolFromSmarts('c1ccccc1') # 벤젠 고리 질의
hit = mol.HasSubstructMatch(patt) # 부분구조 매칭 True/False
fp = AllChem.GetMorganFingerprintAsBitVect(mol, 2, 2048) # ECFP4
```

▶ MolFromSmiles로 그래프 생성 → MolToSmiles(canonical) / SMARTS 매칭 / Morgan(ECFP) 지문. 개념 예시.

SMILES 혼한 합정 — 원본 예시로

합정	무엇이 문제	바른 이해
다중 표현	<chem>CCO=OCC=C(C)O</chem>	canonical로 통일
대괄호와 H	[C] vs C	[C]=수소0, C=메탄
방향족 소문자	c vs C	c=방향족, C=지방족
피롤 질소	n vs [nH]	피롤은 [nH] 필수
고리 번호 재사용	닫힌 뒤 숫자 재활용	다른 고리에 같은 번호 OK
결합 생략	-, : 생략	= # 는 반드시 명시


합정

가장 잦은 실수: 문자열이 다른 분자라 착각(→canonical 필요), 그리고 방향족/지방족 대소문자 혼동. 입력 후 반드시 재파싱해 구조를 확인.

PART D

분자 기술자 (Molecular Descriptor)

구조를 '계산 가능한 숫자'로 — 표현으로서의 기술자

분자 기술자란 — 구조를 숫자로 옮기는 번역기

- 화학적 정보(2D 그래프 · 3D 구조)를 → 논리 · 수학적 절차로 → 유용한 숫자로 변환
- 즉, 화학 구조를 컴퓨터가 계산할 수 있는 '수치형'으로 옮기는 Translator
- 결과는 예측에 활용 가능한 데이터 벡터 [1.4, 0, 5, 22 ...]
- Todeschini & Consonni의 정의에 기반
'기호적 표현에 인코딩된 화학 정보 → 유용한 숫자'

왜 기술자인가 — '선수 카드' 비유

사람 — 농구 능력

- 키·몸무게·윙스팬(피지컬 스펙)
- 3점 성공률·자유투 성공률(퍼포먼스)
- 올스타 경험 [1/0](이진 데이터)
- → 숫자 벡터만으로 선수 가치 평가

분자 — 활성(Activity)

- 분자량(MW)·친유성(LogP)(물리화학 스펙)
- 수소결합 수용체 수·회전결합 수(구조 능력치)
- 특정 작용기 존재 [1/0]
- → 숫자 벡터만으로 특성·활성 설명

+심화

핵심 전제: '유사한 구조 → 유사한 특성(Structure-Property Relationship)'. 그러므로 구조를 잘 요약한 숫자(기술자)가 비슷하면 특성도 비슷할 것으로 기대한다.

차원에 따른 표현자 분류 — 0D~4D

차원	성격	내용·예
0D (스칼라)	원자 개수·분자량	위상·기하 정보 없는 가장 단순
1D (벡터)	하위구조·파편 개수	특정 작용기·결합 존재 여부
2D (위상학)	그래프 이론 기반	원자 연결성 (예: Wiener Index)
3D (기하학)	3D 공간좌표 기반	RDF·3D-MoRSE (회전/이동 불변)
4D (앙상블)	형태·전하 분포	conformational ensemble·CoMFA

+심화

아래로 갈수록 복잡도·정보량이 증가한다. 0D→4D는 '무엇이 얼마나 있나(조성)' → '어떻게 연결됐나(위상)' → '공간에 어떻게 놓였나(기하)' 순으로 정보를 더한다.

기본 구조와 개수 — Constitutional

- 개념: 분자의 기본 조성·구조 요소를 3D 정보 없이 2D 분자식 기반으로 수치화
- 주요 지수: 분자량(MW)·원자 수(nH, nC 등)·결합 수·특정 작용기 개수
- 포함 블록: Constitutional indices · Functional group counts · Atom-centred fragments
- 특징: 무거운 연산 없이 매우 빠름 → HTS(고속 대량 스크리닝) 1차 필터링에 유용
1D 표현자 = 분자의 '부품 명세서'

용어 · Constitutional descriptor

입체·연결 방식을 배제하고 '무엇이 얼마나 들어있는지'만 세는 구성적 데이터 — atom/bond counts, MW

2D 그래프와 위상 — Topological

- 개념: 분자를 2D 수학 그래프로 추상화 → 가지치기·크기·고리 형태를 수치화
- 거리 행렬(Distance Matrix)·인접 행렬(Adjacency Matrix)로 연결성을 완전 수치화
- 주요 지수: Zagreb index · Randic connectivity index(χ) · Wiener index
- 특징: 입체 이성질체 완전 구분은 어렵지만, 분자 정도·골격 형상 표현에 탁월
QSAR의 가장 기초적 변수로 널리 쓰임

+심화

위상학적 표현자는 3D 좌표 없이도 '누가 누구와 연결됐는가'를 그래프 행렬로 완전히 담는다. 대표가 Wiener index(1947)와 Randic χ 지수.

Wiener · Randic ← 위상 지수의 계산

Wiener Index (W, 1947)

- $W = \frac{1}{2} \cdot \sum D_{ij}$ (거리행렬 원소 합의 절반)
- 모든 (비수소) 원자 쌍 간 최단경로 수의 총합
- 절차: 수소 제거 → 거리행렬 → 상삼각 합산
- 의미: 분자의 크기·조밀도를 정수 하나로 압축
예: 골은 4원자 사슬 → $W=10$

Randic 지수 (χ)

- $\chi = \sum (d_i \times d_j)^{-1/2}$
- 각 결합을 이루는 두 원자의 차수(degree)로 계산
- 단순 거리가 아닌 '가지침(branching)' 정량화
- 의미: 골격이 얼마나 복잡하게 얽혔는가

+심화

복잡한 2D 그림이 '고유한 정수/실수 하나'로 변환된다 — 이것이 위상 지수의 힘. 같은 원자 수라도 가지침이 다르면 $W \cdot \chi$ 값이 달라진다.

2D 행렬·스펙트럼 · 전기위상·전하

2D 행렬·스펙트럼

- 그래프 행렬(거리·인접·Laplacian)의 고유값 분석
- 노드에 원자량·전기음성도·분극율 가중치 부여
- 포함: Burden eigenvalues · Edge adjacency indices
- → 연결성 + 원자 고유 특성 결합

전기위상·전하

- 원자 전자 상태 + 위상 거리 영향을 통합
- 주요: partial charge · Max/Min charge · E-state
- 포함: Atom-type E-state · Charge · ETA indices
- → 수소결합·정전기·반응성 부위 예측

+심화

행렬 기반은 '연결성의 고유값 스펙트럼'으로 더 정밀한 특징을 뽑고, 전기위상·전하 기술자는 '어디가 전자가 풍부/부족한가'를 수치화한다.

3D 기하·표면 — Geometrical

- 개념: 원자 간 공간 거리와 질량·전하 등 특성값의 상관을 함수화
- 주요: RDF(원자쌍 거리 분포) · 3D-MoRSE · WHIM(3D 비대칭성) · GETAWAY
- 형태: 타원도(Ovality) = S_{mol} / S_{sphere} — 구에서 얼마나 벗어났나(최소 1)
- 표면: 반데르발스(vdW) · 분자표면(MS/Connolly) · 용매접근(SAS)
회전·평행이동에 불변 → 단백질-바인딩 모델링에 필수

+심화

3D 기술자는 conformer에 의존하므로 '회전·이동해도 값이 안 변하는(invariant)' 설계가 핵심. 표면 종류(vdW/MS/SAS)는 프로브(용매) 취급 방식이 다르다.

물리화학·약물 유사성 — PhysChem & Drug-likeness

- 개념: 실제 실험값과 1:1로 매칭되는 거시적 물리화학 스코어
- 주요 지수: AlogP/MlogP · TPSA · Lipinski's Rule of 5 스코어 · AMR(물 굴절률)
- 포함 블록: Molecular properties · P_VSA-like · Drug-like indices
- 역할: 라이브러리 스크리닝(HTS)·ADME/Tox 예측의 가이드라인
실무에서 가장 직관적으로 쓰이는 축

용어 · TPSA / LogP

TPSA=위상 극성 표면적, LogP=친유성 — 흡수·투과 등 약물성 평가의 핵심 물리화학 기술자

기술자 카탈로그 — 6대 분류와 Dragon 블록

6대 분류	대표 블록(예)	성격
1. 기본 구조·개수	constitutional · functional group	0D·1D
2. 2D 그래프·위상	topological · connectivity · walk/path	2D
3. 2D 행렬·스펙트럼	Burden · edge adjacency · eigenvalue	2D
4. 자기상관·공간분포	2D/3D autocorr · RDF · 3D-MoRSE · WHIM	2D·3D
5. 전기위상·전하	E-state · charge · Randic profiles	2D
6. 물리화학·약물유사성	molecular properties · drug-like	실측 매칭

+심화

Dragon 같은 도구는 기술자를 20여 개 블록(constitutional 48개, topological 119개, RDF 150개 …)으로 수천 개까지 계산한다 — 표현자는 '많이' 만들 수 있고, 고르는 것이 관건.

PART E

지문 (Fingerprints)

구조적 특징의 존재/부재를 비트로 — 유사성 검색의 언어

지문(Fingerprint)이란 — 비트 스트링

- 특정 구조적 특징(fragment)이 존재(1)/부재(0)를 이진 비트 스트링으로 인코딩
- 예: [벤젠 고리? 1][질소 원자? 0][OH 기? 1] → [1, 0, 1]
- 각 비트 = '이 조각이 분자에 있는가?'라는 예/아니오 질문
- 고차원·희소(sparse) 벡터 → 분자 간 유사도 계산에 최적
(농구 지문 비유: 올스타?1 · 왼손잡이?0 · 해외리그?1)

용어 · Fingerprint

분자 내 구조적 특징의 존재 여부를 비트로 나열한 벡터 — 유사성 검색·클러스터링·ML 입력에 쓰임

지문 3대 계열 — 구조키·해시·원형

계열	원리	특징·용도
구조키(structural key)	사전에 정의된 조각 목록의 존재/부재	해석 쉬움 · 고정 길이
해시(hashed/path)	경로(path)를 해시해 비트에 매핑	사전 불필요 · 범용
원형(circular, ECFP)	각 원자 주변 반경 확장 환경을 인코딩	부분구조 · 유사성에 강함

+심화

원형 지문(ECFP/Morgan)은 canonical의 Morgan 아이디어와 동일하게 '원자 주변 이웃을 반복 확장'해 각 반경의 환경을 비트로 남긴다 — 그래서 부분구조·유사성 검색에서 사실상 표준.

기술자 vs 지문 — 무엇이 다른가

분자 기술자 (Descriptor)

- 실수값(연속): MW · LogP · Wiener 등
- 해석 가능: 각 값의 화학적 의미가 명확
- 차원: 수십~수천 개 (선택이 관건)
- 용도: 물성 예측 · 회귀 모델 입력

지문 (Fingerprint)

- 이진/카운트: 조각 존재 여부(0/1)
- 고차원 · 희소: 1024~2048비트 이상
- 유사성에 강함: Tanimoto 등으로 비교
- 용도: 유사 검색 · 클러스터링 · 분류 입력

+심화

둘 다 '구조 → 벡터' 표현이지만, 기술자는 '해석 가능한 물성 축', 지문은 '부분구조 존재의 지도'. 실무에선 둘을 상황에 맞게(또는 함께) 쓴다.

PART F

좋은 표현자의 조건

같은 '벡터'라도 아무 숫자나 표현이 되는 건 아니다

완벽한 표현자를 위한 3대 설계 프레임

[1] 수학적 무결성

모호함 없는 계산 + 불변성의 원칙

[2] 화학적 타당성

구조 변화를 민감하게 반영·해석할 수 있는 능력

[3] 통계적 유용성

데이터 독립성 + 예측 모델에서의 실용적 가치

+심화

대전제: '유사한 표현자를 가진 분자는 유사한 특성을 가져야 한다.' 이 전제가 성립하려면 표현자가 무결·타당·유용해야 한다.

무결성 · 타당성 · 유용성 — 체크리스트

프레임	핵심 요건	의미
수학적 무결성	알고리즘적 계산의 명확성	같은 입력=같은 값
수학적 무결성	라벨링 · 회전 · 병진 이동에 불변	관점에 안 흔들림
화학적 타당성	구조 변화 → 값의 점진적 변화	민감도
화학적 타당성	이성질체 판별력 · 역해독(decodability)	구별 · 해석 가능
통계적 유용성	최소 1개 특성과 유의한 상관	예측력
통계적 유용성	중복성 배제 · 넓은 적용 범위	독립성 · 확장성

+심화

특히 '실험 측정값에 의존하지 않고 순수 구조 정보에서 도출'되어야 in silico 예측 인자로 쓸 수 있다 — 표현자가 정답을 미리 훑쳐보면 안 된다.

2교시 정리

1

SMILES: 분자 그래프를 6대 규칙으로 한 줄 문자열로 직렬화

원자·결합·분지·고리·방향족·단절/반응

2

Canonical SMILES: 1분자=1문자열

Morgan·Cangen으로 유일한 원자 순서 부여

3

Isomeric·SMARTS: 3D 기하 부여 + 부분구조 검색

@/@@·\·부분구조 질의·RDKit

4

기술자: 구조를 해석 가능한 숫자 벡터로 (0D~4D)

constitutional·topological·geometrical·physchem

5

지문: 구조적 특징의 존재를 비트로 → 유사성 검색

구조키·해시·원형(ECFP)

이 기술자·지문이 곧 QSAR 모델의 '입력'이 된다

2교시에서 만든 것

- SMILES / canonical 문자열
- 기술자 벡터 (MW·LogP·Wiener· χ ...)
- 지문 비트 (ECFP 등)
- = 구조를 담은 숫자 표현

3교시에서 할 것 (예고)

- 표현자 → 예측 모델 → 활성/물성 출력
- QSAR: 구조-활성 정량 관계 학습
- 검증·적용범위(Applicability Domain)
- * 모델링 상세는 3교시 전담

+심화

한 문장 브리지 — 오늘 만든 기술자·지문 벡터가 그대로 3교시 QSAR 모델의 입력 feature가 된다. '표현이 있어야 모델이 있다.' 모델 학습·검증은 3교시에서.

3교시 예고

QSAR 모델링 — 표현에서 예측으로

기술자·지문 → 구조-활성 관계 학습 → 검증(교차검증·외부셋) → 적용범위 판단

구조를 문자열·벡터로 표현했으니 — 이제 그 벡터로 활성을 예측한다.

주요 출처 (2교시)

- SMILES: 3_SMILES표현.pdf (전 42p) — 문법(원자·결합·분지·고리·방향족·단절/반응), canonical, isomeric.
- SMILES 표준: Weininger, J Chem Inf Comput Sci 1988; OpenSMILES 명세(opensmiles.org); Daylight Theory Manual.
- Canonical: Morgan, J Chem Doc 1965; Weininger et al. (CANGEN) 1989; 3_SMILES표현.pdf p.21~42.
- SMARTS: Daylight SMARTS 명세 (SMILES 확장) — 부분구조 검색.
- 기술자: 4_Molecular_Descriptor.pdf (표현으로서의 기술자·지문 부분) — 정의·차원분류·6대 블록.
- 기술자 정본: Todeschini & Consonni, Handbook of Molecular Descriptors; Dragon software (20 blocks).
- 위상 지수: Wiener 1947 (W); Randic 1975 (χ). 지문: Rogers & Hahn 2010 (ECFP).
- 실습: RDKit(Chem/AllChem, 개념 예시); openbabel(canonical); MolDraw(SMILES→구조).
- * QSAR 모델링·검증·적용범위는 3교시 전담 — 본 교시는 '표현'까지만 다룸.

감사합니다

2교시 · SMILES와 분자 기술자 — 구조를 문자열·벡터로

이전: 1교시 분자 구조 표현 기초(그래프·InChI·파일포맷) → 다음: 3교시 QSAR 모델링

핵심 프레임: 문자열(SMILES) + 벡터(기술자·지문) = 3교시 모델의 입력