

7/23 · 화학정보학 실습 · 3교시


QSAR

기술자로 활성·물성을 예측하는 모델

정량적 구조-활성 관계 (Quantitative Structure-Activity Relationship)

재직자·전공자 · 한국어 · 1교시 구조표현 → 2교시 기술자 → 3교시 QSAR

2교시에서 만든 '숫자'를, 이제 '예측'에 쓴다



- 2교시 결과물 = 각 분자의 기술자·지문 벡터 (분자량·LogP·TPSA·Morgan FP ...)
- 그 벡터가 바로 QSAR 모델의 입력 X — 오늘은 '입력을 어떻게 만드나'가 아니라 '입력으로 무엇을 하나'
- $y(\text{레이블})$ = 실험으로 측정된 활성/물성 (IC50, 용해도, 독성 ...)
- 3교시 = X와 y 사이의 관계 f를 데이터로 학습하고, 검증하고, 새 분자에 적용

+심화

핵심 한 줄: 2교시의 기술자·지문이 QSAR의 입력 X다. 기술자 종류 상세는 2교시에서 다뤘으므로 오늘은 참조만 하고, 그 X로 모델을 세우고 신뢰할 수 있게 만드는 과정에 집중한다.

3교시가 끝나면

- **QSAR의 정의·기본 가정·역사(Hansch·Free-Wilson)를 설명한다**
구조-활성의 정량적 관계
- **QSAR 워크플로 7단계를 순서대로 말하고 각 단계의 함정을 안다**
데이터→기술자→선택→학습→검증→해석→적용
- **대표 모델(선형/PLS/RF/GBM/딥러닝)의 개념과 선택 기준을 안다**
- **검증 체계(분할·교차검증·y-scrambling·외부검증·지표)를 설명한다**
가장 중요한 부분
- **적용범위(AD)·과적합·상관 ≠ 인과 등 함정과 OECD 5원칙을 안다**
규제·실무 감각

7/23 지도 — 지금 어디에 있나

1교시 · 화학정보학 & 분자 구조 표현

화학정보학 개요 · 분자를 컴퓨터로 표현하는 법 (SMILES·그래프)

2교시 · SMILES & 분자 기술자·지문

SMILES 문법 · Descriptor 종류 · Fingerprint — 분자를 숫자 벡터 X 로

3교시 · QSAR

◀ 현재

그 X 로 활성·물성을 예측: 개념·워크플로·모델·검증·적용범위·규제

+심화

흐름: '분자를 어떻게 표현하나(1교시)' → '숫자 벡터로 만든다(2교시)' → '그 벡터로 예측 모델을 만든다(3교시)'. 오늘은 그 마지막 연결 고리.

3교시에서 볼 것

A. 개념·역사

QSAR 정의·기본 가정·Hansch/Free-Wilson·QSPR

B. 워크플로

데이터→기술자→특징선택→학습→검증→해석→적용

C. 모델

선형회귀·PLS·랜덤포레스트·부스팅·딥러닝 개요

D. 검증

분할·교차검증·y-randomization·외부검증·지표

E. 적용범위·함정

AD·과적합·데이터 편향·상관≠인과·activity cliff

F. 규제·실무

OECD QSAR 5원칙·read-across·도구 생태계

G. 종합·클로징

1→2→3교시 종합·실무 권고·참고문헌

PART A

QSAR — 개념과 역사

구조가 활성을 결정한다는 생각을 '식'으로

QSAR란 무엇인가

$$\text{생리적 활성 } (\Phi) = f(\text{분자 구조} \cdot \text{물리화학적 특성})$$

- QSAR = 정량적 구조-활성 관계 — 구조에서 뽑은 기술자(X)와 활성(y)의 수학적 관계 f를 세움
- 정성적 SAR('이 그룹이 있으면 활성 ↑')을 넘어 '얼마나'를 수치로 예측
- f는 회귀(연속값: IC50·용해도)일 수도, 분류(활성/비활성·독성 여부)일 수도 있음
- 목적: 합성·실험 전에 후보를 우선순위화 → 시간·비용 절감(가상 스크리닝)

기본 가정 — 유사성의 전이

"기능(특성)은 형태(구조)를 따른다"

- 유사한 구조를 가진 분자는 유사한 물성·활성을 갖는다 (Structure-Property Relationships)
- → 따름: 유사한 기술자(X)를 가진 분자는 유사한 특성(y)을 가져야 한다
- 이 가정이 성립해야 '구조 → 숫자 → 예측' 이 원리적으로 가능
- 가정이 깨지는 지점(activity cliff)이 곧 QSAR의 한계 — PART E에서 다룸

+심화

주의: 이것은 '가정'이지 법칙이 아니다. 구조가 조금 바뀌었는데 활성이 급변하는 예외(activity cliff)가 존재하며, QSAR가 어려운 근본 이유가 된다.

QSAR의 계보 — 150년의 흐름

시기	인물·사건	기여
1868	Crum-Brown & Fraser	활성 $\phi = f(\text{구조 } C)$ — 구조-활성 관계를 처음 '함수'로 제안
1930s-40s	Hammett; Wiener(1947)	치환기 전자효과(σ) 정량 · Wiener 위상 지수 등장
1964	Hansch & Fujita / Free & Wilson	현대 QSAR의 탄생 — 두 갈래 접근법(다음 장)
1980s-90s	3D-QSAR (CoMFA 등)	3D 장(field) 기반 표현 · 상용 표현자 소프트웨어
2000s-	기계학습·딥러닝 QSAR	RF·부스팅·신경망 · 대규모 데이터 · GNN

+심화 핵심: QSAR는 유행이 아니라 150년 축적된 개념이다. Crum-Brown&Fraser의 '활성은 구조의 함수'라는 아이디어가 Hansch에서 회귀식으로, 지금은 기계학습으로 이어진다.

Hansch 분석 vs Free-Wilson 분석 (1964)

Hansch 분석 (선형자유에너지)

- 활성 = $f(\text{물리화학 파라미터})$
- 소수성 $\pi(\log P)$ · 전자 σ · 입체 E_s
- $\log(1/C) = a \cdot \pi + b \cdot \sigma + c \cdot E_s + \dots$
- 연속적 물성 축으로 해석 · 외삽 용이

Free-Wilson 분석 (가법 모델)

- 활성 = 치환기 기여도의 합
- 각 위치 · 치환기에 지표변수(0/1)
- 공통 골격 시리즈에 적합
- 물성 파라미터 불필요 · 해석 직관적

+심화

두 접근은 상보적: Hansch는 '어떤 물성이 활성을 이끄냐'(연속 · 기전 지향), Free-Wilson은 '어떤 치환기가 얼마나 기여하냐'(이산 · 시리즈 지향). 현대 ML QSAR은 둘의 정신을 데이터로 일반화한 것.

QSAR vs QSPR — 무엇을 예측하나

QSAR (Activity)

- y = 생물학적 활성
- IC50 / EC50 / Ki / 독성
- 표적 결합 · 약효 · 부작용
- 보통 log 변환(pIC50)해 사용

QSPR (Property)

- y = 물리화학적 물성
- 용해도 · logP · 녹는점 · 투과도
- ADME · 제형 설계
- 측정 오차가 상대적으로 작음

+심화

방법론은 동일(구조→기술자→모델). 차이는 y 가 무엇이나일 뿐. 활성이면 QSAR, 물성이면 QSPR. 오늘 배우는 워크플로 · 검증은 둘 다에 그대로 적용된다.

QSAR의 입력 X = 2교시의 기술자·지문

QSAR 데이터 행렬 (개념도 · 값은 예시)

	MW	LogP	TPSA	HBD	...	FP_2048	y = pIC50
mol_1	180	1.2	63	2	...	[1,0,1,...]	6.4
mol_2	312	3.4	41	1	...	[0,1,0,...]	7.9
mol_3	245	2.1	78	3	...	[1,1,0,...]	5.2
...						...	...

X = 기술자 행렬 (2교시 산출물), y = 측정 활성 (실험값)

▶ 한 행 = 한 분자, 한 열 = 한 기술자. 기술자 계산법은 2교시 참조(재설명 생략).

+심화

기술자 종류·계산(2교시)은 여기서 다시 설명하지 않는다. 오늘의 관심은 이 X와 y가 주어졌을 때 f를 어떻게 세우고, 그것이 새 분자에서도 맞는지 어떻게 증명하나이다.

PART B

QSAR 워크플로

데이터에서 예측까지 — 7단계와 각 단계의 함정

QSAR 워크플로 7단계

1. 데이터 준비

활성 데이터 수집 · 큐레이션 · 단위 통일(pIC50)

2. 기술자 계산

2교시 기술자 · 지문 산출 + 스케일링

3. 특징 선택

불필요 · 중복 변수 제거, 차원 축소

4. 모델 학습

선형/PLS/RF/부스팅/딥러닝 (PART C)

5. 검증

분할 · 교차검증 · y-scrambling · 외부검증 (PART D)

6. 해석

변수 중요도 · 기전 해석(mechanistic)

7. 적용

적용범위 확인 후 새 분자 예측 · 우선순위화

데이터 준비 & 큐레이션 — 성패의 80%

핵심 원리

1. 데이터 수집 — 동일 assay·조건의 활성값 확보(ChEMBL 등 공개 DB)
2. 구조 표준화 — 염·용매 제거, 호변이성·프로토네이션 통일, 중복 제거
3. 활성 단위 통일 — IC50→pIC50 등 log 변환, 단위·부호 정합
4. 이상치·모호값 처리 — >10 μ M 같은 검열값·질 낮은 데이터 플래그
5. 데이터 균형·범위 점검 — 활성 분포·동적 범위(dynamic range) 확인

차별점 · 강점

- ▶ "garbage in, garbage out" — 여기서 결정
- ▶ 재현 가능한 전처리 파이프라인
- ▶ 동일 종말점(endpoint) 정의가 핵심

한계 · 주의

- 서로 다른 assay 혼합 = 잡음
- 중복·누수(leakage)가 성능 착시

활성값을 왜 log로 — pIC50

- IC50는 nM~μM에 걸쳐 수 자릿수로 퍼짐 → 그대로 쓰면 소수 강활성치가 회귀를 지배
- $pIC50 = -\log_{10}(IC50[M])$ — 로그 척도로 변환해 분포를 대칭·선형화
- 모델은 보통 로그 활성에서 선형·정규 가정에 더 잘 맞음
- 종말점(endpoint) 정의를 명확히: 무엇을·어떤 조건에서 측정한 값인가
OECD 원칙 1

+심화

OECD 원칙 1('명확히 정의된 종말점')과 직결. 활성의 정의·단위·assay가 흔들리면 아무리 좋은 모델도 무의미하다. 전처리는 모델링보다 먼저이고 더 중요하다.

기술자 계산과 특징 선택

2단계 · 기술자 계산 (2교시 참조)

- 2교시의 기술자·지문을 X로 산출
- 0D~4D·물리화학·지문 (재설명 생략)
- 스케일링: 표준화(z-score)·정규화
- 결측·상수 열 제거

3단계 · 특징 선택

- 수천 개 기술자 > 분자 수 혼함
- 차원의 저주 → 과적합 위험
- 불필요·중복 변수 제거로 일반화 ↑
- 해석성·계산비용도 개선



함정

기술자 계산 상세는 2교시 영역. 여기서 중요한 건 '스케일링을 학습 데이터 통계로만' 하고 test에 그대로 적용해야 누수가 없다는 점.

특징 선택 3가지 방식 & 차원의 저주

방식	원리	예
Filter	모델 무관·통계 지표로 선별	분산·상관계수·상호정보량, 중복 제거
Wrapper	모델 성능으로 부분집합 탐색	전진/후진 선택·재귀적 제거(RFE)
Embedded	학습 중 자동 선택	LASSO(L1)·트리 변수중요도
차원 축소	변수 결합해 압축	PCA·PLS 잠재변수(원변수 해석성 ↓)

+심화

차원의 저주: 변수 수가 표본 수에 비해 크면 우연히 잘 맞는 조합(chance correlation)이 생김. 특징 선택·정규화·검증이 이를 억제한다. 선택은 반드시 학습 fold 안에서만 수행 (누수 방지).

해석과 적용 — 모델을 실무로

6단계 · 해석 (mechanistic)

- 변수 중요도로 '무엇이 활성을 이끄냐'
- SHAP·부분의존도 등으로 기여 분해
- 화학적으로 말이 되는지 점검
- OECD 원칙 5(기계론적 해석)

7단계 · 적용

- 적용범위(AD) 안의 분자만 신뢰
- 가상 라이브러리 스크리닝·랭킹
- 합성·실험 후보 우선순위화
- 예측→실측 피드백으로 재학습

+심화

QSAR는 '블랙박스 점수기'가 아니라 '가설 생성기'로 쓸 때 가장 강력하다. 왜 그렇게 예측했는지 설명(해석)이 되고, 어디까지 믿을 수 있는지(AD)가 붙어야 실무에서 채택된다.

PART C

QSAR 모델

선형에서 딥러닝까지 — 해석성과 성능의 저울

모델 지형 — 해석성 ↔ 유연성의 저울

모델	성격	해석성 / 데이터 요구
다중선형회귀(MLR)	선형 · 투명	높음 / 적음
PLS	공선성 강한 선형	중간 / 적음
랜덤포레스트(RF)	비선형 · 앙상블	중간 / 중간
그래디언트 부스팅	비선형 · 고성능	중간-낮음 / 중간
딥러닝(MLP · GNN)	비선형 · 표현학습	낮음 / 많음

+심화

만능 모델은 없다(no free lunch). 위로 갈수록 해석 · 소량데이터에 강하고, 아래로 갈수록 복잡한 비선형에 강하지만 데이터 · 검증 부담이 커진다. 데이터 규모와 목적이 모델을 정한다.

다중선형회귀 (MLR) — Hansch의 후예

핵심 원리

1. **형태** — $y = b_0 + b_1 \cdot x_1 + b_2 \cdot x_2 + \dots$ (기술자의 가중합)
2. **적합** — 최소제곱으로 계수 b 추정
3. **장점** — 계수 = 각 기술자의 기여 → 해석 직관적
4. **전제** — 변수 간 낮은 공선성 · 표본 > 변수 수
5. **확장** — 릿지/LASSO로 정규화(과적합 · 공선성 완화)

차별점 · 강점

- ▶ 가장 투명 · 규제 친화적
- ▶ Hansch 전통과 직결
- ▶ 적은 데이터에서 견고

한계 · 주의

- 비선형 관계 포착 못함
- 공선성에 계수 불안정
- 변수 ↑ 시 과적합

부분최소제곱 (PLS) — 공선성의 해결사

핵심 원리

1. **문제** — 기술자들이 서로 강하게 상관(공선성)·변수>표본
2. **아이디어** — X 를 y 와 공분산이 큰 소수 '잠재변수'로 투영
3. **적합** — 잠재변수 공간에서 회귀 → 안정적 계수
4. **성분 수** — 교차검증으로 잠재변수 개수 결정
5. **용도** — 3D-QSAR(CoMFA)·분광 데이터의 표준

차별점 · 강점

- ▶ 고차원·공선성에 강건
- ▶ 화학계량학(chemometrics) 표준
- ▶ 적은 표본에서도 동작

한계 · 주의

- 여전히 본질은 선형
- 잠재변수는 원변수보다 해석 어려움

랜덤포레스트 (RF) — 나무들의 투표

핵심 원리

1. **기반** — 다수의 결정트리를 독립적으로 학습(bagging)
2. **무작위성** — 표본·변수 무작위 추출로 트리 다양화
3. **예측** — 회귀=평균, 분류=다수결로 앙상블
4. **변수중요도** — 불순도 감소·순열 중요도 제공
5. **OOB** — out-of-bag 표본으로 내부 성능 추정

차별점 · 강점

- ▶ 비선형·상호작용 자동 포착
- ▶ 스케일·이상치에 견고
- ▶ 튜닝이 비교적 쉬움

한계 · 주의

- 외삽(범위 밖)에 약함
- 개별 예측 해석은 제한적

그래디언트 부스팅 (GBM/XGBoost)

핵심 원리

1. 원리 — 약한 트리를 순차로 추가, 이전 오차를 보정
2. 경사하강 — 잔차(그래디언트) 방향으로 단계적 학습
3. 구현 — XGBoost·LightGBM — 정규화·속도 강화
4. 규제 — 학습률·트리깊이·서브샘플로 과적합 제어
5. 현황 — 표 형태 기술자 QSAR에서 강력한 기본기

차별점 · 강점

- ▶ 정형 데이터에서 최상위 성능 혼합
- ▶ 결측·혼합 변수 처리 유연
- ▶ 변수중요도·SHAP 해석 지원

한계 · 주의

- 튜닝·과적합 관리 필요
- 부적절 검증 시 성능 착시 큼

딥러닝 QSAR — 개요 (개념 위주)

MLP (기술자 입력)

- 2교시 기술자·지문을 입력 벡터로
- 다층 신경망으로 비선형 f 학습
- 대규모·다중과제(multi-task)에 강점
- 소량 데이터엔 과적합 위험

그래프 신경망 (GNN)

- 분자를 원자=노드·결합=엣지 그래프로
- 메시지 전달로 표현을 '학습'
- 사람이 만든 기술자 없이 end-to-end
- 데이터·계산 요구 큼·해석 난도 ↑

+심화

연결: 2교시가 '사람이 설계한 지문', GNN은 '데이터가 학습한 표현'. 다만 딥러닝이 항상 이기지는 않는다 — 중소 규모 QSAR에선 부스팅/RF가 대등하거나 우세한 경우가 많다(데이터 규모가 관건).

모델 선택 가이드 — 무엇부터?

- 먼저 단순 모델(MLR/PLS)로 baseline — 해석·비교의 기준선을 만든다
- 데이터가 수백~수천이면 RF/부스팅이 견고한 기본 선택
- 데이터가 매우 크고 표현학습이 필요하면 딥러닝/GNN 검토
- 규제·의사결정 설명이 중요하면 해석 가능한 모델을 우선
- 성능은 '모델'보다 '데이터 질·검증 설계'가 좌우한다
모델 경쟁 이전의 문제

+심화

실무 순서: 좋은 데이터 → 정직한 검증 설계 → 단순 모델 baseline → 필요할 때만 복잡한 모델. 복잡한 모델을 부실한 검증에 얹으면 성능은 '보이기만' 한다.

PART D

검증 (Validation)

'맞아 보인다'와 '정말 맞는다'는 다르다 — 3교시의 심장


왜 검증이 QSAR의 심장인가

- 학습 데이터에서의 좋은 적합(R^2)은 예측력을 보장하지 않는다
- 변수가 많으면 우연히 잘 맞는 모델(chance correlation)이 생긴다
- 과적합된 모델은 '본 적 있는 분자'만 잘 맞히고 새 분자엔 실패
- 따라서 '본 적 없는 데이터'에서의 예측력을 반드시 측정해야 한다
→ 내부·외부 검증

+심화

핵심 구분: R^2 (적합도, fitting)와 Q^2 /외부 예측력(prediction)은 다르다. 높은 R^2 만 보고 좋은 모델이라 말하는 것이 QSAR 최대의 함정. Golbraikh & Tropsha가 'q2를 조심하라'고 경고한 이유.

데이터 분할 — train / validation / test



- Test는 모델 개발 내내 '봉인' — 딱 한 번, 최종 보고용으로만 사용
- 무작위 분할은 유사 분자가 train·test에 함께 들어가 성능을 과대평가할 수 있음
- 스캐폴드/시간 분할(scaffold·time split): 골격·시점으로 나눠 더 현실적 평가
- 분할 전에 전처리·특징선택을 하면 누수(leakage) — 반드시 분할 후 학습셋 기준

+심화

현실 예측은 대개 '학습에 없던 새로운 골격'을 만난다. 무작위 분할의 낙관적 수치보다 스캐폴드/시간 분할이 실제 배치 성능에 가깝다.

교차검증 (Cross-Validation)

핵심 원리

1. **k-fold** — 데이터를 k등분, 각 fold를 번갈아 검증셋으로
2. **반복** — k번 학습·평가 후 평균 → 안정적 성능 추정
3. **LOO** — leave-one-out: 표본이 적을 때(n만큼 반복)
4. **Q² (Q2)** — CV 예측 기반 결정계수 — 내부 예측력 지표
5. **Nested CV** — 특징선택·튜닝을 내부 fold에 포함(누수 차단)

차별점 · 강점

- ▶ 소량 데이터를 효율적으로 활용
- ▶ 단일 분할의 운(luck) 제거
- ▶ 하이퍼파라미터 선택에 필수

한계 · 주의

- 누수 시 Q²도 부풀 수 있음
- CV 성능 ≠ 외부 예측력(보완 필요)

y-무작위화 — 우연을 걸러내는 시험

- y(활성)를 무작위로 섞어 '가짜 데이터셋'을 여러 번 만든다
- 같은 절차로 모델을 학습 → 성능($R^2 \cdot Q^2$)을 기록
- 무작위 모델들이 낮은 성능이어야 정상 — 원래 모델이 뚜렷이 높아야 함
- 무작위인데도 성능이 높다면? 그 모델은 우연 상관(chance correlation)
경고 신호

+심화

y-scrambling(무작위화)은 '내 모델이 진짜 신호를 배웠나, 우연히 맞았나'를 가르는 표준 시험. 특히 변수가 많은 QSAR에서 반드시 수행하도록 권고된다.

외부 검증 — 진짜 시험대

- 내부 검증(CV)만으로는 부족 — 개발에 전혀 쓰지 않은 외부셋이 필요
- 외부 예측 결정계수(Q^2_{ext})로 '보지 못한 분자'에서의 예측력 측정
- 이상적으로는 서로 다른 출처·시점의 데이터로 평가(현실 반영)
- **Golbraikh-Tropsha 수용 기준** 등으로 모델 채택 여부 판단
다음 장 지표

+심화

강한 QSAR의 조건: 좋은 적합(R^2) + 좋은 내부 예측(Q^2) + 좋은 외부 예측(Q^2_{ext}) + 적용범위(AD) 명시. 네 가지가 함께 갖춰져야 신뢰할 수 있다.

회귀 성능 지표 — 개념

지표	의미	주의
R^2	학습 적합도(설명된 분산)	적합 ≠ 예측, 변수 ↑ 시 자동 상승
Q^2 (CV)	교차검증 예측 결정계수	내부 예측력, 누수 시 과대
Q^2_{ext}	외부셋 예측 결정계수	실제 예측력에 가장 근접
RMSE	예측 오차의 크기(원단위)	이상치에 민감
MAE	평균 절대 오차	해석 직관적 · 이상치에 견고



함정

R^2 하나만 보고 판단 금지. R^2 는 높지만 Q^2 는 낮은 모델 = 과적합. 반드시 R^2 와 Q^2 /외부지표를 함께 본다.

분류 성능 지표 — 개념

지표	의미	적합 상황
정확도(Accuracy)	전체 중 맞춘 비율	클래스 균형일 때만
민감도/특이도	실제 양성/음성을 맞추는 비율	놓침·오경보 구분
ROC-AUC	임계값 전체 순위 성능	불균형에도 비교적 견고
PR-AUC	정밀도-재현율 곡선 면적	희귀 양성(불균형)에 유용
MCC	상관 기반 균형 지표	불균형 데이터 권장

+심화

활성/비활성처럼 클래스가 불균형(활성 소수)인 QSAR 분류에서는 정확도가 오해를 부른다. ROC-AUC·PR-AUC·MCC로 균형 있게 평가한다.

PART E

적용범위 & 함정

모델이 '어디까지' 믿을 만한가 — 그리고 흔한 실수

적용범위 (Applicability Domain, AD)

- 모델은 학습 데이터가 덮은 화학 공간 안에서만 신뢰할 수 있다
- 그 밖의 분자(외삽)에 대한 예측은 근거가 약함 → '모름'을 인정해야
- 모든 예측에 AD 판정을 붙여 in-domain / out-of-domain을 표시
- AD는 OECD 5원칙 중 3번 — 규제 제출의 필수 요소
'정의된 적용 범위'

+심화

핵심: 좋은 QSAR는 '항상 답을 내는 모델'이 아니라 '언제 자기가 틀릴지 아는 모델'이다. AD는 확장성(넓은 화학 공간에서의 유효 범위)의 실무적 표현이기도 하다.

적용범위를 정하는 방법

방법	원리	도구·비고
기술자 범위	각 기술자의 min-max 범위 내인지	단순·직관적
거리 기반	학습셋 중심/최근접까지의 거리	유클리드·마할라노비스
레버리지	기술자 공간에서의 영향력(hat)	Williams plot
밀도·신뢰도	학습 데이터 밀집도·모델 분산	양상블 분산·conformal

+심화

Williams plot: 표준화 잔차 vs 레버리지 산점도로 이상치(y-outlier)와 외삽점(구조적 outlier)을 한눈에 구분. AD 방법은 여러 개를 함께 쓰는 것이 안전하다.

과적합과 데이터 편향

과적합 (Overfitting)

- 잡음까지 외워 학습셋만 잘 맞음
- 변수 ↑ · 데이터 ↓ · 검증 부실이 원인
- 증상: R^2 높고 Q^2 · 외부 낮음
- 대응: 정규화 · 특징선택 · 정직한 검증

데이터 편향 (Bias)

- 특정 시리즈 · 표적에 치우친 데이터
- 좁은 화학 공간 → 좁은 AD
- 활성 분포 불균형 · assay 잡음
- 대응: 다양성 확보 · 총화 · 외부셋



함정

'화려한 모델'보다 '정직한 데이터 · 검증'이 먼저. 과적합과 편향은 모델을 바꿔서가 아니라 데이터 · 검증 설계로 잡는다.

상관 ≠ 인과, 그리고 activity cliff

- 상관 ≠ 인과: 기술자와 활성이 함께 움직여도 인과의 증거는 아님
- 우연 상관(chance correlation): 변수가 많으면 의미 없는 상관이 생김 → y-scrambling으로 검출
- 데이터 누수(leakage): test 정보가 학습에 새면 성능이 실제보다 좋아 보임
- activity cliff: 구조가 거의 같은데 활성이 급변 → 유사성 가정이 깨지는 지점
QSAR의 근본 한계

+심화

activity cliff는 '유사한 구조=유사한 활성'이라는 QSAR 대전제(PART A)가 국소적으로 붕괴하는 곳. 이런 영역에서는 매끄러운 회귀가 원리적으로 실패하며, 별도 탐지·경고가 필요하다.

QSAR 함정 방지 체크리스트

데이터

동일 assay · 단위 통일 · 중복/누수 제거 · 동적 범위 확인

분할

분할 후 전처리 · 스캐폴드/시간 분할 · test 봉인

검증

CV + y-scrambling + 외부검증 (R^2 와 Q^2 함께)

적용범위

AD 판정 부착 · 외삽 예측은 '모름'으로

해석

변수 중요도가 화학적으로 말이 되는지 점검

보고

성능수치 · 조건 · 한계를 투명하게 기록(재현성)

PART F

규제 & 실무

OECD 5원칙 · read-across — QSAR가 근거로 인정받는 법

OECD QSAR 검증 5원칙 (2007)

원칙	내용
1	명확히 정의된 종말점(defined endpoint) — 무엇을 예측하나
2	모호하지 않은 알고리즘(unambiguous algorithm) — 재현 가능
3	정의된 적용 범위(defined applicability domain) — 어디까지 유효
4	적합도 · 강건성 · 예측력의 적절한 척도(goodness-of-fit · robustness · predictivity)
5	가능하다면 기계론적 해석(mechanistic interpretation)

+심화

이 5원칙은 규제기관이 QSAR 예측을 근거로 받아들이기 위한 국제 표준이다. 오늘 배운 워크플로 · 검증 · AD가 모두 이 원칙과 1:1로 대응한다(다음 장).

OECD 5원칙 ↔ 표현자 3대 설계 프레임

PDF 3대 프레임	의미	대응 OECD 원칙
수학적 무결성	모호X·불변성	② 모호하지 않은 알고리즘
화학적 타당성	해석·역해독	⑤ 기계론적 해석
통계적 유용성(상관)	예측 상관·독립성	④ 예측력·강건성 척도
통계적 유용성(확장성)	넓은 유효 범위	③ 정의된 적용 범위(AD)
(데이터 준비 단계)	종말점 정의	① 명확히 정의된 종말점

+심화

연결: 2교시 PDF의 '완벽한 표현자 3대 프레임(수학적 무결성·화학적 타당성·통계적 유용성)'은 규제의 OECD 5원칙과 사실상 같은 이야기다. 좋은 기술자 요건이 곧 좋은 QSAR 요건.

read-across — 모델 없이 '이웃'으로 채우기

- 유사한 분자(구조적 이웃)의 알려진 특성으로 미지 분자의 특성을 추정
- 정식 QSAR 회귀식 대신 유사성·그룹핑에 근거 (범주 접근, category approach)
- 데이터가 적은 종말점(특히 독성)에서 규제적으로 널리 쓰임
- QSAR와 같은 대전제(유사 구조=유사 특성)에 기댐 → AD·유사성 정의가 관건

+심화

read-across는 '한 분자씩 이웃을 보고 메우는' 접근, QSAR는 '전체에서 함수를 학습하는' 접근. 둘 다 유사성 원리에 기반하며, REACH 같은 규제에서 동물시험 대체 근거로 활용된다.

실무 도구·데이터 생태계 (개념)

데이터·기술자

- 활성 DB: ChEMBL·PubChem
- 기술자·지문: RDKit·Mordred(2교시)
- 표준화: 구조 정규화 파이프라인
- 공개 벤치마크 데이터셋

모델·검증·규제

- 모델링: scikit-learn·XGBoost 등
- 검증: CV·y-scramble·외부셋·AD
- 규제 도구: OECD QSAR Toolbox·VEGA
- 보고: QMRF 양식(모델 문서화)

+심화

실무는 '데이터(공개 DB) → 기술자(2교시 도구) → 모델·검증(ML 라이브러리) → 규제 문서화(QMRF·Toolbox)'로 이어진다. 도구는 바뀌어도 원칙(워크플로·검증·AD)은 그대로다.

PART G

종합 & 클로징

1교시 → 2교시 → 3교시, 하나의 흐름으로

7/23 전체 종합 — 구조표현 → 기술자 → QSAR

1교시 · 구조 표현

분자를 컴퓨터가 읽을 수 있게: SMILES · 그래프 등 표현 체계

2교시 · 기술자 · 지문

표현에서 숫자를 뽑는다: 0D~4D 기술자 · 물리화학 · Fingerprint → 벡터 X

3교시 · QSAR

그 X로 활성 · 물성을 예측: 워크플로 · 모델 · 검증 · AD · 규제

+심화

하나의 문장: '분자를 표현하고(1교시), 숫자로 만들고(2교시), 그 숫자로 예측한다(3교시)'. 세 교시는 신약 초기 발굴의 in-silico 파이프라인 그 자체다.

3교시 정리 — 기억할 다섯

1

QSAR = 기술자(X)와 활성(y)의 정량 관계 f — 대전제는 '유사 구조=유사 활성'

2

워크플로 7단계: 데이터→기술자→선택→학습→검증→해석→적용

데이터 질이 성패의 80%

3

모델은 해석성↔성능의 저울 — 데이터 규모·목적이 선택을 정한다

4

검증이 핵심: R^2 (적합) $\neq$ Q^2 (예측). CV+y-scramble+외부검증을 함께

'맞아 보임' 경계

5

적용범위(AD)·함정(과적합·상관 $\neq$ 인과·cliff)·OECD 5원칙으로 신뢰 확보

현장에서 지킬 것 — Do & Don't

DO

- 데이터 큐레이션에 가장 많은 시간을
- 단순 baseline부터, 정직한 검증부터
- R^2 와 Q^2 ·외부지표를 함께 보고
- 모든 예측에 적용범위(AD)를 부착
- 모델·조건·한계를 재현 가능하게 문서화

DON'T

- R^2 하나로 '좋은 모델' 선언 금지
- 분할 전 전처리·특징선택(누수) 금지
- test셋을 튜닝에 반복 사용 금지
- AD 밖 분자에 확신 있는 예측 금지
- 성능수치·데이터 임의 미화 금지

+심화

QSAR의 신뢰는 화려한 모델이 아니라 정직한 데이터·검증·범위 표시에서 나온다. 이 원칙은 도구·모델이 바뀌어도 변하지 않는다.

주요 출처 (3교시)

- 원자료: 4_Molecular_Descriptor.pdf (CanIT) — QSAR 워크플로(p.3) · 활성=f(구조)(p.7) · 유사성 전이(p.2,21) · 표현자 3대 프레임/진단 매트릭스(p.22-29).
- 고전: Crum-Brown & Fraser 1868; Hansch & Fujita, JACS 1964; Free & Wilson, J Med Chem 1964; Wiener 1947; Randic, JACS 1975.
- 표현자: Todeschini & Consonni, Handbook of Molecular Descriptors (Wiley); Lipinski et al., Adv Drug Deliv Rev 1997 (Rule of 5).
- 검증: Golbraikh & Tropsha, J Mol Graph Model 2002 (Beware of q2!); Gramatica, QSAR Comb Sci 2007; Rücker et al., J Chem Inf Model 2007 (y-randomization).
- 베스트프랙티스: Tropsha, Mol Inform 2010; Cherkasov et al., J Med Chem 2014 (QSAR Modeling review).
- 모델: Breiman 2001 (Random Forests); Chen & Guestrin, KDD 2016 (XGBoost); Wold et al. 2001 (PLS-regression).
- 적용범위 · 함정: Netzeva et al., ATLA 2005 (AD); Sheridan, JCI 2013 (time-split); Maggiora, JCI 2006 (activity cliffs).
- 규제: OECD 2007, Guidance on the Validation of (Q)SAR Models (5원칙); OECD QSAR Toolbox.
- * 방법 · 개념 · 워크플로는 표준 QSAR 교육 내용으로 보완했으며, 성능수치 · 벤치마크는 제시하지 않음(무-날조 원칙).

감사합니다

3교시 · QSAR — 기술자로 활성·물성을 예측하는 모델

핵심 프레임: 2교시 기술자(X) $\rightarrow$ QSAR 모델 $f \rightarrow$ 활성·물성(y), 그리고 정직한 검증·적용범위

7/23 종합: 구조 표현(1교시) $\rightarrow$ 기술자·지문(2교시) $\rightarrow$ QSAR 예측(3교시) = in-silico 발굴 파이프라인