

## 도킹 점수는 역가를 보는가, 골격을 보는가

### 골격 유사성을 설계로 분리한 PDE5A 재채점 연구 (n=163)

작성일 2026-09-05 · 버전 3.0 · 원자료 sample\_run/ (dataset ff01d67b6c7541a2, docking 2992a361c9e0e845, analysis 1dcb3ca9edf11a9e)




Figure 1. 그래픽 초록. 질문, 설계, 대조, 판정, 주 결과를 한 장에 담았다.

### 초록

**배경.** 구조 기반 가상 스크리닝은 도킹 점수로 화합물의 우선순위를 정한다. 이 관행을 평가한 연구는 대개 하나의 전역 상관을 보고하는데, 그 상관에는 표적 구조에 이미 결합해 있는 리간드와 골격이 닮았다는 사실이 섞여 들어간다. 공결정 리간드를 닮은 화합물이 대체로 더 강력하기 때문이다. 이 교란을 분리하지 않으면 점수가 역가를 본 것인지 골격을 본 것인지 알 수 없다.

**방법.** PDE5A 결정 구조(PDB 1UDT, 공결정 리간드 VIA)를 표적으로 삼았다. ChEMBL 에서 2538 개 활성 레코드를 받아 화합물당 중앙값으로 집계한 뒤(2158 종), 역가 3 구간 × 공결정 리간드와 의 Tanimoto 유사도 3 구간의 9 칸 격자에서 균등 추출해 163 종을 만들었다. 이 설계로 두 축의 상관을  $r=+0.175$  까지 낮췄다. smina (AutoDock Vina 1.1.2 scoring), exhaustiveness 64 으로 도킹하고, 공결정 리간드 재도킹을 대조로 두되 샘플링(C1)과 채점(C2)을 따로 판정했다. 자세는 공결정 리간드를 참조하지 않는 점수 1 위 자세를 주 결과로 썼다.

**결과.** 대조에서 샘플링은 결정 자세를 재현했으나(1.077 Å, 모드 5) 채점은 그 자세를 1 위로 올리 지 못했다(8.368 Å). 탐색 깊이를 4 에서 128 까지 32 배 올리자 C1 은 통과율 0%→100% 로 완 전히 고쳐진 반면 C2 는 전 구간 0% 이고 최고 점수는 변하지 않았다 — 탐색은 얇은 깊이에서 이 미 전역 최소를 찾았고 그 최소가 틀린 자리에 있다. 전체 순위상관은 -0.079 (95% CI -0.230–

+0.076, 순열  $p=0.31878$ ) 였고, **Tanimoto** 를 통제한 편상관은 **-0.105** ( $p=0.19274$ ) 였다. 유사도 구간 안에서 유의한 상관을 보인 구간은 1/3 개였다. 강함/약함 판별 ROC-AUC 는 전체 0.574, 구간별 far 0.549 · mid 0.534 · near 0.792. 교차검증  $Q^2$  는 단일 점수 -0.018, 5 개 항 -0.019, Tanimoto 단독 0.007 였다.

**결론.** 이 집합에서는 전체 순위 신호 자체가 없다 ( $p = -0.079$ , 95% CI -0.230~+0.076, 순열  $p = 0.31878$ ). 앞선  $n=30$  설계에서 얻은 상관은 재현되지 않았다. **다만 그 차이의 원인이 골격 교란이라는 설명은 검정 결과 기각되었다 (§ 3.5)** — 원인은 특정하지 못한다. 다만 **결정 구조와 같은 계열 안에서는 신호가 남는다** (near 대역  $p = -0.397$ ,  $p = 0.00365$ , AUC 0.792) — 채점 함수는 구조가 유래한 화합형 안에서만 작동한다. 정량 예측은 사전 기준( $Q^2 \geq 0.3$ )을 충족하지 못했다.

이 판은 자기 초안의 설명도 함께 기각한다. v2.0 은  $n=30$  에서  $p=-0.538$  를 얻었고 본 보고서 초안은 그것이 골격 교란의 산물이라고 적었다. 그러나 같은 편상관을 옛 데이터에 적용하면 감쇠는 **0.8%** 에 불과하고, 옛 데이터의 점수-Tanimoto 상관은 -0.125 ( $p=0.50747$ )로 관계 자체가 없다. 옛 설계를 새 데이터에 재현해도 상관은 중앙값 -0.148 에 그친다. 데이터가 지지하는 진술은 하나다 —  **$n=30$  의 상관은 더 큰 표본에서 재현되지 않았고, 그 차이의 원인을 우리는 특정하지 못한다.**

## 1. 서론

구조 기반 가상 스크리닝은 표적 결합 부위에 화합물을 계산으로 끼워 넣고 그 점수로 우선순위를 정한다. 이 관행이 성립하려면 세 가지가 따로 참이어야 한다. **자세 예측** — 프로그램이 실제 결합 자세를 만들 수 있어야 한다. **채점** — 그 자세에 매기는 점수가 실측 친화도와 같은 방향으로 움직여야 한다. 그리고 **비교 가능성** — 서로 다른 화합물 사이의 점수 차이가 화학적 유사성이 아니라 결합력의 차이를 반영해야 한다. 세 조건은 독립이며, 앞의 둘이 성립해도 셋째는 실패할 수 있다 [R5, R6].

셋째 조건이 이 보고의 초점이다. 도킹 평가 연구는 보통 활성 화합물 집합을 모아 점수와 역가의 상관을 낸다. 그런데 표적 구조는 대개 **어떤 리간드가 결합한 상태로 풀린 holo** 구조이고, 그 리간드를 닮은 화합물은 (a) 포켓에 기하학적으로 잘 맞아 점수가 좋고 (b) 같은 계열의 최적화 산물이라 대체로 더 강력하다. 두 경로가 같은 방향이므로 상관이 관찰되지만, 그것이 채점 함수의 능력인지 골격 유사성의 부산물인지 구분되지 않는다.


본 보고는 **역가와 골격 유사성을 설계로 직교화**해 이 교란을 제거한다. 그리고 다음 세 질문에 각각 답한다.

1. **정량 예측** — 점수가 pChEMBL 을 얼마나 설명하는가. 교차검증  $Q^2$  로 판정한다. 2. **선별** — 점수가 강한 화합물을 상위로 올리는가. 순위상관·ROC-AUC·농축계수로 판정한다. 3. **교란** — 위 성능이 골격 유사성을 통제된 뒤에도 남는가. 편상관과 구간내 상관으로 판정한다.

사전 성공 기준. 정량 예측은  $Q^2 \geq 0.3$  (QSAR 관행), 선별은 순열  $p < 0.05$  이면서 ROC-AUC  $\geq 0.7$  을 성공으로 본다. 교란 통계는 편상관의 절댓값이 원상관의 60% 이상 남고  $p < 0.05$  이면 "살아남았다"로 판정한다. 이 기준의 사후성은 § 2.6 에 고지한다.

## 2. 방법

### 2.1 표적과 구조



**Figure 2. 데이터셋 특성.** (A) 역가 분포, (B) 골격 유사도 분포, (C) 두 축의 직교성, (D) 화합물당 반복 측정 수.

표적은 PDE5A 다 (UniProt O76074, PDE5A, 875 잔기). 수용체는 PDB 1UDT, 공결정 리간드는 VIA (실데나필)이다.

### 2.2 데이터셋 — 역가와 골격의 직교화

ChEMBL 에서 PDE5A 활성( $\text{standard\_type} \in \{\text{IC50}, \text{Ki}\}$ ,  $\text{standard\_relation} = "="$ , pChEMBL 존재)을 전수 받아 2538 개 레코드를 얻었다. 화합물당 pChEMBL 중앙값 (반복 측정 병합) — 반복 측정을 버리지 않고 중앙값으로 합쳐 어세이 잡음을 줄였다. 중원자 12-70 개 범위로 걸러 2158 종의 풀을 만들었다.

각 화합물에 대해 공결정 리간드(실데나필)와의 **Morgan 지문(반지름 2, 2048 비트) Tanimoto 유사도**를 계산했다. 이어 역가 3 구간( $\text{weak} < 6.0 \leq \text{medium} < 7.5 \leq \text{strong}$ )과 유사도 3 구간( $\text{far} < 0.25 \leq \text{mid} < 0.45 \leq \text{near}$ )의 9 칸 격자를 만들고, 각 칸에서 pChEMBL 정렬 후 균등 간격으로 뽑았다 (결정적 규칙이라 시드가 없다).

| 역가     | 유사도  | 풀 내 후보 | 선택 |
|--------|------|--------|----|
| weak   | far  | 570    | 20 |
| weak   | mid  | 11     | 11 |
| weak   | near | 12     | 12 |
| medium | far  | 522    | 20 |
| medium | mid  | 30     | 20 |
| medium | near | 92     | 20 |
| strong | far  | 651    | 20 |
| strong | mid  | 142    | 20 |

|        |      |     |    |
|--------|------|-----|----|
| strong | near | 128 | 20 |
|--------|------|-----|----|

**Table 1. 9 칸 격자별 추출.** 최종 n=163. weak × near 칸이 얇은 것은 화학적으로 당연하다 — 실험결과와 매우 닮았는데 약한 화합물은 드물다. 이 불균형이 남은 잔여 교란의 원인이며 § 4.4 에서 다룬다.

결과적으로 역가와 유사도의 상관은 Pearson  $r = +0.175$ , Spearman  $\rho = +0.208$  로 낮아졌다. 두 지표를 모두 적는다 — 작은 쪽만 골라 보고하면 게이트를 통과시키려 고른 것으로 읽힌다.

**비교 대상인 옛 설계의 값도 함께 적는다.** 역가로만 증화한 n=30 세트에서 같은 상관은 Pearson +0.281 ( $p=0.132$ , 유의하지 않음) · Spearman +0.366 이었다. 즉 옛 설계도 두 축이 "사실상 같은 축" 이었다고 말할 정도는 아니었고, 이 사실이 § 3.5 의 검정 결과와 일관된다.

한 가지 더 적어 둘 것이 있다. Tanimoto 와 중원자수의 상관이 +0.403 이므로, "골격"과 "크기"라는 두 교란축은 서로 상당히 겹친다. 둘을 동시에 통제해도 독립적인 두 통제가 아니다.

## 2.3 도구

도구. Smina Oct 15 2019. Based on AutoDock Vina 1.1.2. · Open Babel 3.1.0 -- Oct 12 2020 -- 14:16:24 · PyMOL 2.5.1.

**수용체 준비.** PDB 1UDT 에서 물(all HOH)을 제거하고 촉매 금속 ZN, MG 은 남겼다. 공결정 리간드를 분리해 상자 기준으로 썼다. PDBQT 변환은 obabel -ipdb -opdbqt -xr -p 7.4 (수용체 전용) — 프로토네이션은 수용체에만 적용했다.

**리간드 준비.** RDKit ETKDGv3 단일 배좌 + MMFF 최적화, Chem.AddHs 중성 형태. **염은 명시적으로 제거했다** (가장 큰 프래그먼트만 남김) — 이전 실행에서 도구 기본 동작에 암묵적으로 맡겼던 단계를 코드로 올렸다. 리간드에는 pH 기반 프로토네이션을 적용하지 않았다.

**도킹.** smina (AutoDock Vina 1.1.2 scoring), exhaustiveness 64, seed 42, --num\_modes 9, --autobox\_add 3. 163/163 건 성공.

**자세 선택.** 주 결과는 점수 1 위 자세(top). 공결정 리간드 참조 없이 채점 함수만으로 결정된다. 참조 기준 자세(reference)는 민감도 분석으로만 쓴다.

## 2.4 대조 — 샘플링과 채점을 분리

공결정 리간드를 같은 조건으로 재도킹하고 두 가지를 따로 판정했다. **C1(샘플링)** = 상위 모드 중 결정 자세와 가장 가까운 것의 RMSD — 탐색이 옳은 자세를 만들어낼 수 있는가. **C2(채점)** = 점수 1 위 모드의 RMSD — 채점 함수가 그 자세를 1 위로 올리는가. 기준은 2.0 Å 이다. 두 대조를 합쳐서 보면 하나의 실패가 다른 하나로 오진된다.

추가로 탐색 깊이를 바꿔가며 두 대조를 반복했다 (§ 3.2). 탐색 부족이 원인이라면 깊이를 올릴 때 C2 도 개선되어야 한다.

## 2.5 분석

순위상관은 **동점 보정 Spearman**(평균 순위, 순위에 대한 Pearson)이다. 도킹 점수에 동점이 많아 단순 정렬 순위를 쓰면 값이 달라진다. p 값은 라벨 순열 20,000 회(시드 42) 양측이고, 신뢰구간은 Fisher z 변환이다. **편상관**은 순위 공간에서 Tanimoto 를 통제한 값이며, 그 p 값은

**Freedman-Lane 절차**로 구했다 — y 를 통째로 섞으면 역가와 Tanimoto 의 관계까지 깨져 검정하려는 귀무가설("점수가 골격 정보 너머의 정보를 주지 않는다")과 달라지므로, Tanimoto 로 회귀한 잔차만 섞고 적합값은 보존한다. 단순 섞기와의 차이도 모의 데이터로 확인했으며 두 절차의 p 값 차이는 0.004 이하였다 (statistics\_validation.json). 이 통계 함수들은 외부 의존 없이 직접 구현했으므로, **동점을 의도적으로 주입한 무작위 데이터 400 회로 scipy.stats 와 대조해 일치를 확인했다** (sample\_run/statistics\_validation.json, 최대 편차 1e-9 이하). 다중 모델 SDF 파서도 같은 방식으로 rdkit.Chem.SDMolSupplier 와 좌표 수준까지 대조했다 — 파서가 모델 경계를 잘못 잡으면 엉뚱한 자세로 접촉을 계산하고도 그럴듯한 잔기 목록이 나오기 때문이다. 회귀는 예측변수와 반응변수를 모두 표준화해 계수를 비교 가능하게 했고, LOO 교차검증  $Q^2$  와 라벨섞기 귀무분포를 함께 보고한다.

## 2.6 사후성 고지

**사전등록이 없다.** 결과를 본 뒤 정해진 결정이 셋 있다.

1. **성공 기준.** § 1 의  $Q^2 \geq 0.3$ ,  $AUC \geq 0.7$ , 편상관 60% 유지는 문헌 관행에서 가져온 값이며 데이터를 본 뒤 명문화했다. 2. **주 자세 규칙.** C2 대조 실패를 확인한 뒤 "점수 1 위를 주 결과로 쓰고 참조 기준 자세는 민감도 분석으로만 쓴다"로 정했다. 다만 이 선택은 **참조를 쓰지 않는 쪽**이므로 결과를 유리하게 만들지 않는다. 두 규칙의 결과를 § 3.7 에 병기한다. 3. **구간 경계.** 역가 3 구간과 유사도 3 구간의 절단점은 분포를 보고 정했다.

이 연구는 이전 판(n=30, 역가로만 층화)의 결론이 골격 교란으로 해석 불가능함을 확인하고 다시 설계한 것이다. 그 경위는 § 개정 이력에 적었다.


## 3. 결과

### 3.1 데이터셋

n=163, pChEMBL 4.00–11.00 (약 7.0 로그), Tanimoto 0.065–0.806. 역가-유사도 상관  $r=+0.175$  (Figure 2C).

### 3.2 대조 — 병목은 채점이다

Re-docking control separates pose generation from scoring




**Figure 3. 재도킹 대조.** (A) 모드별 결정 자세 재현도, (B) 두 대조의 판정.

| 항목                     | 값              | 판정   |
|------------------------|----------------|------|
| 재도킹 점수                 | -9.6 kcal/mol  | —    |
| C1 샘플링 (상위 모드 최선 RMSD) | 1.077 Å (모드 5) | PASS |
| C2 채점 (1 위 자세 RMSD)    | 8.368 Å        | FAIL |

**Table 2. 재도킹 대조. 기준 2.0 Å.**

탐색 깊이를 바꿔 같은 대조를 반복했다.

The bottleneck is scoring, not sampling: a search-depth experiment



**Figure 4. 탐색 깊이 실험.** (A) 깊이별 C1·C2, (B) 최고 점수, (C) 시드별 통과율.

| exhaustiveness | C1 최선 RMSD (Å) | C2 1 위 RMSD (Å) | 최고 점수 | C1 통과율 | C2 통과율 |
|----------------|----------------|-----------------|-------|--------|--------|
| 4              | 2.97           | 8.39            | -9.60 | 0.00   | 0.00   |
| 8              | 1.70           | 8.39            | -9.60 | 0.67   | 0.00   |



|     |      |      |       |      |      |
|-----|------|------|-------|------|------|
| 16  | 1.44 | 8.36 | -9.60 | 0.67 | 0.00 |
| 32  | 1.16 | 8.36 | -9.60 | 1.00 | 0.00 |
| 64  | 1.07 | 8.36 | -9.60 | 1.00 | 0.00 |
| 128 | 1.09 | 8.37 | -9.60 | 1.00 | 0.00 |

**Table 3. 탐색 깊이 스윙.** 시드 [42, 7, 2024] 평균. 요청 모드 수는 전 조건 20 개이나 smina 가 실제로 반환한 모드 수는 조건마다 18-20 개로 달랐다. C1 은 "상위 모드 중 최선"이라 모드 수에 민감하므로 C1 은 "상위 모드 중 최선"이므로 모드 수를 늘리면 값이 좋아진다 — 따라서 이 표의 C1 은 § 3.2 상단 대조(9 개 모드)와 직접 비교하지 말고, 스윙 내부의 깊이 간 비교로만 읽어야 한다.

세 가지가 동시에 보인다.


**첫째, 탐색은 깊이로 완전히 고쳐진다.** C1 은 2.97 Å (통과율 0%)에서 1.09 Å (통과율 100%)로 단조 개선된다. 깊이 32 이상에서는 모든 시드가 결정 자세를 상위 모드 안에 재현한다.

**둘째, 채점은 어느 깊이에서도 실패한다.** C2 는 전 구간에서 0.025 Å 밖에 변하지 않고 통과율은 모든 깊이에서 0% 다.

**셋째, 점수는 가장 얇은 깊이에서 이미 포화한다.** 최고 점수는 전 구간에서 0.0 kcal/mol 변동, 즉 사실상 상수다.

세 관찰을 합치면 결론은 하나다. 탐색은 깊이 4 에서 이미 채점 함수의 전역 최소를 찾아냈고, 그 최소가 결정 자세에서 8.4 Å 떨어진 곳에 있다. 채점 함수의 최적점 자체가 틀린 위치에 있으므로 탐색을 아무리 늘려도 고쳐지지 않는다. 실제로 이 표에서 깊이를 4 에서 128 로 32 배 늘렸을 때 얻은 것은 C1 개선뿐이고 C2 는 그대로다.

### 3.3 점수와 역가 — 통제 전



**Figure 5. 도킹 점수 대 실측 역가.** 왼쪽은 전체, 나머지는 유사도 구간별.

전체 순위상관은 -0.079 (95% CI -0.230-+0.076, 순열 p=0.31878) 다. 점수는 낮을수록, pChEMBL 은 높을수록 좋으므로 음의 상관이 양의 예측력을 뜻한다.


그런데 같은 데이터에서 점수와 Tanimoto 의 상관은 +0.110, 역가와 Tanimoto 의 상관은 +0.208 다. 세 상관이 모두 0 이 아니므로 위 값을 그대로 "예측력"으로 읽으면 안 된다.

| ChEMBL ID     | 역가/유사도 구간   | pChEMBL | Tanimoto | 점수     | MCS-RMSD (Å) |
|---------------|-------------|---------|----------|--------|--------------|
| CHEMBL536568  | weak/far    | 5.40    | 0.135    | -12.00 | 7.126        |
| CHEMBL6059124 | strong/far  | 7.82    | 0.131    | -11.90 | 5.82         |
| CHEMBL5276050 | medium/far  | 7.33    | 0.099    | -11.90 | 2.843        |
| CHEMBL349359  | medium/far  | 7.49    | 0.113    | -11.80 | 5.407        |
| CHEMBL557593  | medium/far  | 6.70    | 0.176    | -11.70 | 4.979        |
| CHEMBL3944571 | medium/near | 6.78    | 0.466    | -11.60 | 5.54         |
| CHEMBL5188011 | weak/mid    | 4.42    | 0.283    | -11.60 | 6.429        |
| CHEMBL130612  | strong/far  | 7.61    | 0.126    | -11.50 | 5.388        |
| CHEMBL372917  | strong/far  | 7.50    | 0.119    | -11.50 | 6.033        |
| CHEMBL160556  | medium/far  | 6.93    | 0.103    | -11.50 | 2.473        |
| CHEMBL5787529 | medium/far  | 6.06    | 0.139    | -11.40 | 4.702        |
| CHEMBL343345  | strong/far  | 8.59    | 0.076    | -11.10 | 6.457        |
| CHEMBL3956031 | strong/near | 8.40    | 0.482    | -11.00 | 5.537        |
| CHEMBL1650673 | strong/far  | 8.00    | 0.150    | -11.00 | 3.702        |
| CHEMBL3940720 | strong/near | 7.66    | 0.477    | -11.00 | 6.369        |

**Table 4. 점수 상위 15 건.** 대역별 구성의 정량 값은 § 3.6 에 있다. MCS-RMSD 는 대칭 보정이 없는 단일 매핑이며, MCS 원자수가 적은 화합물(far 대역 평균 약 10 개, 하한 8 개)에서는 해석이 어렵다.



### 3.4 골격 통제 — 결정적 검증



**Figure 6.** 통제 전후 상관. 막대는 95% Fisher 신뢰구간.

| 유사도 구간 | n  | pChEMBL 범위 | Spearman | 95% CI            | 순열 p    | ROC-AUC |
|--------|----|------------|----------|-------------------|---------|---------|
| far    | 60 | 4.00–11.00 | -0.082   | -0.329–<br>+0.176 | 0.53387 | 0.549   |
| mid    | 51 | 4.37–10.00 | -0.024   | -0.298–<br>+0.253 | 0.86546 | 0.534   |
| near   | 52 | 5.00–10.60 | -0.397   | -0.605–<br>0.139  | 0.00365 | 0.792   |

**Table 5.** 유사도 구간 내 분석. 대역 안에서 역가 신호가 남는지 본다. 대역 구분은 3 분할일 뿐이므로 대역 안에서도 골격이 완전히 고정되지는 않는다 — 그래서 Table 7 에서 대역 내 교란 통제를 다시 적용한다.

| 통제 대상             | 편상관                   |
|-------------------|-----------------------|
| 없음 (원상관)          | -0.079                |
| 골격 유사도 (Tanimoto) | -0.105 (순열 p=0.19274) |
| 분자 크기 (중원자수)      | -0.034                |
| 골격 + 크기 동시        | -0.088                |

**Table 6.** 교란 통제 단계별 편상관. 점수와 중원자수의 상관은 -0.342, 역가와 중원자수의 상관은 +0.136 다. Vina 계열 점수가 분자 크기에 반응한다는 것은 알려진 성질이므로 [R5] 골격만 통제하면 부족하다.

Tanimoto 를 통제한 편상관은 **-0.105** (순열 p=0.19274) 다. 원상관 -0.079 보다 절댓값이 **1.33** 배로 커졌다 — 줄어든 것이 아니다. Tanimoto 가 pIC50 과 양(+0.208)이면서 점수와도 양(+0.110)이라, 통제하면 가려져 있던 약한 음의 관계가 드러나는 **억제변수(suppressor)** 구조다.

다만 커진 뒤에도 유의하지 않으므로 ( $p=0.19274$ ) 결론은 바뀌지 않는다. 유사도 구간 안에서 유의한 상관( $p<0.05$ )을 보인 구간은 **1/3 (near)** 이다. 구간내 상관의 평균은 **-0.168** 다.

**대역 안에서도 골격은 고정되지 않는다.** 대역별 pIC50-Tanimoto 상관은 여전히 0 이 아니므로 (Table 5 의 대역 구분은 3 분할일 뿐이다), 대역 내에서도 교란 통제를 다시 적용했다.

| 대역   | n  | 원상관    | 크기 통제  | 골격 통제  | 동시 통제  |
|------|----|--------|--------|--------|--------|
| far  | 60 | -0.082 | +0.178 | -0.155 | +0.050 |
| mid  | 51 | -0.024 | +0.033 | +0.017 | -0.116 |
| near | 52 | -0.397 | -0.437 | -0.421 | -0.459 |

**Table 7. 대역별 교란 통제.** near 대역의 신호는 통제 후 오히려 강해진다 ( $-0.397 \rightarrow -0.459$ ). far 대역은 크기 통제 시 부호가 뒤집힌다 ( $-0.082 \rightarrow +0.178$ ). 전역 편상관 하나로는 이 이질성이 보이지 않는다.

**near 대역 신호는 한 칸에 얹혀 있다.** 그 대역의 weak 칸은 풀 전수(census)이고 pChEMBL 이 어세이 바닥값에 몰려 있다. 그 칸을 빼면 상관은  $-0.219$  ( $n=40$ ) 로 떨어진다. 바닥값 화합물만 빼면  $-0.370$  ( $n=44$ ) 다. 따라서 **near 대역 결과는 잠정적으로 읽어야 한다.**

이중 회귀(표준화)에서 점수 계수는  $-0.088$ , Tanimoto 계수는  $+0.182$  였다.

### 3.5 앞선 판의 상관은 왜 무너졌는가 — 세 가지를 검정했다

v2.0 은  $n=30$  에서  $p=-0.538$  ( $p=0.00285$ ) 를 보고했다. 본 보고서의 초안은 그 값이 골격 교란의 산물이라고 적었으나, 검정해 보니 그 설명은 성립하지 않았다.

| 검정                            | 결과                                    | 해석               |
|-------------------------------|---------------------------------------|------------------|
| ① 옛 데이터에서 Tanimoto 통제         | $-0.538 \rightarrow -0.534$ (감쇠 0.8%) | 골격 교란이 아니다       |
| ② 옛 데이터의 점수 vs Tanimoto       | $-0.125$ ( $p=0.50747$ )              | 점수가 골격을 따라가지 않았다 |
| ③ 옛 설계를 새 데이터에 재현 (4000 회 추출) | 중앙값 $-0.148$ , 95% $[-0.446, +0.154]$ | 설계만으로도 설명되지 않는다  |
| ④ 층화 없이 무작위 30 건              | 중앙값 $-0.082$ , 95% $[-0.381, +0.242]$ | 표본 크기만의 효과 참조값   |

**Table 8. 상관 붕괴의 원인 검정.** ③ 은 새 163 건에서 옛 절단점( $\text{strong} \geq 7.0$ )으로 역가 3 층 × 층당 10 건을 골격 무시하고 반복 추출한 것이다. 그 분포에서  $-0.4$  이하가 나올 확률은 4.7% 다.

두 세트의 공통 화합물은 3 건뿐이라 프로토콜 차이(탐색 깊이  $16 \rightarrow 64$ , 자세 규칙, 반복측정 집계)를 직접 비교할 수 없었다.

**따라서 원인을 특정하지 못한다.** 남은 후보는 화합물 집합 자체와 프로토콜 차이이며 이 데이터로는 나눌 수 없다. 데이터가 지지하는 진술은 " **$n=30$  의 상관은 더 큰 독립 표본에서 재현되지 않았다**" 까지다. 이 절은 본 보고서 초안의 인과 주장을 철회한 기록이다.

### 3.6 자세 타당도 — 우리는 어떤 자세에 점수를 매겼는가

점수의 의미는 그 점수를 매긴 자세가 실제 결합 자세와 얼마나 가까운지에 달려 있다. 2.0 Å 기준 (§ 3.2 의 C2 와 동일)으로 1 위 자세를 평가했다.

| 유사도 대역 | n   | MCS-RMSD 중앙값 (Å) | 기준 미만 | 평균 점수 (kcal/mol) |
|--------|-----|------------------|-------|------------------|
| far    | 55  | 5.25             | 1.8%  | -10.20           |
| mid    | 51  | 5.74             | 31.4% | -9.63            |
| near   | 52  | 3.27             | 25.0% | -9.99            |
| 전체     | 158 | 4.50             | 19.0% | —                |


**Table 9. 1 위 자세의 결정 자세 부합도.** MCS 원자수가 하한 8 개에 못 미치면 계산이 불가해 제외했다 (전체 163 건 중 5 건). 이 지표는 대칭 보정이 없는 단일 매핑 RMSD 이므로 대칭 분자에서 과대평가될 수 있다.

분석 대상 자세의 81% 가 C2 대조를 실패시킨 것과 같은 기준을 넘지 못한다. far 대역은 1.8% 에 그친다. 즉 § 3.4 의 "신호 없음"은 대부분 결정 자세 틀 밖에 놓인 자세에 매긴 점수에 대한 진술 이고, near 대역의 유의한 상관도 25% 만 틀 안에 있는 자세들에서 나왔다. 이것이 본 연구의 가장 큰 해석 제약이며 § 4.1 에서 다시 다룬다.


평균 점수는 far 가 가장 좋다 (-10.20 vs near -9.99). 점수 상위 16 건의 대역 구성은 far 11 · mid 1 · near 4 (무작위 기대 각 5.3), 역가 구성은 강 7 · 중 7 · 약 2 이다. 도킹 점수는 0.1 kcal/mol 해상도로 출력되어 163 건에 서로 다른 값이 소수뿐이며, 동점이 많아 상위 k 구성은 정렬 안정성에 따라 한두 건 달라질 수 있다.

### 3.7 선별 지표

Triage performance survives (or does not) scaffold control



**Figure 7. ROC 곡선. (A) 전체, (B) 유사도 구간별.**



**Figure 8. 농축 곡선과 상위 10% 구성.** 오른쪽 패널이 핵심이다 — 상위권이 역가로 채워지는지 골격 유사도로 채워지는지 직접 보여준다.

| 대역   | 강/약 n | ROC-AUC | 95% CI      | Bonferroni p (상관) |
|------|-------|---------|-------------|-------------------|
| far  | 20/20 | 0.549   | 0.369–0.729 | 1.0               |
| mid  | 20/11 | 0.534   | 0.320–0.748 | 1.0               |
| near | 20/12 | 0.792   | 0.637–0.947 | 0.0109            |
| all  | 60/43 | 0.574   | 0.463–0.685 | —                 |


**Table 10. 선별 지표와 불확실성.** AUC 는 강함/약함 두 층만으로 계산하므로 n 이 각 대역의 전체 수보다 작다. 신뢰구간은 Hanley-McNeil 근사다.

사전 기준 0.7 을 점 추정으로 넘은 대역은 1/3 개(near)지만, 그 신뢰구간 **[0.637, 0.947]** 은 **0.7** 을 포함한다. 즉 이 표본으로는 near 대역이 기준을 넘는다고 단정할 수 없다.


3 개 대역 상관 검정에 대한 다중비교 보정은 Bonferroni  $0.0109 \cdot BH$  0.0109 로, **near** 대역은 보정 후에도 유의하다. (§ 4.4 한계 8 의 "미보정" 서술을 이 결과로 대체한다.)

농축계수는 상위 10% 에서 1.19 다.

### 3.8 스코어 항 분석



**Figure 9. 항 기여도 네 가지 관점. 지표마다 다른 답을 준다면 그 사실이 결과다.**



**Figure 10. 항 상관·골격 연관·모델 비교.**

| 모델                       | 파라미터 | R² (적합) | Q² (LOO) | 라벨섞기 중앙 | 라벨섞기 95% |
|--------------------------|------|---------|----------|---------|----------|
| single_vina_score        | 2    | +0.005  | -0.018   | +0.003  | +0.024   |
| five_terms               | 6    | +0.048  | -0.019   | +0.028  | +0.069   |
| tanimoto_only            | 2    | +0.030  | +0.007   | +0.003  | +0.023   |
| five_terms_plus_tanimoto | 7    | +0.073  | -0.006   | +0.034  | +0.079   |

**Table 11. 회귀 성능. Q²가 R²보다 크게 낮으면 과적합이다. 라벨섞기 95분위를 넘지 못하는 R²는 우연과 구별되지 않는다.**

이 규칙을 적용하면 도킹 항 기반 모델은 셋 다 우연 수준을 넘지 못한다. 자기 귀무분포의 95분위를 넘는 유일한 모델은 **Tanimoto** 단독 (R² +0.030 vs 섞기 95% +0.023)이고, Q²가 음수가 아닌

것도 그것뿐이다 (+0.007). 즉 이 데이터에서는 골격 유사성 하나가 도킹 항 전부보다 역가를 잘 설명한다. 다만 그 값들도 절대적으로는 0에 가까워, 어느 쪽도 실용적 예측력은 없다.


| 항           | 표준화 계수 | 단변량 r (vs pChEMBL) | r (vs Tanimoto) | 순열 Q <sup>2</sup> 하락 | VIF |
|-------------|--------|--------------------|-----------------|----------------------|-----|
| gauss1      | -0.103 | +0.050             | +0.403          | -0.0004              | 4.8 |
| gauss2      | +0.311 | +0.108             | +0.360          | +0.0229              | 4.8 |
| repulsion   | -0.175 | -0.077             | +0.210          | +0.0095              | 2.7 |
| hydrophobic | -0.056 | -0.077             | -0.244          | -0.0005              | 1.3 |
| hbond       | -0.021 | -0.074             | +0.304          | -0.0090              | 1.8 |

**Table 12. 항별 기여도.** 비표준화 계수는 단위가 달라 비교할 수 없으므로 표준화 값을 쓴다. 순열 Q<sup>2</sup> 하락이 양수여야 그 항이 신호를 담고 있다는 뜻이고, VIF가 5를 넘으면 개별 계수의 해석이 불안정하다.

이 표는 참고 이상으로 읽으면 안 된다. 순열 중요도는 해당 30회 서플로만 추정했고 표준오차를 내지 않았으며, 그 대상 모델(5개 항)의 R<sup>2</sup>는 위에서 보았듯 우연 수준을 넘지 못한다. 우연과 구별되지 않는 모델 안에서 항의 상대적 기여를 논하는 것은 잡음을 읽는 일이다.

### 3.9 자세 선택 규칙 민감도

Pose-selection rule: sensitivity analysis




**Figure 11. 두 자세 규칙 비교.** (A) 공결정 리간드와의 거리 분포, (B) 상관 비교.

주 결과는 공결정 리간드를 참조하지 않는 점수 1위 자세다 (-0.079). 참조 기준으로 고른 자세를 쓰면 -0.144이다. 결론은 규칙에 의존하지 않는다.

### 3.10 적합 가중치를 실제 채점 함수로 넣어 재도킹

§ 3.8의 회귀는 이미 도킹된 자세를 사후 재채점한 것이다. 가중치가 정말 유용하다면 도킹 자체를 그 가중치로 다시 돌렸을 때 더 나은 순위가 나와야 한다. 적합 가중치를 smina --custom\_scoring 파일로 내보내고, 9칸 격자에서 층화 분할한 시험 집합 49건을 두 번 도킹했다

— 한 번은 기본 Vina 점수로, 한 번은 적합 가중치로. 화합물·수용체·상자·시드가 모두 같으므로 차이는 채점 함수뿐이다. 가중치는 훈련 집합 114 건에서만 적합했고 시험 집합은 적합에 쓰이지 않았다.



**Figure 12. 채점 함수 비교.** (A) 두 팔의 held-out 상관, (B) 차이의 부트스트랩 신뢰구간, (C) 같은 화합물의 두 점수.

| 채점 함수   | held-out Spearman | 95% CI          |
|---------|-------------------|-----------------|
| 기본 Vina | -0.118            | [-0.386, 0.169] |
| 적합 가중치  | +0.028            | [-0.255, 0.307] |


**Table 13. 독립 시험 집합에서의 채점 함수 비교 (n=49, 훈련 114 건과 분리).**

차이는 +0.146, 부트스트랩 95% 신뢰구간은 [-0.209, +0.500] 이고 커스텀이 더 나은 재표본의 비율은 21.2% 다. 신뢰구간이 0 을 포함하므로 개선을 주장할 수 없다.


점 추정값만 보고했다면 다른 결론을 썼을 것이다. 숫자가 원하는 방향으로 움직였는지와 그 움직임이 우연과 구별되는지는 다른 질문이며, 후자에는 신뢰구간이 필요하다.



### 3.11 결합 양상과 접촉 잔기



**Figure 13.** 결합 부위와 자세. (위) 수용체 카툰과 포켓 위치, (아래) 포켓 근접 — 결정 자세(회색)와 점수 1 위 도킹 자세(색), 극성 접촉. 이 자세는 공결정 리간드를 참조하지 않고 채점 함수만으로 뽑힌 것이다.



| 잔기     | 참조 선택 자세 | 점수 1 위 자세 |
|--------|----------|-----------|
| GLN817 | 60/60    | 59/60     |
| PHE820 | 60/60    | 60/60     |
| PHE786 | 59/60    | 57/60     |
| LEU804 | 57/60    | 54/60     |
| VAL782 | 60/60    | 60/60     |
| TYR612 | 57/60    | 56/60     |

**Table 14.** 강함 총 60 건 중 해당 잔기와 접촉한 화합물 수. 4.0 Å 이내 중원자 기준. 두 자세의 접촉 집합은 평균 Jaccard 0.619 로 서로 다른데도 핵심 잔기는 양쪽 모두 전 화합물에서 접촉한다. 해석은 § 4.3 에서 다룬다.

## 4. 논의

### 4.1 탐색 깊이는 병목이 아니다 — 그 이상은 말할 수 없다

이전 판의 자세/채점 진단은 재도킹 대조 한 건에 근거해 약했다. 이번에는 탐색 깊이 4-128 × 시드 3 개의 통제 실험으로 대체했다 (§ 3.2).

탐색을 32 배 늘렸을 때 **C1** 은 완전히 고쳐지고(통과율 0% → 100%) **C2** 는 전혀 움직이지 않았다(통과율 0% → 0%, 변동 0.025 Å). 최고 점수가 가장 얇은 깊이에서 이미 포화했다는 사실이 이 관찰을 확정한다 — 탐색이 전역 최소를 못 찾은 것이 아니라, 찾은 전역 최소가 틀린 자리에 있다.

다만 이 스윙은 리간드 한 종(공결정 리간드)에 대해 깊이와 시드만 바꾼 것이다. 실행 횟수는 1 → 18 로 늘었지만 화학적 표본은 여전히  $n=1$  이다. 따라서 이 실험이 지지하는 진술은 "탐색 깊이는 병목이 아니다" 까지이며, "채점 함수가 원인이다" 는 그보다 넓은 주장이다.

가장 큰 제약은 자세 타당도다 (§ 3.6). 분석 대상 자세의 81% 가 2 Å 기준을 넘지 못한다. C2 대조가 실패했다는 사실은 개별 화합물의 1 위 자세도 대부분 결정 자세 틀 밖에 있으리라는 예측이고, 실제로 그렇다. 따라서 § 3.4 의 "신호 없음"을 "채점 함수가 역가를 못 본다"로 곧장 읽으면 안 된다 — 대부분 틀린 자세에 매긴 점수가 역가와 무관한 것은 당연할 수 있다. 둘을 나누려면 각 화합물의 실험 결정 구조가 필요한데 그것은 존재하지 않는다.

프로토네이션 비대칭이 특히 직접적인 후보다. 수용체는 pH 7.4 로 프로토네이션했으나 (obabel -p 7.4) 리간드는 중성 AddHs 그대로다 (§ 2.3). 실데나필의 피페라진은 생리적 pH 에서 양성자화되므로, 중성 실데나필을 pH 7.4 수용체에 재도킹한 것이 C2 실패의 직접 원인일 수 있다. 본 연구는 이를 검정하지 않았다. 그 밖의 후보 — 물 전량 제거, 강체 수용체, 단일 배좌, holo 유도적합 편향 — 도 마찬가지다.

실무적 함의는 직접적이다. 도킹 결과가 나쁠 때 exhaustiveness 를 올리는 것이 흔한 대응인데, 채점이 병목이면 그 조치는 계산 자원만 쓰고 아무것도 바꾸지 못한다. 어느 쪽인지는 재도킹 대조를 C1/C2 로 쪼개고 깊이를 흔들어 봐야만 알 수 있다. 두 대조를 합쳐 하나의 숫자로 보고하면 이 구분이 사라진다.

#### 4.2 무엇이 신호를 만들고 있었나 — 답하지 못한 채로 남긴다

이 집합에서는 전체 순위 신호 자체가 없다 ( $\rho = -0.079$ , 95% CI  $-0.230$ – $+0.076$ , 순열  $p = 0.31878$ ). 앞선  $n=30$  설계에서 얻은 상관은 재현되지 않았다. 다만 그 차이의 원인이 골격 교란이라는 설명은 검정 결과 기각되었다 (§ 3.5) — 원인은 특정하지 못한다. 다만 결정 구조와 같은 계열 안에서는 신호가 남는다 (near 대역  $\rho = -0.397$ ,  $p = 0.00365$ , AUC 0.792) — 채점 함수는 구조가 유래한 화학형 안에서만 작동한다.

여기서 예상과 반대되는 관찰이 나온다. 직관적으로는 공결정 리간드를 닮은 분자가 포켓에 잘 맞아 좋은 점수를 받으리라 기대하게 된다. 데이터는 반대다. 점수는 낮을수록 좋은데, 점수-Tanimoto 순위상관은 **+0.110** — 즉 닮을수록 점수가 나쁘다. 대역별 평균 점수도 far -10.20 · mid -9.63 · near -9.99 kcal/mol 로 가장 안 닮은 대역이 가장 좋은 점수를 받는다. 점수 상위 16 건의 대역 구성은 far 11 · mid 1 · near 4 로, 무작위 기대(각 약 5.3 건) 대비 far 가 뚜렷이 과대표집된다.

분자 크기로는 설명되지 않는다. Vina 계열 점수는 크기에 반응하고 (점수-중원자수 -0.342), 크면 점수가 좋아진다. 그런데 near 대역이 오히려 더 큰 분자로 이루어져 있다. 크기 효과만 있었다면 near 가 좋은 점수를 받아야 하는데 그 반대다.

따라서 우리는 이 방향의 기전을 특정하지 못한다. 관찰만 적는다 — 이 표적·이 구조에서 채점 함수는 공결정 리간드와 닮지 않은 분자에 더 좋은 점수를 준다. 자세 타당도(§ 3.6)를 보면 far 대역은 결정 자세 틀 안에 놓이는 비율이 1.8%에 불과하므로, "닮지 않은 분자가 상자 안에서 접촉을 최대화하는 임의의 자세를 찾아 좋은 점수를 얻는다"는 설명이 가능하지만 **검정하지 않았다**.

**이 보고의 기여는 기전 설명이 아니라 두 가지 음성 결과다.**

첫째, 더 크고 골격을 통제된 표본에서 도킹 점수는 역가와 관계가 없다 ( $p=-0.079$ , 95% CI -0.230~+0.076). 단 이 "없다"는 검정력 한계 안에서의 진술이며  $|p| \leq 0.218$  인 관계는 배제하지 못한다 (§ 4.4 한계 9).

둘째,  $n=30$  에서 얻었던  $p=-0.538$  는 재현되지 않았고, 그 이유로 우리가 처음 제시한 설명(골격 교란)은 **검정 결과 틀렸다** (§ 3.5). 설계 재현 실험도 그 차이를 만들지 못했다. 남은 후보는 화합물 집합과 프로토콜 차이이며 이 데이터로는 나눌 수 없다.

따라서 "골격 유사성을 통제하라"는 처방은 이 연구가 입증한 것이 아니다. 벤치마크 집합의 유사성 편향 자체는 선행 문헌이 반복해서 지적해 온 문제이고 [R12, R13, R14], 통제해서 손해 볼 일은 없다. 다만 본 연구에서 통제가 결과를 바꾼 몫은 옛 데이터 기준 0.8%로 거의 0이었다. 이 사실을 적지 않고 처방만 남기면 앞선 판이 저지른 것과 같은 종류의 과잉 주장이 된다.

#### 4.3 접촉 잔기 일치는 검증력이 거의 없다

핵심 잔기는 참조 기준 자세와 점수 1 위 자세 **양쪽 모두**에서 전 화합물이 접촉한다. 점수 1 위 자세는 공결정 리간드를 참조하지 않으므로 이 관찰은 순환이 아니다. 그러나 **자세 타당성의 증거도 아니다**. 두 자세 모두 공결정 리간드 주변 상자 안에 있으므로 포켓을 둘러싼 잔기와 접촉하는 것은 자세가 맞든 틀리든 일어난다. 실제로 재도킹 대조에서 8.368 Å 벗어난 1 위 자세조차 같은 잔기와 접촉한다.

"알려진 잔기와 접촉한다"는 흔한 정당화 문장은 결합 부위를 지정해 도킹하면 거의 자동으로 참이 된다. 자세를 검증하려면 실험 좌표와의 RMSD 처럼 틀릴 수 있는 지표를 써야 한다.

#### 4.4 한계

1. 단일 표적, 단일 결정 구조다. 다른 표적·다른 구조에서 같은 결론이 나올지는 검정하지 않았다. 2. 수용체를 강제로 다뤘고 물을 모두 제거했다. 유연 도킹·양상불 도킹·결합부 물 유지는 시도하지 않았다. 따라서 "채점 함수의 실패"는 가장 단순한 설명이지 확인된 원인이 아니다. 3. 리간드는 ETKDG 단일 배좌다. 배좌 양상불은 쓰지 않았다. 4. **9 칸이 균형이 맞지 않는다**. weak × near 칸의 풀 후보가 적어 (Table 1) 잔여 교란  $r=+0.175$  가 남았다. 완전한 직교화는 화학적으로 불가능하다 — 공결정 리간드와 매우 닮았는데 약한 화합물이 자연히 드물기 때문이다. 5. y 축이 균질하지 않다. IC50 과 Ki 를 Cheng-Prusoff 보정 없이 한 척도로 묶었고, 서로 다른 문헌·어세이 조건에서 온 값이다. 화합물당 중앙값 집계로 완화했을 뿐이다. 6. Tanimoto 는 골격 유사성의 한 척도일 뿐이다. 다른 지문·다른 유사도 정의로는 통제의 강도가 달라질 수 있다. 7.

사전등록이 없다 (§ 2.6). 8. 다중 비교는 3 개 대역 상관에 대해 Bonferroni·BH 를 계산해 § 3.7 에 보고했다 (near 는 보정 후에도 유의). 그 밖의 검정(AUC, 회귀)에는 보정을 적용하지 않았다. 9. **검정력이 부족하다.** 80% 검정력에서 검출 가능한 최소  $|p|$  은 전체 0.218 · far 0.355 · mid 0.383 · near 0.38 · near AUC 0.478 다. far·mid 대역의 "신호 없음"은  $|p| \lesssim 0.38$  인 관계를 배제하지 못한다. 귀무를 채택한 것이 아니라 기각하지 못한 것이다. 10. **결과변수에 대한 선택.** 각 칸에서 pChEMBL 정렬 후 균등 간격으로 뽑아 역가 분포가 인위적으로 평탄해졌다. 이런 표본의 상관은 모집단 상관의 추정치가 아니다. 11. **칸별 추출 비율이 크게 다르다.** strong × far 는 풀의 3.1%(20/651)인 반면 weak × mid·near 는 전수(100%)다. 전수인 칸은 표본이 아니므로 그 칸에 의존하는 결과 (§ 3.4 의 near 민감도 참조)는 다른 화합물 집합으로 일반화되지 않는다. 12. **자세 타당도가 낮다** (§ 3.6). 분석 자세의 81% 가 2 Å 기준 밖이며, 이것이 모든 상관 해석의 상한을 정한다. 13. MCS-RMSD 는 대칭 보정이 없는 단일 매핑이다. 대칭 분자에서 값이 과대평가될 수 있다. 9. 도킹 점수는 가설이며 결합 친화도의 실측이 아니다.

## 5. 결론

세 질문에 각각 답한다.

**탐색 깊이는 병목이 아니다.** 깊이를 4 에서 128 로 32 배 올리자 C1 은 통과율 0%→100% 로 고쳐졌고 C2 는 전 구간 0%, 최고 점수는 변동 0.0 kcal/mol 이었다. 탐색은 가장 얇은 깊이에서 이미 전역 최소를 찾았다. 도킹 결과가 나쁠 때 탐색을 늘리는 통상의 대응은 이 상황에서 계산 자원만 쓴다. 단, 이 실험은 리간드 한 종(공결정 리간드)에 대한 것이므로 "채점 함수가 원인"까지 확정하지는 못한다 (§ 4.1).

**정량 예측은 사전 기준을 충족하지 못했다.** 교차검증  $Q^2$  는 단일 점수 -0.018, 5 개 항 -0.019, Tanimoto 단독 0.007 로 모두 0 근처이며 기준 0.3 에 한참 미달한다. 이 점수로 개별 IC50 을 추정하는 것은 정당화되지 않는다.

**선별도 전체적으로는 작동하지 않는다.** 이 집합에서는 전체 순위 신호 자체가 없다 ( $p = -0.079$ , 95% CI -0.230→+0.076, 순열  $p = 0.31878$ ). 앞선  $n=30$  설계에서 얻은 상관은 재현되지 않았다. 다만 그 차이의 원인이 골격 교란이라는 설명은 검정 결과 기각되었다 (§ 3.5) — 원인은 특정하지 못한다. 다만 결정 구조와 같은 계열 안에서는 신호가 남는다 (near 대역  $p = -0.397$ ,  $p = 0.00365$ , AUC 0.792) — 채점 함수는 구조가 유래한 화학형 안에서만 작동한다.

**한 대역에서만 신호가 있고, 그 신호는 취약하다.** 유사도 대역별로 나눠 보면 far -0.082 · mid -0.024 · near -0.397 이고 유의한 것은 near 대역뿐이다 ( $p=0.00365$ ; Bonferroni 0.0109 로 보정 후에도 유의). 교란 통제 후 오히려 강해지므로 (→-0.459) 골격이나 크기가 만든 값도 아니다.

**그러나 이 결과에 무게를 실을 수 없다.** 세 가지 때문이다. (a) 그 대역의 AUC 신뢰구간 [0.637, 0.947] 이 사전 기준 0.7 을 포함한다. (b) 전수(census)인 weak 칸을 빼면 상관이 -0.219 로 떨어

저 유의하지 않다. (c) 그 칸의 역가는 어세이 바닥값에 몰려 있다. **near 대역 결과는 가설로 남기고 독립 표본에서 재검정해야 한다.**

**실무 지침 셋.** (1) 도킹 결과를 쓰기 전에 재도킹 대조를 C1/C2 로 쪼개고 깊이를 흔들어 병목을 특정하라. (2) 점수를 매긴 자세가 실제로 어디에 놓였는지 먼저 보고하라 — 본 연구에서 그 비율은 19.0% 였고, 이 사실 없이 상관값만 보면 무엇을 측정했는지 알 수 없다. (3) 벤치마크 집합의 골격 유사성을 통제하라 — 선행 문헌이 반복해 지적한 문제이고 [R12, R13, R14] 비용도 낮다. 다만 본 연구에서 그 통제가 바꾼 몫은 거의 0 이었다는 사실도 함께 적어야 정직하다.

**가장 중요한 결론은 이 연구가 자기 자신에 대해 알아낸 것이다.** 같은 표적·같은 도구·같은 채점 함수로 세 판본을 냈고, 세 번 모두 자동 게이트를 전부 통과했으며, 결론은 세 번 달랐다.

- v1.0 "예측하지 못한다" → 선별 지표를 계산하지 않았기 때문 - v2.0 "선별은 된다" → 표본이 골격에 치우쳐 있었기 때문 - v3.0 초안 "그 치우침이 원인이었다" → **검정해 보니 아니었다** (§ 3.5)

세 번 모두 게이트가 아니라 외부 비평이 오류를 찾았다. 게이트는 수치가 산출되었는지, 출처와 맞는지, 형식이 옳은지를 검사한다. 그것은 필요조건이고, **결론이 데이터에서 따라 나오는지**는 검사하지 못한다. 세 번째 판본이 자기 초안의 인과 주장을 스스로 기각하게 된 것도 리뷰어가 "그 설명을 옛 데이터에 적용해 보라"고 요구했기 때문이다. 그 한 줄의 요구가 1.2% 라는 수치를 만들었고, 그 수치가 논문의 중심 주장을 무너뜨렸다.

## 참고문헌

1. [R1] Sung B-J, Hwang KY, Jeon YH, et al. Structure of the catalytic domain of human phosphodiesterase 5 with bound drug molecules. *\*Nature\** 2003;425:98–102. doi:10.1038/nature01914. — PDB 1UDT 원논문. 2. [R2] Card GL, England BP, Suzuki Y, et al. Structural basis for the activity of drugs that inhibit phosphodiesterases. *\*Structure\** 2004;12:2233–2247. doi:10.1016/j.str.2004.10.004. 3. [R3] Trott O, Olson AJ. AutoDock Vina: improving the speed and accuracy of docking with a new scoring function, efficient optimization, and multithreading. *\*J Comput Chem\** 2010;31:455–461. doi:10.1002/jcc.21334. 4. [R4] Koes DR, Baumgartner MP, Camacho CJ. Lessons learned in empirical scoring with smina from the CSAR 2011 benchmarking exercise. *\*J Chem Inf Model\** 2013;53:1893–1904. doi:10.1021/ci300604z. 5. [R5] Warren GL, Andrews CW, Capelli A-M, et al. A critical assessment of docking programs and scoring functions. *\*J Med Chem\** 2006;49:5912–5931. doi:10.1021/jm050362n. 6. [R6] Enyedy IJ, Egan WJ. Can we use docking and scoring for hit-to-lead optimization? *\*J Comput Aided Mol Des\** 2008;22:161–168. doi:10.1007/s10822-007-9165-4. 7. [R7] Rogers D, Hahn M. Extended-connectivity fingerprints. *\*J Chem Inf Model\** 2010;50:742–754. doi:10.1021/ci100050t. — 본 연구의 골격 유사도 지문. 8. [R8] Truchon J-F, Bayly CI.



Evaluating virtual screening methods: good and bad metrics for the "early recognition" problem. *J Chem Inf Model* 2007;47:488–508. doi:10.1021/ci600426e. 9. [R9] Zdrazil B, Felix E, Hunter F, et al. The ChEMBL Database in 2023. *Nucleic Acids Res* 2024;52:D1180–D1192. doi:10.1093/nar/gkad1004. 10. [R10] O'Boyle NM, Banck M, James CA, et al. Open Babel: An open chemical toolbox. *J Cheminform* 2011;3:33. doi:10.1186/1758-2946-3-33. 11. [R11] Landrum G. RDKit: Open-source cheminformatics. <<https://www.rdkit.org>>. 12. [R12] Mysinger MM, Carchia M, Irwin JJ, Shoichet BK. Directory of Useful Decoys, Enhanced (DUD-E): better ligands and decoys for better benchmarking. *J Med Chem* 2012;55:6582–6594. doi:10.1021/jm300687e. — 벤치마크 집합의 편향 문제. 13. [R13] Tran-Nguyen V-K, Jacquemard C, Rognan D. LIT-PCBA: An unbiased data set for machine learning and virtual screening. *J Chem Inf Model* 2020;60:4263–4273. doi:10.1021/acs.jcim.0c00155. — 활성/비활성 집합의 유사성 편향 보정. 14. [R14] Chen L, Cruz A, Ramsey S, et al. Hidden bias in the DUD-E dataset leads to misleading performance of deep learning in structure-based virtual screening. *PLoS ONE* 2019;14:e0220113. doi:10.1371/journal.pone.0220113.

**출처 확인 범위.** 인용은 서지사항 수준에서 확인했다. 본 보고의 어떤 수치도 문헌에서 가져오지 않았다. 모든 수치는 sample\_run/ 산출 파일의 계산값이다.

## 윤리 · 라이선스 · 이해상충

**연구 범위.** 분자 수준의 계산 실험이다. 인간 피험자·동물·환자 데이터를 쓰지 않았고 인구집단에 대한 추론을 하지 않는다. 인구통계학적 공정성 분석은 해당되지 않는다.

**데이터 라이선스.** ChEMBL 은 CC BY-SA 3.0 [R9], PDB 좌표는 RCSB 를 통해 제약 없이 제공된다. 도구는 AutoDock Vina(Apache-2.0), smina(GPL-2.0), Open Babel(GPL-2.0), RDKit(BSD-3-Clause), PyMOL(오픈소스판).

**이중 용도.** 산출물은 공개 DB 에 이미 있는 기지 화합물의 도킹 점수와, 평가 설계에 관한 방법론적 음성 결과다. 신규 화합물 설계나 합성 경로를 제시하지 않는다.

**이해상충.** 없다. 외부 연구비 지원을 받지 않았다.

**목적.** 교육 목적의 시연이다. 결론을 임상적·규제적 판단의 근거로 사용해서는 안 된다.

## 검증 로그

| 단계           | 산출                      | 게이트 검사                                | 결과   |
|--------------|-------------------------|---------------------------------------|------|
| 데이터셋 (골격 통제) | dataset_controlled.json | 9 칸 충족 · 역가 3 로그 · 교란 $r < 0.35$ · 중복 | PASS |
| 도킹           | docking_controlled.json | 성공률 95% · C1 대조 · 전 화합물 점수 · 9 칸 대표   | PASS |
| 탐색 깊이 스위프    | exhaustiveness_sweep.j  | 전 조건 실행 · 4 단계 이상                     | PASS |




|             |                                |                                       |      |
|-------------|--------------------------------|---------------------------------------|------|
|             | son                            | · 복수 시드                               |      |
| 통제 분석       | analysis_controlled.json       | 상관 · 3 구간 · 편상관 · 순열 p                | PASS |
| 항 분석        | terms_controlled.json          | 추출률 95% · 4 모델 · VIF · 섞기 1000 회      | PASS |
| 접촉 일치       | contact_concordance.json       | 강함 층 전수 · 두 자세 접촉                     | PASS |
| 통계 함수 검증    | statistics_validation.json     | Spearman · 편상관 · AUC · CI · SDF 파서 대조 | PASS |
| 커스텀 채점 검증   | custom_scoring_controlled.json | 층화 분할 · 훈련/시험 분리 · 부트스트랩              | PASS |
| 상관 붕괴 원인 검정 | collapse_diagnosis.json        | 옛 데이터 편상관 · 설계 재현 추출 · 표본크기 대조        | PASS |

게이트가 검사하지 않는 것. 게이트는 수치가 산출되었는지와 형식이 맞는지를 볼 뿐, **결론이 데이터와 일치하는지는 보지 못한다**. 이 연구의 이전 판(v2.0)은 모든 게이트를 통과한 상태에서 골격 교란을 인지하지 못한 결론을 담고 있었다. 그것을 잡아낸 것은 게이트가 아니라 외부 비평 리뷰였다.

## 개정 이력

**v1.0** — n=30, 역가로만 층화. 결론: "도킹은 역가를 예측하지 못한다".

**v2.0** — 외부 리뷰가 결론이 자기 데이터와 모순됨을 지적. 선별 지표(ROC-AUC, 농축)를 계산하니 AUC 0.775, 점수 상위 10 건에 약한 화합물 0 건이었다. 결론을 "선별에는 쓸 수 있고 정량에는 쓸 수 없다"로 바꾸고, 접촉 잔기 논증의 순환성을 철회했다.



**Figure 14. 판본별 결론과 그것을 무너뜨린 관찰.** (A) 판본별 헤드라인 수치, (B) 각 판본의 결론과 붕괴 사유, (C) 무엇이 오류를 잡았는가. 자동 게이트는 세 판본 모두 전부 통과했다.

**v3.0 (본 판)** — v2.0의 긍정적 선별 결론이 **골격 교란으로 해석 불가능함**을 확인. 강함 층은 공결정 리간드 유사 골격(MCS 평균 16.6 원자)이 주도하고 약함 층은 무관한 골격(9.4 원자)이었으며, 수용체가 그 리간드의 **holo** 구조였다. 다음을 새로 했다.

1. **데이터셋 재설계** — 역가  $\times$  골격 유사도 9 칸 격자,  $n=163$ , 교란  $r+0.175$ . 반복 측정 중앙값 집계. 2. **탐색 깊이 통제 실험** — 자세/채점 진단을  $n=1$ 에서 스윙으로 대체. 3. **편상관·구간내 분석** — 골격 통제 후 신호 잔존 여부를 직접 검정. 4. **주 자세를 점수 1 위로 전환** — 공결정 리간드를 참조하지 않는 규칙을 주 결과로. 5. **염 제거 명시화** — 도구 기본 동작에 맡기던 단계를 코드로. 5b. **커스텀 채점 재검증** — 이전  $n=10$  시험은 검정력이 없었다. 9 칸 층화 분할 (훈련 114 / 시험 49)로 재실행 (§ 3.10). 7. **초안의 인과 주장 철회** — 초안은 v1/v2의 상관을 골격 교란의 산물로 설명했다. 외부 비평 리뷰가 그 설명을 검정하라고 요구했고, 검정 결과 옛 데이터에서 골격 통제의 감쇠는 0.8%에 불과했다. 해당 주장을 철회하고 § 3.5에 검정 기록으로 대체했다. 8. **자세 타당도 보고** — 1 위 자세의 81%가 2 Å 기준 밖이라는 사실이 초안에 없었다. § 3.6 신설. 9. **불확실성 보강** — AUC 신뢰구간, 다중비교 보정, 최소검출효과, near 대역 민감도, 대역별 교란 통제를 추가했다. 모두 초안에 없던 것이며 일부는 결론을 약화시킨다. 6. **전 그림 재생성** — 본문이 바뀌면 그림도 바뀌어야 한다.

## 무-날조 선언

본 보고서의 결과 수치는 전부 `sample_run/`의 산출 파일에서 스크립트가 주입한 값이다. 서술문과 절 제목은 사람이 작성했다. 산출되지 않은 양은 산출되지 않았다고 적었다.