


QSAR/QSPR — 구조-특성 함수를 학습



가정: 비슷한 구조 → 비슷한 특성

7/23 · 2 교시 · 4 시간 중 1 시간

특성 예측의 원리와 구현

QSAR/QSPR · 데이터 · 표현 · 모델 · 파이프라인 — 구조에서 특성을 어떻게 학습하나

이론 · 전공자 · 현직자

1 교시 → 2 교시

1 교시 (무엇을)

- ADMET· 물성이 무엇인지
- 각 특성의 실험 assay·endpoint
- '예측 대상'을 정의했다

2 교시 (어떻게)

- 구조→특성을 학습하는 원리 (QSAR)
- 데이터 · 표현 · 모델 선택
- 파이프라인 · 검증 · 함정 — 실습 (4 교시) 의 토대

2 교시에서 볼 것

파트	내용
A · QSAR/QSPR	구조→특성 가정 · 유사성 · property cliff
B · 데이터	ChEMBL·TDC · 규모 감각 · 품질 = 성능 상한 · SOTA
C · 표현	descriptor · 지문 · 그래프 — 특성별 선택
D · 모델 · 검증	회귀 / 분류 · 지표 · baseline · scaffold split
E · 파이프라인 · 도구	전체 파이프라인 · OSS · 무료 웹 · 상용
F · 최신 · 재현성	파운데이션 · baseline 논쟁 · prospective
G · 함정 · 정리	누수 · 불균형 · 적용범위 (AD)


PART A

QSAR / QSPR

구조가 특성을 결정한다 — 그 함수를 배운다

QSAR/QSPR — 구조→특성 함수를 학습

QSAR/QSPR — 구조→특성 함수를 학습



가정: 비슷한 구조 → 비슷한 특성


- QSAR — 정량적 구조 - 활성 관계
- ^{활성, 독성}QSPR — 정량적 구조 - 물성 관계
- ^{용해도, logP}가정: 비슷한 구조 → 비슷한 특성
- 표현 (descriptor) 으로 구조를 숫자화 → 모델

용어 · QSAR/QSPR

구조를 수치 표현으로 바꿔 활성 · 물성을 예측하는 통계 · ML 모델 계열

QSAR의 흐름 — Hansch 에서 딥러닝까지

QSAR의 흐름 — Hansch에서 딥러닝까지




핵심은 같다 — '구조를 어떻게 숫자로(표현)·어떤 함수로 매핑(모델)'

+ 심화

핵심은 계속 같다 — '구조를 어떻게 숫자로 (표현), 어떤 함수로 특성에 매핑 (모델)'. 딥러닝은 표현을 '학습'한다는 점이 다름

유사성 원리 · property cliff

- 유사성 원리 : 닮은 분자는 닮은 특성
- QSAR· 유사성 검색의 근거
- 예외 : activity/property cliff
- 작은 변화가 특성을 급변 → 모델이 놓침



용어 · cliff

구조는 거의 같은데 특성이 급변하는 쌍 — 국소적으로 QSAR 가정이 깨짐

믿을 수 있는 QSAR — OECD 5 원칙

원칙	내용
① 명확한 endpoint	무엇을 예측하는지 정의 (assay· 단위)
② 명시적 알고리즘	재현 가능한 모델 · 코드
③ 적용범위 (AD)	신뢰할 화학공간 정의 (4 교시)
④ 성능 · 강건성	적합 · 교차검증 · 외부 검증 지표
⑤ 기계적 해석 (가능시)	가능하면 기전 설명 (SHAP· 경보)

+ 심화

규제 (ICH M7 등) 에서 (Q)SAR 을 받아들이는 근거 를 — ' 성능 ' 만이 아니라 정의 · 재현 · 적용범위 · 해석까지 갖춰야 ' 믿을 수 있는 ' 모델

PART B

데이터

특성 예측의 '정답'은 어디서 오나 — 품질이 성능 상한

특성 데이터의 출처

- ChEMBL

활성 · 물성 · ADMET 실험값 (대규모)

- PubChem


생물검정 대량

- Tox21 / ToxCast

독성 스크리닝 (공공)

- TDC

ADMET 벤치마크 표준화 (다음 장)




용어 · endpoint

예측 대상이 되는 하나의 특성 · assay 결과 (예 : hERG 저해 , 용해도 logS)

Therapeutics Data Commons (TDC)

- 신약개발 ML 데이터 · 벤치마크를 표준화한 오픈 리소스
- ADME·Tox·HTS 등 다수 endpoint 를 통일된 API 로
- scaffold split· 평가지표까지 제공 → 재현 · 비교 용이
- 4 교시 hERG 실습의 데이터 출처



+ 심화

TDC 는 ' 데이터 로드 → 표준 split → 평가 ' 를 한 API 로 통일해 논문마다 다른 split· 지표 문제를 줄인다

데이터 규모 감각 — 왜 소규모가 제약인가

- **ADMET endpoint** 는 대체로 수백 ~ 수천 분자

이미지 · NLP 의 수백만과 다르다


- **작은 test** 는 지표가 노이즈에 민감

hERG 648 · DILI 475

- **불균형 (독성 양성 소수)** 까지 흔함

- → **소규모 · 불균형 · 노이즈가 이 분야 ML 의 지배적 제약**

TDC ADMET — 데이터 규모 감각



+ 심화

핵심 감각 : 대규모 딥러닝의 직관을 그대로 옮기면 안 된다 — 소규모엔 단순 모델 · 강한 검증

데이터 품질이 성능의 상한

● assay 이질성

측정 조건 다른 값 섞으면 노이즈↑

● 단위 · 부호


IC50 vs pIC50, % 저해 vs 연속값 혼재 주의

● 중복 · 상충

같은 분자 다른 값 → 정제 필요 (7/22 연계)

● 불균형

독성 양성 소수 → 지표 · 샘플링 고려



합정

라벨 노이즈에는 '상한' 이 있다 — 실험 재현 오차만으로도 모델 정확도 천장이 생김 (무한정 좋아지지 않음)

데이터 정제 파이프라인 — '정답' 을 만든다

데이터 정제 파이프라인 — '정답'을 만든다



7/22(표현·DB)와 직결 — 정제 품질이 곧 모델 성능 상한

- 표준화 (SMILES 정규화 · salt 제거 · 중화) → 같은 분자 통일
- 중복 · 상충 병합 · 단위 / 부호 통일 (IC50→pIC50)
- 이상치 · 범위 검증 — 라벨 노이즈가 곧 성능 상한 (7/22 연계)

+ 심화

모델 코드보다 정제가 성능을 더 바꾸는 일이 흔하다 — '쓰레기 입력, 쓰레기 출력'

불균형 데이터 , 어떻게 다루나

- 클래스 가중

scale_pos_weight 로 소수 (양성) 에 가중

- 리샘플링


over/under-SMOTE (누수 주의)

- 지표 변경

정확도 대신 PR-AUC·MCC

- 임계값 조정

' 위험 놓침 ' 비용 크면 recall 우선



합정

리샘플링은 반드시 train 에만 — valid/test 에 적용하면 누수 . 4 교시 실습에서 scale_pos_weight+ 임계로 처리

현재 성능 · 규제 — 왜 지금인가

endpoint	표준 데이터	현재 성능 (출처)
용해도	ESOL·AqSolDB	MAE ~0.74 log (TDC)
투과 Caco-2	Caco2_Wang 906	MAE ~0.26 log (TDC)
CYP2C9 저해	Veith 12,092	AUPRC ~0.86 (TDC)
Ames	Hansen 7,255	AUROC ~0.87 (TDC)
DILI	TDC 475 / DIL1st	AUROC ~0.96 (작은 test 주의)
hERG	TDC 648 · scaffold	AUROC ~0.88 (MapLight+GNN)

+ 심화

FDA NAMs(동물시험 대체 · 감축) 흐름으로 in-silico ADMET 의 규제적 수용 · 실무 수요가 구조적으로 증가 — 단 , 규제용은 검증 · 문서화 · 적용범위 근거 필요

PART C

표현 (representation)

특성별로 무엇이 잘 되나 — descriptor · 지문 · 그래프

분자 표현 3 계열 (7/22 복습)

물성 descriptor




MW·logP·TPSA 계산값

지문(fingerprint)



ECFP 등 부분구조 존재 비트

그래프(graph)



원자=노드·결합=엣지 → GNN 학습

- 물성 descriptor
- 지문 (fingerprint)
- 그래프 (graph)

원자 = 노드 · 결합 = 엣지 → GNN 이 표현 학습

용어 · ECFP

원형 부분구조를 해시한 지문 — 활성 · 독성 분류의 강건한 표준 표현

ECFP4 원리 — 원자 환경을 확장 · 해시

ECFP4 원리 — 원자 환경을 반복 확장·해시



부분구조 존재를 비트로 · 반경2=ECFP4 · 해시 충돌은 감수

- 각 원자 중심으로 반경 0→1→2 이웃 환경을 반복 확장 (Morgan)
- 각 부분구조를 해시 → 고정 길이 비트벡터 (예 : 2048)
- 반경 2 = ECFP4 · 해시 충돌 (collision) 은 감수 · 비트 = 부분구조 존재

+ 심화

카운트형 (ECFP count)·FCFP(기능형)· 해시 크기 등이 변형 축 — 소규모 분류엔 여전히 강한 표준 표현

descriptor 종류 — 무엇을 숫자화하나

범주	예	용도
물리화학	MW·logP·TPSA·HBD/HBA	물성 ·Ro5
구성 · 토폴로지	원자수 · 고리 · 연결성 지수	전반 특성
전자적	부분전하 · 극성 ·HOMO/LUMO	반응성 · 대사
3D/ 형태	표면적 · 부피 ·pharmacophore	형태 의존 특성

+ 심화

RDKit 만으로 200+ descriptor 계산 가능 — 물성 · 회귀에 강함 . 단 , 스케일 제각각이라 선형 · 신경망엔 표준화 필요

3D· 구조 기반 표현 — 언제 필요한가

2D(지문 · descriptor)

- 빠르고 강건 · 대부분 ADMET 에 충분
- conformer 불필요
- 소규모에 안전

3D(형태 · 구조)

- conformer·pharmacophore· 정전기 표면
- 단백질 - 리간드 결합 · 형태 의존 특성
- 비용↑ · conformer 오류 위험

**합정**

3D 가 항상 낫진 않다 — conformer 생성 오류가 노이즈를 더할 수 있음 . 특성이 형태에 강하게 의존할 때만 이득

특성별 표현 선택 — 경험칙

상황	권장 표현	이유
물성 (용해도 · logP)	descriptor+ 지문	물성은 계산 descriptor 가 강함
활성 · 독성 분류	ECFP4 지문	부분구조 신호 강함 · 강건
대규모 · 복잡 패턴	그래프 (GNN)	표현을 데이터로 학습
소규모 데이터	지문 + 트리	GNN 은 데이터 부족 시 불리

+ 심화



'그래프가 항상 낫다' 는 오해 — 물성 · 소규모에선 descriptor/ 지문 + 트리가 자주 동급 이상 . 표현은 특성 · 데이터 크기에 맞춰 선택

PART D

모델 · 검증

회귀 / 분류 · baseline · GNN · scaffold split

회귀나 분류냐 — 특성이 결정



- 회귀
- 분류 $(\log S) \cdot \log P \cdot \text{clearance} \cdot t_{1/2}$ — RMSE · MAE · R^2 · Spearman
- 불균형 (양성 소수)에선 PR-AUC가 ROC보다 민감

용어 · PR-AUC

정밀도 - 재현율 곡선 아래 면적 — 불균형 분류에서 ROC보다 성능차를 잘 드러냄

지표 심화 — 무엇을 언제 보나

유형	지표	언제 · 주의
회귀	RMSE·MAE	단위 그대로 · 큰 오차 강조 =RMSE
회귀	R ² ·Spearman	순위만 중요하면 Spearman
분류 (균형)	ROC-AUC· 정확도	불균형이면 부적절
분류 (불균형)	PR-AUC·MCC·recall	hERG· 독성은 여기
스크리닝	EF·BEDROC	상위 순위 집중

+ 심화

MCC(Matthews) 는 불균형에서 균형 잡힌 단일 지표 · EF/BEDROC 는 ' 상위 N 개에 진짜가 얼마나 ' 를 본다 (스크리닝 관점)

무엇을 먼저 ? — baseline 이 강하다

- RF / XGBoost + 지문 = 강한 baseline

특성 예측에서 자주 최상위권

- GNN(Chemprop)


대규모 · 복잡 특성에서 이득 가능

- 멀티태스크 · 사전학습

데이터 적은 endpoint 에 유리 (3 교시)

- 항상 baseline 먼저 → 딥러닝은 그 다음

무엇을 먼저? — baseline이 강하다



합정

baseline(XGBoost) 없이 GNN 만 보고 '딥러닝 우수' 주장 금지 — 여러 ADMET 벤치마크에서 트리 앙상블이 GNN 과 동급 / 우위

그래프 신경망 (D-MPNN) — 표현을 학습

GNN(D-MPNN) — 결합 따라 메시지 전달·집계




- ① 결합 따라 이웃 메시지 집계 → ② 노드 갱신 (T 회 반복)
- ③ readout 로 분자 벡터 → 특성 예측 (표현을 데이터로 학습)
- 대규모 · 복잡 패턴에서 이득 — 소규모 · 물성엔 지문 + 트리가 자주 동급

용어 · D-MPNN

결합 (엣지) 메시지를 전달하는 그래프 신경망 (Chemprop) — 학습된 분자 표현

검증 — scaffold split (누수 방지)

- random split 은 유사 분자가 train/test 에 함께 → 과대평가
- scaffold split: 골격 기준 분리 → 현실적 일반화
- TDC 기본 제공 · 실습에서 사용
- 시간분할 (temporal) 도 현업에선 중요




용어 · scaffold split

Bemis-Murcko 골격 기준으로 train/test 를 나눠 구조 누수를 막는 분할

교차검증 — 어떻게 나누나

- k-fold: 데이터를 k 등분, 돌아가며 valid
- 신약은 scaffold/group CV 권장 — 구조 누수 방지
- nested CV: 튜닝 (내부) 과 평가 (외부) 를 분리
- 소규모일수록 다 -fold· 다 -seed 로 분산까지 보고

교차검증 — k-fold / scaffold·group / nested



신약:
scaffold/
group CV
권장

+ 심화

단일 split 의 숫자는 우연에 흔들린다 — 특히 작은 test(hERG 648) 는 fold·seed 마다 크게 달라짐

하이퍼파라미터 튜닝 — 누수 없이

올바른 방법

- valid(또는 nested CV 내부) 로만 튜닝
- Optuna 등으로 탐색 · seed 고정
- 최종 성능은 ' 건드리지 않은 ' test 로 1 회

흔한 누수 (금지)

- test 로 튜닝 · 조기중단
- 전체 데이터로 featurize · 스케일 fit
- 리샘플링을 split 전에 적용



함정

'test 로 하이퍼파라미터를 골랐다 ' 가 가장 흔한 낙관 편향 — 리더보드 과대성능의 단골 원인

앙상블 — 예측 + 불확실성


- 여러 모델 (seed·서브샘플) 예측을 평균 → 성능 ↑ · 안정 ↑

- 예측값의 '흩어짐 (분산)' 이 곧 불확실성 신호

- deep ensemble·MC dropout·트리 분산

- 4 교시 conformal·적용범위와 연결

앙상블 — 예측값 + '얼마나 흩어지나'(불확실성)



deep ensemble·MC dropout·트리 분산 → 4교시 conformal과 연결

용어 · 불확실성

예측이 얼마나 믿을 만한지의 정량 — 앙상블 분산 ·conformal 로 추정 (4 교시)

PART E

파이프라인 · 도구 지형

data→featurize→...→eval · OSS · 무료 웹 · 상용

특성 예측 파이프라인 전체

특성 예측 파이프라인 전체



- ① 데이터 (TDC/ChEMBL) → ② 정제 · featurize(ECFP/descriptor) → ③ scaffold split
- ④ 학습 (baseline XGBoost → 튜닝) → ⑤ 평가 (다지표) → ⑥ 예측 · 스코어링

+ 심화

각 단계에 대응 도구가 있다 — 다음 3 장에서 OSS · 무료 웹 · 상용을 지형으로 정리 (4 교시 실습이 이 파이프라인)

오픈소스 스택 (실습 기반)

도구	역할	비고
RDKit	표준화 ·descriptor· 지문	케미인포 표준
PyTDC	데이터 ·split· 벤치마크	실습 데이터 출처
scikit-learn / XGBoost	baseline 모델	강한 기준선
DeepChem	MoleculeNet 통합 파이프	featurizer 다수
Chemprop	D-MPNN(GNN)	대규모 특성용

무료 웹 ADMET 예측기 — 2024 세대

도구 (기관)	커버리지 · 방법	특징
ADMETlab 3.0 (CSU)	119 feature · 멀티태스크 DMPNN	불확실성 +API
admetSAR 3.0 (ECUST)	최다 endpoint · 37 만 실험값	검색 + 예측
ProTox 3.0 (Charité)	독성 61 endpoint	BA 86%
Deep-PK (KAIST)	PK · 독성 73 endpoint · D-MPNN	GNN
ADMET-AI (Stanford)	41 ADMET (Chemprop) + 8 물성	리더보드 1 위

+ 심화

2024 Nucleic Acids Research 웹서버 특집에 ADMETlab · admetSAR · ProTox · Deep-PK 동시 게재 — '2024 무료 ADMET 예측기의 현주소 '

상용 플랫폼 — 현업 표준

플랫폼 (벤더)	무엇을 · 방법	포지션
ADMET Predictor (Sim+)	175+ 물성 ·v13+GastroPlus PBPK	ADMET 전문 1 위
QikProp (Schrödinger)	물성 ·ADME+DeepAutoQSAR·LiveDesign	suite 통합
StarDrop (Optibrium)	QSAR+MPO+Glowing Molecule	해석 · 의사결정
Percepta (ACD/Labs)	25+ 물성 · 독성 ·v2024	물성 강점
MetaSite (Mol Discovery)	CYP 대사 부위 예측	top-3 >90%

⚠ 함정

상용 예측값도 '정답' 아님 — 적용범위 밖 (신규 골격) 에선 크게 틀릴 수 있음 . 내부 데이터로 재보정 · 검증 필요

PART F


최신 연구 · 재현성

파운데이션 모델 · baseline 논쟁 · prospective 검증

분자 파운데이션 모델 — 무엇이 달라졌나

- 수억 ~ 수십억 분자로 자기지도 사전학습
- 학습된 표현을 여러 특성으로 전이 (fine-tune)
- SMILES LM / 그래프 / 3D 계열 (MoLFormer·Uni-Mol·MolE·MolGPS)
- 데이터 적은 endpoint에 특히 기대

분자 파운데이션 모델 — 사전학습 후 여러 특성으로 전이



데이터 적은 endpoint에 특히 기대




합정

'저자 / 벤더 보고 성적' 과 '독립 재현 성적' 은 다름 — reported value 로만 받아들이고 baseline 과 비교

정말 더 나은가 ? — baseline 논쟁

- Jiang 2021: descriptor+RF/XGBoost $\approx$ GNN
- 대규모 비교 : 사전학습 임베딩이 ECFP 대비 유의차 작음
- 여러 공개 리더보드 : 최고 성적 상당수가 고전 ML
- → scaffold/random split 공개벤치에선 baseline 이 강함




+ 심화

딥러닝이 이길 때는 대개 (a) 대규모 생물학적 멀티태스크 사전학습이나 (b) 지문·descriptor 하이브리드일 때


딥러닝이 특히 약한 곳 — activity cliff

- activity cliff: 구조 거의 같은데 활성 급변
- van Tilborg 2022: 30 타깃 · 720 모델 벤치마크
- cliff 화합물에서 descriptor 기반 고전 ML 이 딥러닝 능가
- → '평균 성능' 이 좋아도 '중요한 쌍' 을 놓칠 수 있음



리더보드를 의심하라 — 재현성 위기

- 2026 TDC 비판적 재평가: 상위 방법 중 3 개만 전 검증 통과
CaliciBoost·MapLight·MapLight+GNN
- 나머지는 코드부재 · 환경파손 · 데이터 누수 · test 과적합
- 작은 test(hERG 648·DILI 475) 는 AUROC 수천분의 1 차이 = 노이즈



합정

논문 '리더보드 1 위' 를 그대로 믿지 말 것 — 누수 · 재현불가가 혼함 . 항상 tuned ECFP+GBDT baseline 과 비교

회고 성능 ≠ 실제 예측력

retrospective (공개벤치)

- random/scaffold split
- 딥러닝 우위 주장 → 회의적으로
- 누수 · 과적합 위험

prospective (현업)

- Fang 2023: 내부 120 데이터 · 20 개월 · 6 ADME assay
- 시간이 지나며 GBDT · 딥러닝 > RF
- temporal split 이 배포에 가까움

+ 심화

교훈 : ' 평가를 배포와 일치시켜라 ' — 진짜 prospective 엔 GBDT · 현대 DL 이 경쟁력↑ , 공개 리더보드 DL 주장엔 회의적 + 항상 baseline

PART G

함정 & 정리

노이즈 상한 · 불균형 · applicability domain

특성 예측의 흔한 함정

● 데이터 누수

random split · 중복 분자 → 성능 착시

● 불균형 무시


정확도만 보면 독성 소수 클래스 놓침

● 적용범위 (AD) 무시

훈련 분포 밖 분자는 예측 신뢰 낮음

● 단일 지표 맹신

RMSE 만 · AUC 만 → 다지표 + 보정 필요



용어 · applicability
domain

모델이 신뢰할 수 있는 화학공간 범위 — 밖의 예측은 경고 (3 교시 불확실성)

2 교시 정리

1

QSAR/QSPR = 구조→특성 함수 학습

유사성 원리 · property cliff 유의

2

데이터 품질이 성능 상한

assay 이질성 · 노이즈 상한 · 불균형

3

표현은 특성 · 데이터 크기에 맞춰

물성 =descriptor, 분류 =ECFP, 대규모 =GNN

4

baseline(XGBoost) 먼저 · scaffold split 로 검증

5

적용범위 · 다지표로 신뢰 관리

다음 : 실제 구현 +hERG 실습 (4 교시)