

특정 예측 파이프라인 전체



7/23 · 4 교시 (실습) · 4 시간 중 1 시간

실습 — hERG 예측 : baseline vs 딥러닝

데이터 정제 → ECFP+XGBoost(baseline) vs GNN(D-MPNN) 비교 → 해석 · 불확실성

Jupyter 노트북 (Colab 실행 · 결과 포함) · TDC/dataverse·RDKit·XGBoost·PyTorch

3 교시 → 실습

강의 (1~3 교시)

- 무엇을 · 왜 → 어떻게 (원리) → 믿고 쓰기
- 'baseline 먼저 , 딥러닝은 그 다음 '
- 데이터 품질 = 성능 상한

실습 (지금)

- 데이터를 제대로 정제
- baseline(XGBoost) vs 딥러닝 (GNN) 같은 split 비교
- + SHAP 해석 · conformal 불확실성

오늘 만드는 것 — 전체 파이프라인


- 원본 → 정제 (표준화 · 중복 / 상충 제거) → ECFP4 → scaffold split
- ① baseline: ECFP+XGBoost ② 딥러닝 : GNN(D-MPNN)
- 같은 split 에서 비교 → 새 분자 예측 → 해석 · 불확실성
- Colab 에서 실행 (GNN 은 GPU 권장 , CPU 도 수 분)

특성 예측 파이프라인 전체



데이터는 TDC에만 있지 않다

- TDC = 여러 출처를 표준화한 벤치마크 래퍼 (원천은 ChEMBL·문헌)
- 노트북 : PyTDC → dataverse 직접 다운로드 → CSV 어느 경로든
- 기본 데이터 : hERG_Karim(≈13k·균형) — 소규모 hERG(655) 보다 깨끗
- 출처 무엇이든 'SMILES + 라벨' 이면 같은 파이프라인



+ 심화

PyTDC 가 없어도 동일 원본을 직접 내려받아 동작 — 오프라인 · 재현 가능 · df 만 바꾸면 어떤 출처든 연결

데이터 정제 — 이 실습의 핵심

- 표준화 : salt/ 용매 제거 (가장 큰 조각) · 중화 · canonical SMILES

- 유효성 : 파싱 실패 분자 제거

- 중복 병합 · 상충 라벨 제거

같은 분자에 측정이 엇갈리면 버린다 (노이즈 차단)

- 결과 : 13,445 → 13,136 (상충 16 개 제거 · 균형 50%)

데이터 정제 파이프라인 — '정답'을 만든다



7/22(표현·DB)와 직결 — 정제 품질이 곧 모델 성능 상한



함정

모델보다 데이터가 먼저 — 정제 없이 학습하면 성능이 부풀거나 (누수) 노이즈로 무너진다

노트북 단계 — 셀별 요약

셀	무엇을	핵심
정제	표준화 · 중복 / 상충 제거	RDKit MolStandardize
featurize·split	ECFP4 · scaffold split	구조 누수 방지
① baseline	XGBoost(scale_pos_weight)	강한 기준선
② 딥러닝	GNN D-MPNN(PyTorch)	메시지 전달 · 표현 학습
비교	같은 split · PR-AUC·MCC	baseline vs 딥러닝
해석 · 불확실성	SHAP · split-conformal	왜 · 얼마나 믿나

핵심 코드 — 정제 & GNN

정제 (표준화 · 상충 제거) + GNN 메시지 패싱


```
# 표준화 : 염 제거 → 중화 → canonical
m = _lfc.choose(rdMolStandardize.Cleanup(m)); m = _unc.uncharge(m)
can = Chem.MolToSmiles(m)           # 중복은 canonical로 병합, 상충 라벨은 제거

# GNN 메시지 패싱 (D-MPNN): 결합 따라 이웃 메시지 집계 → 노드 갱신
m = msg(h)[src] * torch.sigmoid(et(edge_type)) # 결합종류 게이트
agg = torch.zeros_like(h).index_add_(0, dst, m) # 이웃 집계
h = gru(agg, h)                                # 노드 갱신 (T 회 반복)
```

+ 심화

GNN은 분자를 그래프로 보고 표현을 '학습' — baseline(고정 지문)과 대비되는 딥러닝 접근

baseline vs 딥러닝 — 실제 결과




- **baseline XGBoost**
ROC 0.836 · PR 0.824
- **지문 +descriptor**
ROC 0.869 · PR 0.854 (최고)
- **GNN D-MPNN**
ROC 0.754 · PR 0.737
- → 같은 split 에서 baseline 우위

+ 심화



강의 핵심 확인 — 소규모 / 중간 ADMET 에션 족석 GNN 이 튜닝된 트리 baseline 을 넘기 어렵다 . GNN 은 더 많은 데이터 · 튜닝 · 사전학습에서 이득

새 분자 예측 & baseline 강화

- 학습된 baseline 으로 임의 SMILES 위험 확률 즉시 산출
- astemizole 0.98(알려진 차단제) · aspirin 0.07(안전)
- 예측 전에도 동일 표준화 적용 (일관성)
- 지문 +descriptor(MapLight) 로 PR-AUC 0.82→0.85



해석 (SHAP) · 불확실성 (conformal)




+ 심화

conformal: 목표 90% 커버리지 · 예측집합이 $\{0,1\}$ 이면 '모른다' 신호 · SHAP 는 위험 $\uparrow$ 부분구조를 지목 — 화학자에게 실행 신호

확장 & 자기검증 체크리스트

- 데이터 정제 (표준화 · 중복 · 상충) 했나 · scaffold split 인가
- tuned baseline 과 비교했나 · 다 seed · 다지표 (PR-AUC·MCC)
- 적용범위 · 불확실성을 함께 봤나 · ' 같은 split ' 에서만 비교
- 확장 : 다른 endpoint·Optuna·Chemprop(정식 D-MPNN)·MAPIE

SHAP — 어떤 부분구조가 hERG 위험을 올리/내리나



■ 위험↑ 기여 ■ 위험↓ 기여



합정

단일 실행 · 단일 지표로 ' 좋다 / 나쁘다 ' 결론 금지 — 다 seed · 다지표 · 불확실성까지

실습 정리 · 관통 메시지

- 데이터를 제대로 정제한 뒤 baseline 과 딥러닝 (GNN) 을 같은 split 에서 비교했다
- baseline 이 대등 / 우위 — 소규모 ADMET 의 전형 . 딥러닝은 데이터 · 튜닝 · 사전학습이 있을 때
- SHAP 로 ' 왜 ', conformal 로 ' 얼마나 믿나 ' 를 붙였다
- ' 어떤 모델이냐 ' 보다 ' 데이터를 어떻게 다듬고 어떻게 검증했느냐 '

확정은 실험 · 임상에서

노트북

Day3/T012_ADMET_hERG_Prediction.ipynb — Colab 에서 위→아래로 실행 (결과 · 그래프 포함)